



การสร้างแบบจำลองการวัดรายได้ทางอ้อมด้วยวิธี Machine Learning

โดย

ภวินทร์ เติวียนนท์

วิทยานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

เศรษฐศาสตรมหาบัณฑิต

คณะเศรษฐศาสตร์

คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์

ปีการศึกษา 2567

CREATING PROXY MEANS TEST BY USING MACHINE LEARNING
TECHNIQUES

BY

BHAWIN TEVEYANUN



A THESIS SUBMITTED IN PARTIAL FULFILLMENT OF THE REQUIREMENTS
FOR THE DEGREE OF MASTER IN ECONOMICS
FACULTY OF ECONOMICS
THAMMASAT UNIVERSITY
ACADEMIC YEAR 2024

มหาวิทยาลัยธรรมศาสตร์

คณะเศรษฐศาสตร์

วิทยานิพนธ์

ของ

ภวินทร์ เตเวียนันท์

เรื่อง

การสร้างแบบจำลองการวัดรายได้ทางอ้อมด้วยวิธี Machine Learning

ได้รับการตรวจสอบและอนุมัติ ให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร


เศรษฐศาสตรมหาบัณฑิต

เมื่อ วันที่ 9 กรกฎาคม พ.ศ. 2568

ประธานกรรมการสอบวิทยานิพนธ์

(ผู้ช่วยศาสตราจารย์ ดร.วศิน ศิวสุฤกษ์)

อาจารย์ที่ปรึกษาวิทยานิพนธ์



(รองศาสตราจารย์ ดร.ชัยยุทธ ปัญญสวัสดิ์สุทธิ์)

กรรมการสอบวิทยานิพนธ์

(รองศาสตราจารย์ ดร.ธนพงษ์ โพธิ์ปิติ)

คณบดี

(รองศาสตราจารย์ ดร.พีระ เจริญพร)

หัวข้อ	การสร้างแบบจำลองการวัดรายได้ทางอ้อมด้วยวิธี Machine Learning
ชื่อผู้เขียน	ภวินทร์ เติวียนันท์
ชื่อปริญญา	เศรษฐศาสตรมหาบัณฑิต
สาขาวิชา/คณะ/มหาวิทยาลัย	เศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์
อาจารย์ที่ปรึกษา	รองศาสตราจารย์ ดร.ชัยยุทธ ปัญญสวัสดิ์สุทธิ์
ปีการศึกษา	2567

บทคัดย่อ

งานวิจัยฉบับนี้มีวัตถุประสงค์เพื่อพัฒนาแบบจำลองการวัดรายได้ทางอ้อม (Proxy Means Test: PMT) โดยประยุกต์ใช้เทคนิค Machine Learning เพื่อเพิ่มความแม่นยำในการจำแนกครัวเรือนยากจนซึ่งเป็นเป้าหมายของนโยบายสวัสดิการภาครัฐ การศึกษาใช้ข้อมูลจากการสำรวจภาวะเศรษฐกิจและสังคมของครัวเรือน (SES) ปี พ.ศ. 2566 ซึ่งครอบคลุมข้อมูลระดับครัวเรือนและบุคคล เช่น รายได้ รายจ่าย สภาพที่อยู่อาศัย ทรัพย์สิน และลักษณะทางสังคมต่าง ๆ

การวิเคราะห์เริ่มจากการสร้างแบบจำลองพื้นฐาน (Baseline Models) คือ Logistic Regression จากนั้นเปรียบเทียบประสิทธิภาพกับแบบจำลอง Machine Learning ได้แก่ Random Forest และ LightGBM ทั้งในกรณีของการพยากรณ์รายได้ (Regression) และการจำแนกสถานะความยากจน (Classification) โดยใช้ตัวชี้วัดประสิทธิภาพ เช่น Root Mean Squared Error (RMSE), Precision, Recall, F1-Score และข้อผิดพลาดจากการคัดกรอง (Inclusion/Exclusion Error) นอกจากนี้ ยังมีการใช้เทคนิคการถ่วงน้ำหนักของกลุ่มที่สนใจ (Weight Class) และการตัดช่วงรายได้ (Income Cut-off) เพื่อมุ่งเน้นการจำแนกเฉพาะกลุ่มประชากรรายได้ต่ำซึ่งเป็นกลุ่มเป้าหมายที่แท้จริงของนโยบาย

นอกจากนี้งานวิจัยอาศัยการคำนวณ SHAP และ SHAP Regression เพื่อทำความเข้าใจอิทธิพลและแปรผลของแต่ละตัวแปรที่ส่งผลต่อผลลัพธ์ของแบบจำลอง Machine Learning การวิเคราะห์ SHAP regression ทำให้สามารถตีความค่าทำนายของแบบจำลองได้ในเชิงนโยบายอย่างมีความหมาย และแสดงให้เห็นความสำคัญของตัวแปรในแบบจำลอง

ผลการศึกษาแสดงให้เห็นว่า แบบจำลอง LightGBM ที่พัฒนาในงานวิจัยนี้มีประสิทธิภาพเหนือกว่า Baseline Models ทั้งในด้านค่าความผิดพลาดและความสามารถในการคัดกรองกลุ่มเป้าหมาย โดยเฉพาะเมื่อมีการปรับช่วงข้อมูลรายได้ ซึ่งส่งผลให้การจำแนกสถานะ

ความยากจนมีความแม่นยำและเที่ยงตรงมากยิ่งขึ้น ขณะที่ค่า SHAP ยังช่วยเปิดเผยโครงสร้างเชิงเหตุผลของแบบจำลองได้อย่างชัดเจน ซึ่งสนับสนุนความโปร่งใสและความน่าเชื่อถือในการใช้แบบจำลองเพื่อวัดรายได้ครัวเรือน

ข้อเสนอแนะจากการวิจัยนี้คือ การใช้แบบจำลอง Machine Learning ควบคู่กับการตีความผ่าน SHAP Regression ช่วยในการยกระดับประสิทธิภาพของวิธีการวัดรายได้ทางอ้อมอย่างมีนัยสำคัญ อย่างไรก็ตาม การนำไปใช้จริงควรพิจารณาถึงความพร้อมของระบบข้อมูลความสามารถของบุคลากรในการใช้งานแบบจำลองที่ซับซ้อน และความเป็นธรรมในการกำหนดเกณฑ์คัดกรองที่อาจมีผลกระทบต่อครัวเรือนชายขอบ

คำสำคัญ: Proxy Means Test, Machine Learning, LightGBM, SHAP Regression, การวัดรายได้ทางอ้อม, ความยากจน

Title	CREATING PROXY MEANS TEST BY USING MACHINE LEARNING TECHNIQUES
Author	Bhawin Teveyanun
Degree	Master of Economics
Major Field/Faculty/University	Economics Thammasat University
Advisor	Associate Professor Dr. Chaiyuth Punyasavatsut
Academic Year	2024

ABSTRACT

This study aims to develop a Proxy Means Test (PMT) model by applying Machine Learning techniques to improve the accuracy of identifying poor households targeted by government welfare policies. The analysis utilizes data from the 2023 Socio-Economic Survey (SES), which includes household- and individual-level information such as income, expenditure, housing conditions, assets, and social characteristics. The modeling process begins with a Baseline logistic regression model, which is then compared to Machine Learning models—Random Forest and LightGBM—under both income prediction and poverty status classification tasks. Model performance is evaluated using metrics such as Root Mean Squared Error (RMSE), Precision, Recall, F1-Score, and Inclusion/Exclusion Errors. Furthermore, the study applies class weighting and income cut-off techniques to enhance the model's focus on accurately classifying low-income populations, who are the true targets of social welfare interventions.

The study also incorporates SHAP values and SHAP regression to interpret the influence of individual variables on Machine Learning model predictions. This approach enables meaningful policy interpretation of model outputs and reveals the significance of explanatory variables in a transparent manner.

The results indicate that the LightGBM model developed in this study outperforms Baseline models in terms of error reduction and targeting efficiency,

particularly when applying income threshold adjustments. These enhancements lead to more accurate and reliable poverty classification. SHAP analysis further reveals the underlying structure of the model, supporting transparency and credibility in its use for household income assessment.

The study recommends that combining Machine Learning models with SHAP-based interpretability can significantly enhance the effectiveness of PMT methods. Nevertheless, practical implementation should consider data infrastructure readiness, the capacity of personnel to handle complex models, and fairness in screening criteria that may impact marginalized households.

Keywords: Proxy Means Test, Machine Learning, LightGBM, SHAP Regression, Poverty targeting



กิตติกรรมประกาศ

ข้าพเจ้าขอกราบขอบพระคุณ รองศาสตราจารย์ ดร.ชัยยุทธ ปัญญสวัสดิ์สุทธิ์ อาจารย์ที่ปรึกษาวิทยานิพนธ์ ซึ่งได้ให้คำแนะนำ อุทิศเวลา ตลอดจนความเอาใจใส่อย่างใกล้ชิด ในการทำวิจัยตลอดระยะเวลาของการศึกษา จนทำให้ข้าพเจ้าสามารถดำเนินงานวิทยานิพนธ์ฉบับนี้ แล้วเสร็จด้วยความเรียบร้อย

ข้าพเจ้าขอขอบพระคุณ รองศาสตราจารย์ ดร.ธนพงษ์ โพธิ์ปิติ อาจารย์ผู้ทรงคุณวุฒิ จากภายนอก และผู้ช่วยศาสตราจารย์ ดร.วศิน ศิวสฤกษ์ดี กรรมการสอบจากภายในสถาบัน ที่ได้ให้ข้อเสนอแนะที่มีคุณค่า อันก่อให้เกิดการพัฒนาทางวิชาการและความเข้าใจเชิงลึกในหัวข้อ การวิจัยอย่างยิ่ง

ข้าพเจ้าขอขอบคุณสำนักงานสถิติแห่งชาติ (National Statistical Office: NSO) เป็นอย่างยิ่ง ที่เอื้อเฟื้อข้อมูลจากการสำรวจภาวะเศรษฐกิจและสังคมของครัวเรือน (SES) ประจำปี พ.ศ. 2566 ซึ่งมีบทบาทสำคัญต่อการดำเนินการศึกษาและพัฒนาแบบจำลองในงานวิจัยฉบับนี้ ข้อมูลดังกล่าวมีคุณค่ายิ่งทั้งในเชิงวิชาการและเชิงนโยบาย อันเป็นพื้นฐานสำคัญที่ช่วยให้การวิเคราะห์มีความครบถ้วน สมบูรณ์ และสามารถนำไปประยุกต์ใช้เพื่อพัฒนาระบบการคัดกรอง กลุ่มเป้าหมายด้านสวัสดิการสังคมได้อย่างมีประสิทธิภาพ

ข้าพเจ้าขอขอบคุณ นายนันท์วัฒน์ พงษ์สรนันท์ เพื่อนร่วมคณะผู้มีน้ำใจและให้ความช่วยเหลือในการเรียนและการวิจัยอย่างเสมอมา รวมทั้งขอขอบคุณเป็นพิเศษแด่ นางสาวโสมสุภา ปาสวัสดิ์ ผู้ซึ่งเป็นแรงสนับสนุนที่สำคัญทั้งทางด้านจิตใจและการดำเนินชีวิตในทุกช่วงเวลา ตลอดระยะเวลาของการศึกษาและการทำวิทยานิพนธ์นี้

สุดท้ายนี้ ข้าพเจ้าขอขอบคุณทุกท่านที่มีส่วนเกี่ยวข้องและเป็นแรงผลักดันในการเรียนรู้ และเติบโตทางวิชาการของข้าพเจ้าในครั้งนี้

ภวินทร์ เตียนนันท

สารบัญ

	หน้า
บทคัดย่อภาษาไทย	(1)
บทคัดย่อภาษาอังกฤษ	(3)
กิตติกรรมประกาศ	(5)
สารบัญตาราง	(10)
สารบัญภาพ	(11)
บทที่ 1 บทนำและวัตถุประสงค์	1
1.1 ที่มาและความสำคัญ	1
1.2 วัตถุประสงค์ของการศึกษา	5
1.3 ขอบเขตของข้อมูลที่ใช้ในการศึกษา	6
1.4 ประโยชน์ที่ได้รับจากการศึกษา	6
บทที่ 2 วรรณกรรมและงานวิจัยที่เกี่ยวข้อง	
2.1 ทฤษฎีที่เกี่ยวข้อง	7
2.1.1 แบบจำลองการวัดรายได้ทางอ้อม	7
2.1.2 จุดอ่อนของแบบจำลองการวัดรายได้ทางอ้อม	10
2.1.3 การใช้เทคนิคอื่น ๆ มาช่วยในการสร้างแบบจำลองรายได้ทางอ้อม	11
2.2 งานวิจัยอื่น ๆ ที่เกี่ยวข้อง	14
2.2.1 เปรียบเทียบการใช้เทคนิค Machine Learning ต่าง ๆ	14
2.2.2 Shapley Regression และการตีความแบบจำลอง	17
2.3 สรุปการทบทวนวรรณกรรม	18

บทที่ 3 วิธีการศึกษา	20
3.1 ขั้นตอนในการศึกษา	20
3.2 แบบจำลองที่ใช้ในการศึกษา	21
3.2.1 แบบจำลอง Logistics Regression	22
3.2.1 แบบจำลอง Random Forest	23
3.2.2 แบบจำลอง LightGBM	26
3.2.4 การปรับปรุงกระบวนการพยากรณ์เพื่อรองรับปัญหาการกระจายตัวของรายได้และความไม่สมดุลของข้อมูล	28
3.2.4.1 การตัดช่วงรายได้เพื่อจำกัดความเหลื่อมล้ำในการฝึกแบบจำลอง	29
3.2.4.2 การถ่วงน้ำหนักเพื่อจัดการกับปัญหาความไม่สมดุลของข้อมูล	29
3.3 วิธีการวัดประสิทธิภาพของแต่ละแบบจำลอง	30
3.3.1 วิธีการวัดประสิทธิภาพของแบบจำลองสมการถดถอย	30
3.3.1.1 แบบจำลอง Random Forest	32
3.3.1.2 แบบจำลอง LightGBM	33
3.3.2 วิธีการวัดประสิทธิภาพของแบบจำลองจำแนกประเภท	33
3.3.3 วิธีการวัดประสิทธิภาพโดยรวมสำหรับทุกแบบจำลอง	35
3.4 วิธีการแปลผลการประมาณค่าของแบบจำลอง Machine Learning	37
3.4.1 วิธีการตรวจสอบการอนุมานทางสถิติผ่านการวิเคราะห์แบบ Shapley Regression	38
3.5 ข้อมูลที่ใช้ในการศึกษา	39
3.5.1 ข้อมูลส่วนภาคครัวเรือน	40
3.5.2 ข้อมูลส่วนบุคคล	41
3.5.3 ข้อมูลคุณลักษณะรายจังหวัด	41
บทที่ 4 ผลการวิจัยและการอภิปรายผล	43
4.1 สรุปข้อมูลวิเคราะห์ทางสถิติ	43
4.2 แบบจำลองแบบ Classification	45

4.2.1 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง	45
4.2.2 อภิปรายผลของแบบจำลอง LightGBM แบบ Classification	46
4.2.3 อภิปรายผลของแบบจำลอง LightGBM แบบ Classification ผ่าน ค่า SHAP	49
4.2.3.1 อภิปรายผลของของแต่ละตัวแปรผ่านค่า SHAP	49
4.2.3.2 ตัวอย่างของผลกระทบของแต่ละตัวแปรต่อการตัดสินใจของ แบบจำลอง	66
4.2.3.3 ค่าเฉลี่ยของผลกระทบของแต่ละตัวแปรต่อการตัดสินใจของ แบบจำลอง	68
4.2.4 สรุปผลของตัวแปรในแบบจำลองว่ามีนัยสำคัญทางสถิติหรือไม่	70
4.3 แบบจำลองแบบ Regression	71
4.3.1 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง	71
4.3.2 อภิปรายผลของแบบจำลอง LightGBM แบบ Regression	72
4.3.2.1 อภิปรายผลของแบบจำลอง LightGBM แบบ Regression ผ่านค่า SHAP	72
4.3.2.2 ค่าเฉลี่ยของผลกระทบของแต่ละตัวแปรต่อการตัดสินใจของ แบบจำลอง	76
4.3.3 สรุปผลของตัวแปรในแบบจำลองว่ามีนัยสำคัญทางสถิติหรือไม่	78
4.4 เปรียบเทียบแบบจำลองกับ Based-line Logistic Regression	79
4.5 สรุปผล	81
บทที่ 5 สรุปผลการวิจัยและข้อเสนอแนะ	83
5.1 ข้อเสนอแนะเชิงนโยบาย	83
5.1.1 การออกแบบมาตรการนโยบายต่าง ๆ ผ่านตัวแปรที่บ่งชี้ความ ยากจน	83
5.1.2 การใช้แบบจำลองเชิงทำนายเพื่อลดการรั่วไหลของงบประมาณ	84
5.1.3 ข้อเสนอแนะเชิงระบบฐานข้อมูล	84
5.2 ข้อเสนอแนะสำหรับงานวิจัยขั้นถัดไป	85
5.2.1 การนำข้อมูลแบบช่วงเวลา (Panel Data) มาใช้ในการวิเคราะห์ พลวัตของความยากจน	85

5.2.2 การใช้ Hybrid Technique เพื่อเพิ่มประสิทธิภาพของแบบจำลอง	85
5.2.3 การสร้างตัวแปรสังเคราะห์เพื่อเพิ่มประสิทธิภาพของแบบจำลอง	86
5.2.4 การจัดการกับตัวแปรที่มีความสัมพันธ์กันสูง (High Correlation)	86
5.2.5 การบูรณาการข้อมูลหลากหลายมิติเพื่อเพิ่มความครอบคลุมของตัวแบบ	86
รายการอ้างอิง	87



สารบัญตาราง

ตารางที่	หน้า
3.1 ความเชื่อมโยงของข้อผิดพลาดกับเมตริกการจำแนกและผลกระทบเชิงนโยบาย	37
4.1 สรุปค่าสถิติของตัวแปรค่าเฉลี่ยรายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคน	44
4.2 แสดงผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง Random Forest กับ LightGBM แบบ Classification	45
4.3 แสดงผลของ Shapley Regression เพื่อตรวจสอบนัยสำคัญทางสถิติของตัว แปรของแบบจำลอง LightGBM แบบ Classification	70
4.4 แสดงผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง Random Forest กับ LightGBM แบบ Regression	72
4.5 แสดงผลของ Shapley Regression เพื่อตรวจสอบนัยสำคัญทางสถิติของตัว แปรของแบบจำลอง LightGBM แบบ Regression	78
4.6 แสดงผลการเปรียบเทียบแบบจำลองกับ Based-line Logistic Regression	79
4.7 แสดงผลการเปรียบเทียบแบบจำลองที่ใช้พยากรณ์เฉพาะครัวเรือนที่รายได้ต่ำกว่า 8,000 บาทต่อครัวเรือนต่อเดือน	80

สารบัญภาพ

ภาพที่	หน้า
3.1 สรุปขั้นตอนกระบวนการในการศึกษา	20
3.2 แสดง Confusion Matrix	34
4.1 แสดงค่าการกระจาย histogram ของรายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคน	45
4.2 แสดงค่า confusion matrix ของแบบจำลอง LightGBM แบบ Classification	46
4.3 แสดงค่าสรุปผลของแบบจำลอง LightGBM แบบ Classification	47
4.4 แสดงการตัดสินใจของแบบจำลองผ่านค่า Precision และ Recall	48
4.5 แสดงค่า SHAP ของแบบจำลอง Classification ของ LightGBM โดยที่เลือกตัวแปรที่สำคัญ 20 อันดับแรก	49
4.6 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1)	53
4.7 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05)	53
4.8 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11)	54
4.9 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของค่าเช่าบ้านต่อเดือน (HH05)	55
4.10 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06)	55
4.11 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของอายุของหัวหน้าครัวเรือน (C02)	56
4.12 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนหลอดตะเกียบ (HH44)	57
4.13 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกในครัวเรือนรวม (A04)	57
4.14 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของเป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19)	58
4.15 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนหลอดไฟนีออน (HH42)	59

4.16 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของเป็นเจ้าของรถยนต์ไฮบริดหรือไม่ (HH17)	59
4.17 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05)	60
4.18 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนเครื่องปรับอากาศ (HH35)	61
4.19 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาร์ทโฟน (HH41)	61
4.20 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของเชื้อเพลิงที่ใช้ในการปรุงอาหาร (HH10)	62
4.21 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนหลอดไฟนีออน (HH45)	63
4.22 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้น (C24)	63
4.23 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10)	64
4.24 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนห้องที่อยู่อาศัยทั้งหมด (HH07)	65
4.25 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C25)	65
4.26 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจครัวเรือนนี้ไม่ใช่ครัวเรือนยากจน	67
4.27 แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจครัวเรือนนี้เป็นครัวเรือนยากจน	68
4.28 แสดงค่าเฉลี่ยผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจของแบบจำลอง LightGBM แบบ Classification	69
4.29 แสดงค่า SHAP ของแบบจำลอง Regression ของ LightGBM โดยที่เลือกค่าแปรที่สำคัญ 20 อันดับแรก	73
4.30 แสดงค่าเฉลี่ยผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจของแบบจำลอง LightGBM แบบ Regression	77

บทที่ 1

บทนำและวัตถุประสงค์

1.1 ที่มาและความสำคัญ

ความยากจนถือเป็นปัญหาหลักที่พบได้อย่างแพร่หลาย โดยเฉพาะอย่างยิ่งในประเทศกำลังพัฒนา เช่น ประเทศไทย ปัญหาความยากจนนั้นมิได้เป็นเพียงปัญหาเชิงโครงสร้างทางเศรษฐกิจเท่านั้น แต่ยังสะท้อนถึงความเหลื่อมล้ำทางสังคม ซึ่งอาจส่งผลกระทบทั้งในระยะสั้นและระยะยาวต่อระบบเศรษฐกิจโดยรวม ภาครัฐจึงจำเป็นต้องมีบทบาทในการเข้าแทรกแซงและบรรเทาปัญหาดังกล่าวผ่านเครื่องมือนโยบายต่าง ๆ อาทิ นโยบายการคลัง การเงิน และนโยบายทางสังคม โดยหนึ่งในเครื่องมือที่ได้รับความนิยมในการใช้เพื่อบรรเทาความยากจน ได้แก่ การอุดหนุนทางการเงินแบบมีเงื่อนไข (Conditional Cash Transfers: CCT) (World Bank, 2019)

แนวคิดของการให้เงินอุดหนุนแบบมีเงื่อนไขเกิดขึ้นจากความมุ่งหมายในการให้ความช่วยเหลือแก่ประชาชนผู้มีรายได้น้อย ทั้งในรูปแบบของเงินสดหรือสิ่งของจำเป็นต่อการดำรงชีวิต เช่น เสื้อผ้า อาหาร หรือยา (World Bank, 2019) ทั้งนี้ ผู้ที่จะได้รับสิทธิในความช่วยเหลือจำเป็นต้องปฏิบัติตามเงื่อนไขที่รัฐกำหนดก่อน อาทิ เช่น กรณีศึกษาของ Baird et al. (2014) ซึ่งรัฐบาลกำหนดให้นักเรียนจากครัวเรือนยากจนที่ต้องการรับเงินอุดหนุน จะต้องมิอัตราการเข้าเรียนไม่น้อยกว่าร้อยละ 80 ของช่วงภาคการศึกษา เพื่อเป็นการส่งเสริมให้เยาวชนในครัวเรือนยากจนได้รับการศึกษาอย่างต่อเนื่อง ทั้งนี้การให้เงินอุดหนุนภายใต้เงื่อนไขดังกล่าวส่งผลให้เกิดผลทางเศรษฐศาสตร์สองประการ คือ การเพิ่มแรงจูงใจด้านรายได้ (Income Effect) และการลดต้นทุนค่าเสียโอกาสในการเข้าเรียน (Substitution Effect) ซึ่งก่อให้เกิดแรงจูงใจในการเปลี่ยนพฤติกรรมของผู้รับอุดหนุนในทางที่สอดคล้องกับวัตถุประสงค์ของนโยบาย (ชัยยุทธและคณะ, 2562)

การคัดกรองผู้มีสิทธิได้รับความช่วยเหลือนับเป็นประเด็นสำคัญที่ส่งผลต่อประสิทธิภาพของนโยบายอย่างมีนัยสำคัญ โดยเฉพาะในด้านการลดข้อผิดพลาดจากการคัดกรองผิดพลาด ไม่ว่าจะเป็นการตัดสิทธิ์ผู้ที่ควรได้รับการช่วยเหลือ (Exclusion Error) หรือการให้สิทธิแก่ผู้ที่ไม่สมควรได้รับ (Inclusion Error) เครื่องมือที่ได้รับความนิยมอย่างแพร่หลายในการคัดกรองผู้มีรายได้น้อย คือ วิธีการวัดรายได้ทางอ้อม หรือ Proxy Means Test (PMT) ซึ่งเป็นเทคนิคเชิงสถิติที่ใช้ตัวชี้วัดอื่นแทนรายได้โดยตรง ซึ่งเหมาะสมกับบริบทที่ข้อมูลรายได้มักไม่มีความน่าเชื่อถือหรือยากแก่การตรวจสอบ (ชัยยุทธและคณะ, 2562)

คุณลักษณะของตัวแปรที่นำมาใช้ในแบบจำลอง PMT ควรเป็นตัวแปรที่สามารถสังเกต ตรวจสอบ และประเมินได้ง่าย เช่น ประเภททรัพย์สินของครัวเรือน ลักษณะที่อยู่อาศัย วัสดุที่ใช้ในการก่อสร้าง การเข้าถึงสาธารณูปโภคขั้นพื้นฐาน ตลอดจนระดับการบริโภคในครัวเรือน

จากงานศึกษาเพิ่มประสิทธิภาพหลักเกณฑ์คัดกรองความยากจนด้วยวิธีการวัดรายได้ทางอ้อมของชัยยุทธและคณะ (2565) โดยวิธีการสร้างแบบจำลองการวัดรายได้ทางอ้อมพบข้อจำกัดหลากหลายประการ อาทิเช่น ขั้นตอนการเลือกตัวแปรที่มีข้อจำกัดต้องเลือกผ่านตัวแปรที่สามารถชี้วัดรายได้ได้จากตัวแปรหลายร้อยตัว ไม่มีมุมมองของการพัฒนาตัวแปรที่ใช้ในการศึกษาหรือเทคนิคที่เรียกว่า Feature Engineering และ ตัวแปรที่เลือกยังต้องคำนึงถึงปัญหามภาวะร่วมเส้นตรงเชิงพหุ (Multicollinearity)

ปัจจุบันมีการประยุกต์ใช้เทคนิคที่มีการใช้การประมวลผลทางคอมพิวเตอร์ที่มีประสิทธิภาพมากยิ่งขึ้นผ่านการใช้เทคนิคที่เรียกว่า Machine Learning โดย Machine Learning คือ กลไกการเขียน Algorithm โดยการนำ Algorithm นั้น ไปเรียนรู้ชุดข้อมูลต้นแบบ (Training Set) เพื่อให้ได้ออกมาเป็น Function (ที่เป็น Black-box หรือรูปแบบสมการต่าง ๆ) จากนั้นจะมีการนำ Function ดังกล่าวไปใช้งานโดยมีชุดข้อมูลทดสอบ (Testing Set) เข้ามาประมวลผลผ่าน Function เพื่อให้ได้ออกมาเป็นผลลัพธ์ที่พร้อมนำไปใช้งาน แบ่งออกเป็น Supervised (จำเป็นต้องกำหนดตัวแบบให้กับแบบจำลอง) กับ Unsupervised learning (ไม่จำเป็นต้องกำหนดตัวแบบให้กับแบบจำลอง)

ในปัจจุบันการนำเทคนิค Machine Learning มาใช้ในงานศึกษาทางด้านเศรษฐศาสตร์มากขึ้นไม่ว่าจะเป็นงานศึกษาของ Athley (2018) พบว่าการใช้ประยุกต์ใช้เทคนิค Machine Learning กับการสร้างแบบจำลองในงานศึกษาทางด้านเศรษฐศาสตร์สามารถปรับปรุงคุณภาพของแบบจำลอง ให้ได้แบบจำลองที่มีความ Robust และมีความเสถียรมากกว่า รวมทั้งสามารถแก้ไขปัญหาต่าง ๆ ของแบบจำลองได้มากขึ้น และสามารถทำให้แบบจำลองสามารถเพิ่มประสิทธิภาพของตัวเองได้ไม่จำเป็นต้องคำนวณหาค่าพารามิเตอร์โดยใช้นักเศรษฐศาสตร์แบบดั้งเดิมตลอดเวลา

งานศึกษาของ Desai (2023) ชี้ให้เห็นว่าแบบจำลอง Machine Learning เช่น Tree-based Models, Neural Networks และ Regularized Linear Models สามารถเพิ่มความแม่นยำในการคาดการณ์ได้อย่างมีนัยสำคัญ ทั้งนี้ การเลือกใช้เทคนิค Machine Learning ควรพิจารณาความเหมาะสมของข้อมูล จุดมุ่งหมายของงานวิจัย ตลอดจนการออกแบบกระบวนการวิเคราะห์ที่ครอบคลุมทั้งการปรับแต่งแบบจำลอง การประเมินผลด้วย Baseline และการตีความผลลัพธ์ผ่านเครื่องมืออธิบายแบบจำลอง เพื่อให้ได้ผลลัพธ์ที่เชื่อถือได้และนำไปใช้ในการกำหนดนโยบายได้อย่างมีประสิทธิภาพ

การใช้เทคนิคทาง Machine Learning ที่มีความซับซ้อนอย่างเทคนิค Deep Learning สามารถใช้ประโยชน์กับงานด้านทางเศรษฐศาสตร์ได้ จากงานของ Dell (2024) ที่ใช้เทคนิค Deep Learning กับงานทางด้านเศรษฐศาสตร์ พบว่าสามารถแก้ไขปัญหาต่าง ๆ ทางด้านเศรษฐศาสตร์ได้ดีโดยเฉพาะกับปัญหาที่มีฐานข้อมูลขนาดใหญ่ เช่น ข้อมูลจำนวนกลุ่มตัวอย่างหลายล้านตัวอย่าง หรือเป็นพันล้านตัวอย่าง จะเห็นได้ว่าการประยุกต์ใช้เทคนิค Machine Learning กับงานทางด้านเศรษฐศาสตร์สามารถสร้างประโยชน์ให้กับการศึกษาต่าง ๆ ได้เป็นอย่างมาก

งานศึกษาการสร้างแบบจำลองการวัดรายได้ทางอ้อมมีการประยุกต์ใช้เทคนิค Machine Learning เพื่อเพิ่มประสิทธิภาพแบบจำลอง ไม่ว่าจะเป็นงานศึกษาในอดีตของประเทศไทยของ Kambuya (2017) ที่ทำการศึกษารูปแบบจำลองการวัดรายได้ทางอ้อมผ่านเทคนิค Machine Learning พบว่าผลของการนำเทคนิคดังกล่าวมาใช้สามารถทำให้แบบจำลองการวัดรายได้ทางอ้อมมีประสิทธิภาพและความแม่นยำเพิ่มมากขึ้น แต่งานศึกษาดังกล่าวมีจุดอ่อนสองประการคือ ไม่สามารถอธิบายผลกระทบของแต่ละตัวแปรได้เนื่องจากแบบจำลอง Machine Learning มีลักษณะที่เป็น Black-box ทำให้ไม่สามารถอธิบายผลของตัวแปรแบบตรงไปตรงมาได้เหมือนสมการถดถอยเชิงเส้น (Regression) แบบปกติ และเทคนิค Machine Learning ที่ใช้ยังเป็นเทคนิคที่ยังไม่ซับซ้อนมากทำให้ไม่ได้เพิ่มประสิทธิภาพมากกว่าวิธีแบบดั้งเดิมมาก

ในโครงการ Benazir Income Support Programme (BISP) ประเทศปากีสถานได้ใช้แบบสอบถาม PMT ร่วมกับการวิเคราะห์เชิงสถิติเพื่อกำหนดกลุ่มเป้าหมาย โดยมีการทดลองใช้แบบจำลอง Random Forest และ Gradient Boosting เพื่อประเมินรายได้ครัวเรือนและเปรียบเทียบกับวิธีการ PMT ดั้งเดิม ผลลัพธ์พบว่า Machine Learning มีความแม่นยำมากกว่าโดยสามารถลด Exclusion Error ได้ถึง 30% ในบางภูมิภาค (World Bank, 2019)

รัฐบาลฟิลิปปินส์ได้นำระบบ Listahanan มาใช้ร่วมกับ PMT ในการจัดทำฐานข้อมูลครัวเรือนยากจนทั่วประเทศ โดยใช้เทคนิค Logistic Regression อย่างไรก็ตามการศึกษาโดย UNICEF (2021) ได้เสนอให้ปรับปรุงวิธีโดยใช้ Machine Learning แทนการถดถอยแบบเส้นตรง โดยอ้างอิงจากประสิทธิภาพที่เพิ่มขึ้นในความแม่นยำและความสามารถในการจัดการกับข้อมูลที่มีลักษณะไม่เชิงเส้น

โครงการ Cadastro Único ของประเทศบราซิลซึ่งเป็นฐานข้อมูลระดับชาติที่ใช้สำหรับโครงการสวัสดิการ เช่น Bolsa Família รัฐบาลได้ใช้ข้อมูล PMT ผสมกับระบบ GIS และข้อมูลเชิงพื้นที่เพื่อระบุครัวเรือนที่มีความเสี่ยงสูง โดยมีการทดลองใช้เทคนิค XGBoost เพื่อประเมินโอกาสที่ครัวเรือนจะตกอยู่ในภาวะยากจน ผลลัพธ์พบว่า สามารถลดค่า False Negative ได้อย่างมีนัยสำคัญ (Carvalho et al., 2022)

งานศึกษาของ Wobcke และ Mariyah (2023) เสนอแนวทางใหม่ในการประยุกต์ใช้เทคนิค Machine Learning ร่วมกับการเพิ่มข้อมูล (Data Augmentation) เพื่อยกระดับความแม่นยำของ PMT ในการระบุครัวเรือนยากจนในอินโดนีเซีย โดยใช้ข้อมูลจากสามจังหวัดและเน้นการลดข้อผิดพลาดทั้งการรวม (Inclusion Error) และการยกเว้น (Exclusion Error) การศึกษานี้เปรียบเทียบประสิทธิภาพของแบบจำลองเชิงสถิติกับ Machine Learning ได้แก่ Ridge Regression, Logistic Regression และ XGBoost โดยใช้ Logistic Regression เป็น Baseline ในการจำแนกครัวเรือนที่อยู่ในกลุ่มยากจนที่สุด 40% จากคุณลักษณะระดับครัวเรือน เช่น ขนาดครัวเรือน การศึกษา การจ้างงาน และที่อยู่อาศัย รวมถึงคุณลักษณะระดับพื้นที่ และข้อมูลที่เสริมในพื้นที่ขนาดเล็ก เช่น ระดับตำบล ผลการศึกษาพบว่าเทคนิค Machine Learning สามารถลด Inclusion Error และ Exclusion Error ได้ดีกว่า Logistic Regression อย่างมีนัยสำคัญ อย่างไรก็ตามตามงานศึกษาของ Wobcke และ Mariyah (2023) ยังไม่ได้ทำการเปรียบเทียบเทคนิคแบบสมการถดถอย และแบบจำลองการจำแนกกว่าเทคนิคแบบใดจะสามารถจำแนกครัวเรือนยากจนได้มีประสิทธิภาพมากกว่า รวมทั้งไม่มีการอธิบายผลกระทบทิศทางของตัวแปรที่ใช้

แบบจำลองที่ใช้ในสร้างแบบจำลองการวัดรายได้ทางอ้อมในงานศึกษารั้งนี้จะใช้แบบจำลองสองแบบประกอบไปด้วยแบบจำลองแบบสมการถดถอย (Regression) และแบบจำลองการจำแนก (Classification) ในลักษณะของ Binary โดยคำตอบมี 2 คำตอบ คือเป็นการทำนายสิ่งที่ใกล้เคียงกับข้อมูลที่ป้อน ว่าการจำแนกกลุ่มของครัวเรือนเป็น “ครัวเรือนยากจน” และ “ครัวเรือนรายได้สูง” โดยแบบจำลองทั้งสองประเภทจะใช้สองเทคนิคหลักคือ Random Forest ซึ่งใช้เทคนิคแบบ Bagging คือมีการสร้างค่าเฉลี่ยของแบบจำลองต้นไม้ (Decision Tree) หลายแบบจำลองที่แบบจำลองต้นไม้เหล่านั้นไม่มีความสัมพันธ์ซึ่งกันเพื่อช่วยให้ประสิทธิภาพของแบบจำลองมีประสิทธิภาพสูงขึ้นจากลดความแปรปรวนของแบบจำลอง โดยไม่เพิ่มค่า Bias หรือความอคติของแบบจำลอง ทำให้ช่วยแก้ปัญหา Overfitting ของข้อมูลได้ และ LightGBM เป็นเทคนิคการทำ Gradient Boosting ที่นำเอาแบบจำลองแบบต้นไม้มาผ่านกระบวนการเรียนรู้หลาย ๆ แบบจำลอง แต่ละแบบจำลองต้นไม้จะเรียนรู้จากข้อผิดพลาดหรือ Error ของแบบจำลองต้นไม้ก่อนหน้าทำให้ภาพรวมการทำงานของ Boosting จะเหมือนการทำงานในลักษณะช่วยกันทำงานโดยการเอา Classifier ที่มีประสิทธิภาพต่ำมารวมกันจนทำนายข้อมูลที่ซับซ้อนมาก ๆ ได้ ทำให้จะช่วยแก้ปัญหาความแม่นยำต่ำ (Bias) ได้ และงานศึกษาชิ้นนี้ จะใช้แบบจำลอง Logistics Regression เป็นตัวแบบ Based-line สำหรับการเปรียบเทียบกับแบบจำลองอื่น ๆ

นอกจากการใช้เทคนิค Machine Learning แล้วงานศึกษาชิ้นนี้เพิ่มข้อมูลที่ใช้ในแบบจำลองที่นอกเหนือจากงานศึกษาอื่น ๆ เพื่อเพิ่มประสิทธิภาพของเทคนิคการใช้ Machine Learning ข้อมูลที่ใช้งานจะประกอบไปด้วยสามส่วนคือ ส่วนแรกข้อมูล

การสำรวจสถานะเศรษฐกิจสังคมของครัวเรือน (SES) ปี พ.ศ. 2566 ส่วนรายครัวเรือนทั้งข้อมูลรายได้ (ใช้สำหรับคัดแยกครัวเรือนยากจนกับครัวเรือนที่ไม่ใช่เพื่อให้แบบจำลอง Machine Learning ใช้ในการเรียนรู้) ข้อมูลลักษณะของครัวเรือน ข้อมูลลักษณะของที่อยู่อาศัย ข้อมูลการถือครองทรัพย์สินต่าง ๆ ของครัวเรือน และข้อมูลรายจ่ายประเภทต่าง ๆ ส่วนที่สองคือข้อมูลการสำรวจสถานะเศรษฐกิจสังคมของครัวเรือน (SES) ปี พ.ศ. 2566 รายบุคคล เพื่อใช้สำหรับสร้างตัวแปรลักษณะของครัวเรือน และส่วนสุดท้ายคือข้อมูลคุณลักษณะของจังหวัดต่าง ๆ ประกอบไปด้วยข้อมูลผลิตภัณฑ์มวลรวมจังหวัด (Gross provincial product : GPP) ข้อมูลจำนวนประชากรรายจังหวัด และข้อมูลลักษณะอุตสาหกรรมรายจังหวัด

วิทยานิพนธ์ฉบับนี้มีเป้าหมายที่จะพัฒนาการเลือกตัวแปรที่จะใช้สำหรับการสร้างแบบจำลองการวัดรายได้ทางอ้อมให้มีประสิทธิภาพและประสิทธิผลมากขึ้นผ่านการใช้เทคนิค Machine Learning โดยเพิ่มจำนวนตัวแปรในหลากหลายมิติเข้าไปในแบบจำลอง เพื่อให้แบบจำลองคัดกรองตัวแปรที่มีประสิทธิภาพมากที่สุด รวมทั้งเปรียบเทียบแบบจำลองหลากหลายรูปแบบตั้งแต่แบบจำลองที่มีความซับซ้อนต่ำไปจนถึงที่มีความซับซ้อนมากที่สุด ศึกษาผลกระทบและทิศทางของแต่ละตัวแปรผ่านการวิเคราะห์จากการคำนวณค่า Shapley Values (ตามแบบจำลองของทฤษฎีเกม) แปลผลของแบบจำลองที่มีลักษณะเป็น Black-box โดยคาดหวังว่าจะสามารถสร้างระบบการคัดกรองที่ชัดเจนและมีประสิทธิภาพสูงขึ้นผ่านการเลือกตัวแปรที่ส่งผลต่อครัวเรือนยากจนอย่างเดี่ยวได้ชัดเจน

1.2 วัตถุประสงค์ของการศึกษา

- 1) เพื่อพัฒนาแบบจำลองการวัดรายได้ทางอ้อมโดยอาศัยเทคนิค Machine Learning เพื่อเพิ่มประสิทธิภาพการประมาณค่าที่วัดจากค่าอัตราการพลาดโอกาส (Exclusion Error) และอัตราการรั่วไหล (Inclusion Error)
- 2) ศึกษาเปรียบเทียบการสร้างแบบจำลองการวัดรายได้ทางอ้อมผ่านแบบจำลอง Regression (ทำนายรายได้โดยตรง) และแบบจำลองที่เป็น Binary Classification (ทำนายว่าเป็นครัวเรือนยากจนหรือไม่ยากจน)
- 3) ศึกษาผลกระทบของแต่ละตัวแปรต่อตัวแบบจำลองผ่านการวิเคราะห์ผ่านค่า Shapley Values

1.3 ขอบเขตของข้อมูลที่ใช้

1) ข้อมูลการสำรวจสถานะเศรษฐกิจสังคมของครัวเรือน (SES) ปี พ.ศ. 2566 โดยใช้ข้อมูลประกอบไปด้วยข้อมูลรายได้ (ใช้สำหรับคัดแยกครัวเรือนยากจนกับครัวเรือนที่ไม่ใช่เพื่อให้แบบจำลอง Machine Learning ใช้ในการเรียนรู้) ข้อมูลลักษณะของครัวเรือน ข้อมูลลักษณะของที่อยู่อาศัย ข้อมูลการถือครองทรัพย์สินต่าง ๆ ของครัวเรือน และข้อมูลรายจ่ายประเภทต่าง ๆ

2) ข้อมูลการสำรวจสถานะเศรษฐกิจสังคมของครัวเรือน (SES) ปี พ.ศ. 2566 รายบุคคลเพื่อใช้สำหรับสร้างตัวแปรลักษณะของครัวเรือน

3) ข้อมูลคุณลักษณะของจังหวัดต่าง ๆ อาทิเช่น ข้อมูลผลิตภัณฑ์มวลรวมจังหวัด (Gross provincial product: GPP) ข้อมูลจำนวนประชากรรายจังหวัด ข้อมูลลักษณะอุตสาหกรรมรายจังหวัด เป็นต้น

1.4 ประโยชน์ที่ได้รับจากการศึกษา

1) นำผลของการเลือกตัวแปรที่สะท้อนถึงครัวเรือนยากจนที่แม่นยำขึ้นไปสร้างข้อเสนอแนะเชิงนโยบายที่มีประสิทธิภาพมากยิ่งขึ้น

2) ได้มีมุมมองเรื่องการคัดกรองครัวเรือนยากจนที่หลากหลายมากขึ้นจากจำนวนตัวแปรที่ศึกษาจำนวนมาก

3) สามารถสร้างแบบจำลองที่สามารถปรับปรุงตัวแบบจำลองเองได้เพื่อให้แบบจำลองมีความแม่นยำในการคัดกรองที่ดีที่สุดในแต่ละช่วงเวลาโดยไม่จำเป็นต้องสร้างแบบจำลองใหม่ทั้งหมด

บทที่ 2

วรรณกรรมและงานวิจัยที่เกี่ยวข้อง

บทนี้เป็นการทบทวนวรรณกรรมและงานวิจัยที่เกี่ยวข้องมีส่วนหลักประกอบไปด้วย ทฤษฎีที่เกี่ยวข้องทั้งแบบจำลองการวัดรายได้ทางอ้อม การใช้เทคนิคอื่น ๆ กับการสร้างแบบจำลอง การวัดรายได้ทางอ้อม การใช้เทคนิค Machine Learning และการตีความแบบจำลอง Machine Learning

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 แบบจำลองการวัดรายได้ทางอ้อม (PMT)

Proxy Means Test เป็นเทคนิคทางสถิติที่ใช้ในการระบุครัวเรือนยากจน โดยพิจารณาจากตัวชี้วัดอื่นๆ นอกเหนือจากรายได้ที่มีความสัมพันธ์กับระดับความยากจนของครัวเรือน แทนที่จะสอบถามรายได้โดยตรง (GROSH ET AL., 2008; KIDD & WYLDE, 2011) วิธีการนี้มีข้อดีคือ ตัวชี้วัดที่นำมาใช้ในการประเมินต้องวัดและตรวจสอบได้ง่าย มีความน่าเชื่อถือ และยากต่อการปกปิดข้อมูลจริง ซึ่งเป็นปัญหาหากใช้การสอบถามรายได้โดยตรง วิธี PMT จึงเป็นทางเลือกที่มีประสิทธิภาพในการระบุครัวเรือนยากจน และได้รับการนำมาใช้อย่างแพร่หลายในหลายประเทศ วิธี PMT ช่วยให้สามารถระบุครัวเรือนยากจนได้อย่างมีประสิทธิภาพ และเป็นเครื่องมือสำคัญในการกำหนดนโยบายและมาตรการช่วยเหลือครัวเรือนที่มีฐานะทางเศรษฐกิจและสังคมยากจน

การประเมินครัวเรือนยากจนโดยใช้วิธีการ Proxy Means Test เป็นกระบวนการทางสถิติที่ขึ้นอยู่กับข้อมูลที่มีการจัดเก็บไว้เป็นหลัก รายละเอียดของการวิเคราะห์จึงแตกต่างกันไปตามลักษณะของแหล่งข้อมูล ความครอบคลุม คุณภาพของการสำรวจ และความสม่ำเสมอในการเก็บข้อมูล การสำรวจรายได้ส่วนใหญ่มักจะดำเนินการในระดับครัวเรือน เช่น การสำรวจสภาพเศรษฐกิจและสังคมของครัวเรือนในประเทศไทยซึ่งสามารถนำมาพัฒนาเป็นแผนที่ความยากจน หรือการสำรวจกลุ่มต่าง ๆ เช่น เด็กและเยาวชน ในปัจจุบัน ประเทศไทยมีการนำ PMT มาใช้ในการคัดกรองครัวเรือนยากจน โดยหน่วยงานต่าง ๆ เช่น กระทรวงการพัฒนาสังคมและความมั่นคงของมนุษย์ กองทุนเพื่อความเสมอภาคทางการศึกษา (กสศ.) และสำนักงานคณะกรรมการการศึกษาขั้นพื้นฐาน ซึ่ง PMT ได้ถูกนำไปประยุกต์ใช้ในการพัฒนาระบบสวัสดิการแห่งรัฐ โครงการช่วยเหลือผู้มีรายได้น้อย และการบริหารจัดการโครงการพัฒนาต่าง ๆ

การใช้วิธี Proxy Means Test แทนการวัดรายได้โดยตรงสามารถแก้ไขข้อจำกัดจากการสอบถามรายได้โดยตรงได้หลายประการไม่ว่าจะเป็น ความยากในการรวบรวมข้อมูลที่แม่นยำ โดยเฉพาะในกรณีของครัวเรือนยากจนที่มักมีรายได้ไม่แน่นอน ไม่สม่ำเสมอ หรือมาจากแหล่งที่ไม่เป็นทางการ ซึ่งทำให้ผู้ตอบยากที่จะให้ข้อมูลที่ตรงกับความเป็นจริง การใช้ PMT จึงเป็นทางเลือกที่น่าสนใจ โดยใช้ข้อมูลด้านอื่น ๆ ของครัวเรือนที่สะท้อนสถานะทางเศรษฐกิจ-สังคม เช่น ทรัพย์สินที่พำนักอาศัย และการเข้าถึงสาธารณูปโภคพื้นฐาน ซึ่งสามารถตรวจสอบได้ง่ายและน่าเชื่อถือมากกว่า นอกจากนี้การใช้ค่าใช้จ่ายเป็นตัวแทนของรายได้ก็เป็นอีกแนวทางหนึ่งที่ใช้ในการประเมินความยากจนของครัวเรือนแทนการใช้รายได้โดยตรง เนื่องจากข้อมูลค่าใช้จ่ายมักจะมีค่าน่าเชื่อถือและสะท้อนความเป็นจริงได้ดีกว่า

ตัวชี้วัดที่เหมาะสมสำหรับการใช้ในการวิเคราะห์ด้วยวิธี PMT ควรเป็นตัวแปรที่สามารถเก็บรวบรวมหรือสำรวจได้อย่างสะดวก เช่น อายุของหัวหน้าครัวเรือน ขนาดของครัวเรือน ระดับการศึกษา จำนวนเด็กนักเรียน สภาพที่พำนักอาศัย จำนวนสินค้าคงทน และทรัพย์สินในครัวเรือน ตัวแปรเหล่านี้ถูกนำมาประมวลผลทางสถิติ เพื่อจัดทำดัชนีชี้วัดระดับความยากจนที่สะท้อนสถานะรายได้หรือความยากจนของครัวเรือน การใช้ตัวแปรแทนรายได้หลายตัวนั้น ช่วยให้การประเมินระดับรายได้มีความแม่นยำมากขึ้น โดยปกติจะใช้ตัวแปรแทนรายได้ตั้งแต่ 10 ถึง 30 ตัวแล้วแตงานวิจัย ซึ่งแต่ละตัวแปรจะมีความสามารถในการสะท้อนรายได้หรือรายจ่ายที่แตกต่างกัน เมื่อได้ตัวแปรแทนรายได้ที่กำหนด และกำหนดค่าน้ำหนักของตัวแปรเหล่านั้น ผู้สำรวจสภาพครัวเรือนสามารถคำนวณคะแนนความยากจนรวมสำหรับแต่ละครัวเรือนได้ ครัวเรือนที่ได้คะแนนต่ำกว่าเกณฑ์ที่กำหนด ถือว่าผ่านการคัดกรอง (มีรายได้หรือระดับรายจ่ายเพื่อการบริโภคต่ำกว่าเกณฑ์ขั้นต่ำที่กำหนด) เป็นครัวเรือนยากจนที่สมควรได้รับการช่วยเหลือจากรัฐ (Grosh et al., 2024)

งานศึกษาในต่างประเทศที่มีชื่อเสียง คือ ดัชนีความน่าจะเป็นที่จะยากจน (Poverty Probability Index: PPI) โดย Schreiner (2006 – 2017) ซึ่งถูกสร้างขึ้นเพื่อใช้ในการคัดกรองคนยากจนในกว่า 60 ประเทศทั่วโลก เช่น ประเทศ ฮอนดูรัส นิการากัว โบลิเวีย เปรู เวียดนาม กานา เม็กซิโก กัวเตมาลา ฟิลิปปินส์ ปากีสถาน บังกลาเทศอินเดีย เอกวาดอร์ โคลัมเบีย ยูกันดา เคนยา จีน เนปาล ปารากวัย กัมพูชา เป็นต้น โดยใช้คะแนนความยากจน (Poverty Scorecard) ในแต่ละประเทศ ถูกสร้างขึ้น ผ่านการใช้วิธีการทางสถิติในการประมาณค่าแบบโลจิสติก (Logistic Regression) และมีการจำกัดตัวแปรที่ใช้เป็นตัวชี้วัดความยากจนเพียงแค่ 10 ตัวแปร เพื่อความสะดวกและลดต้นทุนในการเก็บข้อมูล ตัวแปรที่นำมาใช้มีความแตกต่างกันในแต่ละประเทศ ขึ้นอยู่กับว่าตัวแปรใดมีความสัมพันธ์กับความยากจนในแต่ละประเทศ แต่ละประเทศจะมีชุดของค่าน้ำหนักของคะแนนความยากจนที่ไม่เท่ากัน กลุ่มตัวแปรดัชนีที่ใช้ชี้วัดความยากจนที่มีความสำคัญประกอบไปด้วย จำนวนสมาชิกในครัวเรือน สินทรัพย์คงทนที่ครัวเรือนถือครอง

อาชีพของสมาชิกในครัวเรือน และ สภาพที่อยู่อาศัย โดยวิธีการของ Schreiner (2006 – 2017) มีกระบวนการในการคัดเลือกตัวแปรชี้วัดความยากจนผ่านวิธี Forward Stepwise Logistic Regression คือ มีกระบวนการเพิ่มตัวแปรชี้วัดความยากจนเพื่อได้ 10 ตัวแปรที่อธิบายถึงความยากจนในแบบจำลองได้ดีที่สุด แล้วจึงทำการแปลงค่าพารามิเตอร์ที่ได้มาเป็นคะแนนที่ใช้ในการวัดความยากจน โดยมีค่าตั้งแต่ 0 ถึง 100 เรียงลำดับจากยากจนมาก คือมีค่าคะแนนเท่ากับ 0 ไปจนถึงไม่ยากจนเลยมีค่าคะแนนเท่ากับ 100

สำหรับการคัดกรองคนยากจนด้วยวิธีการวัดรายได้ทางอ้อมในประเทศไทย ชัยยุทธและคณะ (2560) ได้ทำการสร้างคะแนนความยากจนโดยอาศัยหลักการของ PMT ขึ้น เพื่อใช้ในการคัดกรองนักเรียนยากจนใน 10 จังหวัดของประเทศไทย ได้แก่ จังหวัดเชียงราย แม่ฮ่องสอน กาญจนบุรี จันทบุรี ตรัง นครปฐม นครราชสีมา น่าน ภูเก็ต และอุดรธานี โดยอาศัยหลักเกณฑ์เดียวกับโครงการเงินอุดหนุนเพื่อการเลี้ยงดูเด็กแรกเกิด ของกระทรวงการพัฒนาสังคมและความมั่นคงของมนุษย์ (พม.) ประกอบไปด้วยเงื่อนไข 2 เกณฑ์ ได้แก่ เกณฑ์ทางด้านรายได้ ครัวเรือนที่มีรายได้ไม่เกิน 3,000 บาทต่อเดือน และเกณฑ์ทางด้านสถานะครัวเรือน ซึ่งเงื่อนไขเกณฑ์ทางด้านสถานะครัวเรือนดังกล่าว ถูกนำมาใช้ในการสร้างคะแนนความยากจนด้วยวิธี PMT เพื่อใช้ในการคัดกรองนักเรียนยากจน โดยใช้วิธีการประมาณค่าแบบกำลังสองน้อยที่สุด (Least Squares Regression) เพื่อหาความสัมพันธ์ระหว่างรายได้ครัวเรือนเฉลี่ยต่อหัวต่อเดือน และทางด้านสถานะทางด้านครัวเรือน โดยมีการใช้ตัวแปรหุ่น (Dummy Variables) ของจังหวัด เพื่อควบคุมความแตกต่างระหว่างจังหวัดรวมอยู่ในแบบจำลองด้วย ผลการประมาณค่า พบว่า สถานะทางครัวเรือนที่ไม่มียานพาหนะมีผลต่อความยากจนสูงที่สุด ตามด้วยสภาพที่อยู่อาศัยชำรุดทรุดโทรม ครัวเรือนมีภาระพึ่งพิง และครัวเรือนเป็นเกษตรกรที่ไม่มีที่ดินทำกิน หรือไม่เกิน 1 ไร่ อย่างไรก็ตาม คะแนนความยากจนจากการใช้วิธี PMT ในงานศึกษาครั้งนี้ ไม่ได้มีการแยกย่อยคะแนนลงไปในเกณฑ์แต่ละหัวข้อ ครัวเรือนที่มีภาระพึ่งพิงโดยมีทั้งคนพิการและผู้สูงอายุเมื่อเปรียบเทียบกับครัวเรือนซึ่งมีภาระพึ่งพิงโดยมีเพียงคนพิการจะมีคะแนนความยากจนที่เท่ากัน หรือครัวเรือนที่อยู่บ้านเช่ากับครัวเรือนที่อยู่บ้านที่ทำจากวัสดุพื้นบ้านจะมีคะแนนความยากจนที่เท่ากัน

ชัยยุทธและคณะ (2565) ได้พัฒนาแบบจำลองการวัดรายได้ทางอ้อม (Proxy Means Test: PMT) เพื่อใช้ในการคัดกรองนักเรียนยากจนในสถานศึกษาภายใต้ 6 สังเกต ได้แก่ สพฐ., อบท., ดชด., พศ., สช. และ กทม. ครอบคลุมนักเรียนกว่า 1.8 ล้านคนทั่วประเทศ โดยใช้ข้อมูลจากแบบสอบถาม นร./กสศ.01 ที่บันทึกรายละเอียดลักษณะครัวเรือน แบบจำลองที่นำมาใช้เป็นแบบจำลองเชิงเส้น (Linear Regression) โดยอาศัยเทคนิคการคัดเลือกตัวแปรแบบ Backward Stepwise และมีการใช้ตัวแปรหุ่น (Dummy Variables) ของจังหวัดเพื่อควบคุมค่าครองชีพในแต่ละพื้นที่ พร้อมกับปรับค่ารายได้ที่รายงานให้สะท้อนความแตกต่างของค่าครองชีพรายจังหวัด

โดยใช้ดัชนีเส้นความยากจน (ร้อยละ 80) และดัชนีรายได้ของนักเรียนยากจน ณ เปอร์เซ็นไทล์ที่ 25 (ร้อยละ 20)

กระบวนการสร้างแบบจำลอง PMT ดำเนินการผ่านการแบ่งข้อมูลออกเป็นชุดฝึกหัด (ร้อยละ 70) และชุดทดสอบ (ร้อยละ 30) เพื่อประเมินผลการประมาณค่ารายได้ทางอ้อม โดยใช้เกณฑ์ Root Mean Square Error (RMSE) เป็นตัวชี้วัดความแม่นยำของแบบจำลอง พบว่าแบบจำลองซึ่งมีการปรับค่าครองชีพแล้ว มีค่าคลาดเคลื่อนต่ำสุด (RMSE = 727.56 บาท/คน/เดือน) คะแนนความยากจนที่ได้จากการประมาณค่ารายได้ทางอ้อม จะถูกแปลงให้อยู่ในช่วง 0 – 100 คะแนน โดยใช้เกณฑ์คะแนนตั้งแต่ 64 คะแนนขึ้นไป เพื่อระบุนักเรียนยากจนพิเศษ (เทียบเท่ารายได้ต่ำกว่า 1,080 บาท/คน/เดือน) และนำมาใช้เป็นเกณฑ์ในการจัดสรรเงินอุดหนุนแบบมีเงื่อนไข (Conditional Cash Transfers: CCTs)

2.1.2 จุดอ่อนของแบบจำลองการวัดรายได้ทางอ้อมโดยวิธี PMT แบบดั้งเดิม

การใช้เทคนิค Proxy Means Test เป็นวิธีการที่นิยมใช้ในการวิเคราะห์และประเมินภาวะความยากจนในระดับครัวเรือน แต่อย่างไรก็ตามวิธีการดังกล่าวก็มีจุดอ่อนอยู่หลากหลายประการ อาทิเช่น การใช้ Proxy Means Test อาจทำให้เกิดความคลาดเคลื่อนในการประเมินภาวะความยากจน เนื่องจากตัวแปรที่ใช้เป็นตัวแทนอาจจะไม่สามารถสะท้อนความเป็นจริงของความยากจนได้อย่างแท้จริง ทำให้ผลการวิเคราะห์และการประเมินภาวะความยากจนอาจไม่ตรงกับความเป็นจริง (Ting, 2022)

วิธีการ Proxy Means Test ในบางกรณีไม่สามารถที่จะจำแนกความแตกต่างของสถานะความยากจนของครัวเรือนได้อย่างชัดเจน เนื่องจากการพิจารณาค่าเฉลี่ยของกลุ่มเพียงอย่างเดียวไม่ได้คำนึงถึงการกระจายของข้อมูลภายในกลุ่ม ทำให้ไม่สามารถระบุถึงความแตกต่างระหว่างครัวเรือนที่มีสถานะความยากจนในระดับที่แตกต่างกันได้อย่างละเอียด และ การใช้ Proxy Means Test อาจมีความล่าช้าในการประเมินสถานะความยากจนของครัวเรือน เนื่องจากต้องรอการเลือกข้อมูลตัวแปรที่จะเป็นตัวแปรในการแทนก่อน ซึ่งอาจไม่ทันต่อการเปลี่ยนแปลงของภาวะความยากจนที่อาจเกิดขึ้นอย่างรวดเร็วในบางพื้นที่ หรือการเปลี่ยนแปลงของข้อมูลในบางช่วงฤดูกาล (Seasonal Data) ทำให้ความยืดหยุ่นในการปรับปรุงตัวแบบจำลองมีไม่สูง

งานวิจัยจำนวนมากชี้ให้เห็นว่า การใช้วิธีการ Proxy Means Test อาจก่อให้เกิดปัญหาความคลาดเคลื่อนจากการวัด (Measurement Error) ซึ่งส่งผลกระทบต่อความแม่นยำของการระบุตัวกลุ่มเป้าหมาย แต่งานศึกษาของ Gazeaud (2020) วิเคราะห์ผลกระทบของความคลาดเคลื่อนดังกล่าวต่อประสิทธิภาพของแบบจำลอง PMT ในบริบทของประเทศแทนซาเนีย พบว่า การประเมินประสิทธิภาพของ Proxy Means Test ส่วนใหญ่มักตั้งอยู่บนข้อสมมติที่ว่า ตัวแปรอิสระซึ่งใช้เป็นข้อมูลนำเข้าของแบบจำลองถดถอย (Regression) ปราศจาก

ความคลาดเคลื่อนในการวัด หรือมีเพียงความคลาดเคลื่อนแบบสุ่มเท่านั้น แม้ว่าข้อสมมติดังกล่าว จะถูกตั้งข้อสงสัย โดยงานวิจัยหลายชิ้น แต่ผลการศึกษาของ Gazeaud พบว่า ความคลาดเคลื่อนในการวัดในลักษณะดังกล่าวอาจไม่มีผลกระทบอย่างมีนัยสำคัญต่อผลลัพธ์ของแบบจำลอง Proxy Means Test

2.1.3 การใช้เทคนิคอื่นๆ มาช่วยในการพัฒนาแบบจำลองการวัดรายได้ทางอ้อม

การประยุกต์ใช้เทคนิค Machine Learning ในงานวิจัยเศรษฐศาสตร์มีบทบาทเพิ่มมากขึ้น โดยเฉพาะในบริบทที่ข้อมูลมีลักษณะซับซ้อนหรือมีขนาดใหญ่กว่าที่วิธีเชิงสถิติแบบดั้งเดิมจะรับมือได้ ในกรณีที่ต้องการทำนายด้วยความแม่นยำสูง มีข้อมูลจำนวนมาก และความสัมพันธ์ระหว่างตัวแปรเป็นแบบไม่เชิงเส้น (Nonlinear) การใช้เทคนิค Machine Learning จะมีความเหมาะสมมากกว่า โดยกลุ่มแบบจำลองที่นิยมใช้ เช่น Tree-based Models (เช่น Random Forest หรือ XGBoost) Neural Networks และ Regularized Linear Models อย่าง Ridge และ Lasso (Desai, 2023)

อย่างไรก็ตาม การใช้เทคนิค Machine Learning ในเศรษฐศาสตร์จำเป็นต้องพิจารณาทั้งด้านเทคนิคและความเข้าใจในเชิงนโยบาย เช่น การปรับค่าพารามิเตอร์อย่างเหมาะสม การหลีกเลี่ยง Overfitting ของแบบจำลอง และการเปรียบเทียบกับแบบจำลองพื้นฐาน ทั้งนี้ยังต้องใช้เครื่องมือช่วยตีความแบบจำลอง เช่น ค่า SHAP หรือการวิเคราะห์ความสำคัญของตัวแปร เพื่อให้ผลลัพธ์สามารถนำไปใช้ในเชิงนโยบายได้อย่างเหมาะสม (Desai, 2023)

มีงานวิจัยหลายชิ้นที่พยายามประยุกต์การใช้เทคนิคอื่น ๆ เพื่อที่จะพัฒนาการใช้แบบจำลองการวัดรายได้ทางอ้อม งานศึกษาของ Houssou และคณะ (2007) มีการสร้างแบบจำลองการวัดรายได้ทางอ้อมผ่านเทคนิคอื่น ๆ นอกเหนือจากวิธี Ordinary Least Square (OLS) ประกอบไปด้วยแบบจำลอง Linear Probability Model แบบจำลอง Probit และแบบจำลอง Quantile Regressions ผลการศึกษาพบว่าแบบจำลอง Quantile Regressions สามารถใช้ในการสร้างแบบจำลองการวัดรายได้ทางอ้อมได้ดีที่สุด แต่แบบจำลองดังกล่าวยังมีความ Robustness ที่น้อยกว่าแบบจำลองอื่น ๆ งานศึกษาจึงมีข้อเสนอแนะให้ใช้แบบจำลองแบบ Probit ที่มีความสมดุลระหว่างความแม่นยำของแบบจำลองและความ Robust ของแบบจำลอง ข้อเสนอแนะของงานศึกษาดังกล่าวมีความสอดคล้องกับกรณีการศึกษาของชัยยุทธและคณะ (2017) ที่ใช้แบบจำลองแบบ Logistic Regression

งานศึกษาของ McBride และ Nichols (2016) ใช้เทคนิค Machine Learning มาเปรียบเทียบกับแบบจำลองการวัดรายได้ทางอ้อมแบบดั้งเดิมเพื่อที่จะกำหนดเป้าหมายกลุ่มคนยากจนเพื่อได้รับนโยบาย Water Subsidy ในประเทศกาน่า ผ่านการนำเทคนิค LASSO (Least Absolute Shrinkage And Selection Operator) มาใช้ในการเลือกตัวแปรสำหรับการทำ

แบบจำลองการวัดรายได้ทางอ้อมพบว่าการใช้เทคนิคดังกล่าวมีผลของความแม่นยำในการชี้วัดครัวเรือนยากจนได้มากกว่าการใช้แบบจำลองการวัดรายได้ทางอ้อมแบบดั้งเดิมอย่างมีนัยสำคัญ งานศึกษาชิ้นนี้ยังมีข้อเสนอแนะว่าถ้าหากจำนวนของข้อมูลมีขนาดที่ใหญ่มากยิ่งขึ้นจะยิ่งทำให้ผลของการใช้เทคนิคดังกล่าวมีประสิทธิภาพสูงขึ้น

งานศึกษาของ P. Ting (2022) ได้สรุปไว้ว่ามีหลายงานศึกษาที่มีความพยายามในการกำหนดกลุ่มเป้าหมายเพื่อที่จะนำโครงการช่วยเหลือทางด้านสังคมต่าง ๆ ไปช่วยเหลือกับกลุ่มคนจนโดยตรงในกลุ่มของประเทศกำลังพัฒนา เนื่องจากข้อมูลเกี่ยวกับสวัสดิการและสถานะของครัวเรือนมีข้อจำกัดที่สูงรวมทั้งต้นทุนของการได้ข้อมูลการระบุคนจนนั้นสูงมาก ดังนั้นการกำหนดกลุ่มเป้าหมายด้วยตัวแปรเสมือนจึงเป็นเครื่องมือที่สำคัญสำหรับกลุ่มประเทศดังกล่าว ซึ่งใช้ตัวแปรเสมือนเพื่อประมาณการความยากจนของครัวเรือน เช่น รายได้หรือการบริโภคของครัวเรือน จึงกลายเป็นวิธีที่ใช้กันอย่างแพร่หลายในการกำหนดกลุ่มเป้าหมาย การศึกษานี้ใช้เทคนิค Unsupervised Machine Learning บนชุดของตัวบ่งชี้ความยากจนที่ไม่ใช่รายได้ระดับครัวเรือน และบุคคลที่ใช้ในการประมาณรายได้ครัวเรือน โดยใช้ข้อมูล National Household Targeting System for Poverty Reduction หรือ Listahanan ของประเทศฟิลิปปินส์เพื่อศึกษาว่าตัวแปรที่ไม่ใช่รายได้โดยตรงเหล่านี้ที่ใช้ในการทำ Proxy Mean Test เหล่านี้มีความแตกต่างระหว่างครัวเรือนที่มีความยากจนกับกลุ่มที่เป็นครัวเรือนรายได้ปานกลาง และกลุ่มที่เป็นครัวเรือนรายได้สูงหรือไม่ ผ่านการประยุกต์ใช้ Uniform Manifold Approximation And Projection For Dimension Reduction Algorithm หรือที่เรียกว่า UMAP โดยใช้ตัวแปรของตัวบ่งชี้ของ Listahanan 2 เมื่อได้จัดกลุ่มของครัวเรือนผ่านการใช้เทคนิค Clustering ได้เป็น 3 ถึง 4 กลุ่มแล้วทดสอบผลของตัวแปรดังกล่าวพบว่ากลุ่มที่ได้ทำการแบ่งเหล่านี้แทบจะไม่มี ความแตกต่างของตัวแปรที่ใช้ชี้วัดครัวเรือนยากจน กล่าวคือ ครัวเรือนที่รวยที่สุดและยากจนที่สุดในประเทศฟิลิปปินส์กลับมีลักษณะและแนวโน้มของตัวแปรที่ใช้ในการชี้วัดที่ปรากฏว่ามีลักษณะเหมือนกัน และไม่สามารถจำแนกได้จากตัวบ่งชี้ความยากจนที่ไม่ใช่รายได้ที่เลือกมาในวิธีเทคนิค PMT แบบดั้งเดิมได้

การศึกษาของ Kambuya (2017) ได้ประยุกต์ใช้แนวคิดของ Proxy Mean Test เพื่อคัดกรองครัวเรือนที่ประสบปัญหาความยากจนของประเทศไทย โดยเปรียบเทียบประสิทธิภาพของเทคนิคการคัดเลือกตัวแปรชี้วัดความยากจนด้วย 3 วิธี ได้แก่ Stepwise Regression, LASSO และ Random Forest ผ่านข้อมูลครัวเรือนจากการสำรวจภาวะเศรษฐกิจและสังคมของครัวเรือน (Household Socio-Economic Survey: SES) ปี พ.ศ. 2559 ของสำนักงานสถิติแห่งชาติ ผลการศึกษาพบว่า ทั้งสามวิธีสามารถคัดเลือกตัวแปรชี้วัดความยากจนที่มีความคล้ายคลึงกับตัวแปรในการศึกษาของ ชัยยุทธ และคณะ (2560) และทั้งสามเทคนิคมีประสิทธิภาพในการคัดกรองครัวเรือนยากจนค่อนข้างดี นอกจากนี้การใช้เทคนิค Machine Learning เช่น Random Forest ยัง

สามารถช่วยคัดเลือกว่าตัวแปรชี้วัดความยากจนที่มีความสำคัญได้อย่างมีประสิทธิภาพ สะท้อนว่าเทคนิค Machine Learning เป็นเครื่องมือที่มีประโยชน์ในการพัฒนาแบบจำลองการวัดรายได้ทางอ้อม

Wobcke และ Mariyah (2023) ได้นำเสนอแนวทางใหม่ในการใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) และการเพิ่มข้อมูล (Data Augmentation) เพื่อพัฒนาความแม่นยำของ PMT สำหรับการระบุครัวเรือนยากจนในประเทศอินโดนีเซีย โดยใช้ข้อมูลสำรวจครัวเรือนจากสามจังหวัด และมุ่งเป้าหมายไปที่การลดข้อผิดพลาดในการรวม (Inclusion Error) และการยกเว้น (Exclusion Error) การศึกษานี้เปรียบเทียบประสิทธิภาพของแบบจำลองเชิงสถิติและแบบจำลอง Machine Learning โดยพิจารณาแบบจำลองหลัก 3 ประเภท ได้แก่ Ridge Regression เป็นรูปแบบของการถดถอยแบบเส้นตรงที่มีการปรับ Regularization เพื่อลด Overfitting, Logistic Regression ใช้สำหรับจำแนกครัวเรือนว่า "ยากจน" หรือ "ไม่ยากจน" โดยเปลี่ยนปัญหาเป็นการจำแนกประเภท (Classification) และ XGBoost อัลกอริธึมแบบ Gradient Boosting ที่มีประสิทธิภาพสูงในการจัดการกับข้อมูลที่มีลักษณะไม่เชิงเส้น และสามารถจัดอันดับคุณลักษณะได้ โดยงานศึกษานี้จะใช้แบบจำลอง Logistic Regression มาใช้เป็นฐานะ Baseline Classification เพื่อทำนายความน่าจะเป็นที่ครัวเรือนใดครัวเรือนหนึ่งจะตกอยู่ในกลุ่มยากจนที่สุด 40% ล่างที่สุดของประชากร โดยแบบจำลองจะใช้ข้อมูลคุณลักษณะของครัวเรือน เช่น ขนาดครัวเรือน ระดับการศึกษา สถานภาพการจ้างงาน และลักษณะของที่อยู่อาศัยเป็นกลุ่มตัวแปรหลัก และยังใช้คุณลักษณะระดับพื้นที่ (Area-level Features) ตลอดจนเทคนิคการเพิ่มข้อมูลเพื่อเสริมความละเอียดของข้อมูลในพื้นที่ที่มีขนาดเล็ก เช่น ระดับตำบล

ผลการศึกษาพบว่า การประเมินประสิทธิภาพของ Logistic Regression เมื่อเทียบกับ Ridge Regression และ XGBoost แสดงให้เห็นว่า Logistic Regression แม้จะง่ายต่อการตีความและปรับใช้ในเชิงนโยบาย แต่ยังมีข้อจำกัดในด้านความยืดหยุ่นและความสามารถในการจัดการกับข้อมูลเชิงซ้อน และเทคนิค XGBoost สามารถลด Inclusion Error รวมทั้ง Exclusion Error ได้ดีกว่าเทคนิค Logistic Regression อย่างมีนัยสำคัญ

ในโครงการ Benazir Income Support Programme (BISP) ประเทศปากีสถาน ได้ใช้แบบสอบถาม PMT ร่วมกับการวิเคราะห์เชิงสถิติเพื่อกำหนดกลุ่มเป้าหมาย โดยมีการทดลองใช้แบบจำลอง Random Forest และ Gradient Boosting เพื่อประเมินรายได้ครัวเรือน และเปรียบเทียบกับวิธีการ PMT ดั้งเดิม ผลลัพธ์พบว่า Machine Learning มีความแม่นยำมากกว่า โดยสามารถลด Exclusion Error ได้ถึง 30% ในบางภูมิภาค (World Bank, 2019)

รัฐบาลฟิลิปปินส์ได้นำระบบ Listahanan มาใช้ร่วมกับ PMT ในการจัดทำฐานข้อมูลครัวเรือนยากจนทั่วประเทศ โดยใช้เทคนิค Logistic Regression สำหรับการประเมิน

คุณสมบัติ อย่างไรก็ตามการศึกษาโดย UNICEF (2021) ได้เสนอให้ปรับปรุงวิธีโดยใช้ Machine Learning แทนการถดถอยแบบเส้นตรง โดยอ้างอิงจากประสิทธิภาพที่เพิ่มขึ้นในความแม่นยำและความสามารถในการจัดการกับข้อมูลที่มีลักษณะไม่เชิงเส้น

โครงการ Cadastro Único ของประเทศบราซิลซึ่งเป็นฐานข้อมูลระดับชาติที่ใช้สำหรับโครงการสวัสดิการ เช่น Bolsa Família รัฐบาลได้ใช้ข้อมูล PMT ผสมกับระบบ GIS และข้อมูลเชิงพื้นที่เพื่อระบุครัวเรือนที่มีความเสี่ยงสูง โดยมีการทดลองใช้แบบจำลองเชิงพื้นที่และ XGBoost เพื่อประเมินโอกาสที่ครัวเรือนจะตกอยู่ในภาวะยากจน ผลลัพธ์พบว่าการใช้ตัวแปรเชิงพื้นที่ยังช่วยเพิ่ม F1-score และสามารถลดค่า False Negative ได้อย่างมีนัยสำคัญ (Carvalho et al., 2022)

จากการทบทวนวรรณกรรมสะท้อนให้เห็นว่า การใช้เทคนิค Machine Learning ไม่เพียงแต่เพิ่มประสิทธิภาพในแง่ของความแม่นยำเท่านั้น แต่ยังช่วยลดต้นทุนระยะยาวและเพิ่มความโปร่งใสในการระบุกลุ่มเป้าหมายในนโยบายสวัสดิการของรัฐ ด้วยเหตุนี้ การออกแบบระบบ PMT ที่ยืดหยุ่นและขับเคลื่อนด้วยข้อมูล (Data-driven Targeting System) จึงกลายเป็นแนวโน้มสำคัญของการสร้างเครื่องมือชี้วัดความยากจนในระดับสากล

2.2 งานวิจัยอื่น ๆ ที่เกี่ยวข้อง

การวิจัยอื่น ๆ ที่เกี่ยวข้องจะประกอบไปด้วยการทบทวนวรรณกรรมสองส่วนคือการเปรียบเทียบการใช้เทคนิค Machine Learning ต่าง ๆ ที่เกี่ยวข้อง และการตีความแบบจำลอง Machine Learning ผ่านการใช้ค่า Shapley Value

2.2.1 เปรียบเทียบการใช้เทคนิค Machine Learning ต่าง ๆ ที่เกี่ยวข้อง

การทบทวนวรรณกรรมส่วนนี้จะยกตัวอย่างของแบบจำลองมาทั้งหมด 4 ตัว แบบจำลองคือกลุ่มแบบจำลองการจำแนก (Classification) แบบจำลองประเภทต้นไม้ตัดสินใจ หรือ Decision Tree แบบจำลองประเภทต้นไม้ตัดสินใจที่ใช้เทคนิค Bagging (Random Forest) และแบบจำลองประเภท Decision Tree ที่ใช้เทคนิค Boosting (XGBoost)

กลุ่มแบบจำลอง Classification หรือเทคนิคการจำแนก คือกลุ่มประเภทแบบจำลอง Machine Learning ในกลุ่มของ Supervised Learning (แบบจำลองที่มีความจำเป็นต้องกำหนดปลายทางของกลุ่มที่แบบจำลองต้องทำการเรียนรู้ เพื่อให้แบบจำลองสามารถเรียนรู้จากข้อมูลที่ทำกรนำเข้าไปในแบบจำลอง และให้ผลลัพธ์ที่ตอบคำถามตามวัตถุประสงค์ได้ ซึ่งคำตอบที่ได้จากแบบจำลองจำแนกจะอยู่ในรูปแบบค่าที่ไม่ต่อเนื่อง (Discrete Value)

ทำให้สามารถตอบคำถามที่กำหนดคำตอบไว้ล่วงหน้าได้เป็นอย่างดี อาทิเช่น เป็นคนจนหรือไม่ใช่คนจน เป็นเด็กหรือผู้ใหญ่ หรือเป็นกลุ่มเด็กที่ขาดสารอาหารหรือไม่ เป็นต้น)

แบบจำลองจำแนกสามารถแบ่งกลุ่มออกมาเป็น 3 กลุ่มประกอบไปด้วยแบบจำลองแบบ Binary Classification (จำแนกแบบสองกลุ่ม) เป็นแบบจำลองที่มีการจำแนกแบบ 2 ตัวแปร ผลลัพธ์ที่ได้จากข้อมูลจะมีเพียงแค่ 2 หมวดหมู่ที่ทำการกำหนดไว้เท่านั้น เช่น ข้อมูลลักษณะของครวเรือนว่าครวเรือนดังกล่าวเป็นครวเรือนยากจนหรือไม่ ผลลัพธ์คำตอบของแบบจำลองที่ได้จะมีเพียง “เป็นครวเรือนยากจน” หรือ “ไม่ใช่ครวเรือนยากจน” เท่านั้น กลุ่มที่สองคือแบบจำลอง Multi-Class Classification (จำแนกแบบหลายกลุ่ม) การจำแนกแบบหลายหมวดหมู่ลักษณะการวิเคราะห์จะใกล้เคียงกับแบบจำลองแบบ Binary แต่ผลลัพธ์ที่ได้จะมีมากกว่า 2 คำตอบเป็นการทำนายสิ่งที่ไม่ใกล้เคียงกับข้อมูลที่ป้อน เช่น การจำแนกกลุ่มของครวเรือนเป็น “ครวเรือนยากจน” หรือ “ครวเรือนรายได้สูง” หรือ “ไม่ใช่ทั้งคู่” เป็นต้น ในกลุ่มแบบจำลองแบบนี้จะมีเป้าหมายอยู่ที่การใช้เพื่อหาคำตอบที่ต้องการกำหนดเป้าหมายมากกว่าสองกลุ่มขึ้นไป กลุ่มที่สามคือแบบจำลองแบบ Multi-Label Classification (จำแนกแบบหลาย) โดยแบบจำลองแบบนี้จะมีความคล้ายคลึงกับแบบจำลองแบบ Multi-Class แต่มีข้อแตกต่างหลักคือแบบจำลอง Multi-Class จะเป็นการจำแนกข้อมูลที่มีคุณสมบัติเหมือนกัน แต่ให้ผลลัพธ์ที่แตกต่างกัน แบบจำลองแบบ Multi-Label เป็นการจำแนกข้อมูลที่มีคุณสมบัติแตกต่างกันแต่ผลลัพธ์สามารถเหมือนกันได้ ซึ่ง Multi-Label จะมีความซับซ้อนในการวิเคราะห์มากกว่า

กลุ่มแบบจำลองประเภทที่มีความซับซ้อนมากยิ่งขึ้นคือแบบจำลอง Decision Tree หรือ ต้นไม้ตัดสินใจ คือ การจำลองวิธีการตัดสินใจของมนุษย์มาประยุกต์ใช้ในการทำนายของแบบจำลอง ซึ่งการตัดสินใจแต่ละครั้งจะมีการแตกโจทย์หลักออกเป็นโจทย์ย่อยหลาย ๆ โจทย์ก่อนเพื่อที่จะได้ง่ายต่อการตัดสินใจ หรือนำเอาปัจจัยต่าง ๆ ที่เกี่ยวข้องกับการตัดสินใจหรือเกี่ยวข้องกันกับโจทย์หลักมาตั้งเป็นคำถามใหม่หรือแตกเป็นโจทย์ย่อย และทำการตั้งคำถามใหม่แบบจำลองต้นไม้จะเป็นแบบจำลองที่มีลักษณะเป็น Rule-Based Model ที่จะสร้างเงื่อนไข “ถ้า-แล้ว” ขึ้นมาจากข้อมูลเพื่อที่จะแบ่งข้อมูลออกเป็นกลุ่มใหม่ที่สามารถอธิบายได้ดีที่สุด โดยการสร้างเงื่อนไขในแต่ละตัวแปรจะถูกกำหนดด้วยฟังก์ชันเป้าหมาย (Objective Function) ซึ่งแบบจำลอง ต้นไม้มีฟังก์ชันเป้าหมายอยู่หลายตัวตามประเภทของ Decision Tree นั้น ๆ

แบบจำลองแบบ Decision Tree จะแบ่งออกเป็น 2 ประเภท คือ กลุ่ม Regression Tree ที่ใช้สำหรับ แบบสมการถดถอยโดยมีค่า Residual Sum Of Squares (RSS) (ค่า Residual คือ ค่าความคลาดเคลื่อน หรือค่า Error ระหว่างค่าของตัวแปร y ทุก ๆ จุดในข้อมูลกับ ค่า y ที่ได้มาจากการประมาณค่าขึ้นมากการคำนวณ Residual ของข้อมูลตัวที่ i และค่า Residual Sum Of Squares (RSS) คือ การวัดค่า Residual หรือ ค่า Error ของทุก ๆ จุดในชุดข้อมูล และ

นำมายกกำลังสอง เพื่อให้ค่า Residual เป็นบวก และเป็นการทำ Normalize ด้วย เนื่องจากถ้า y ที่พยากรณ์ได้มีค่ามากกว่า y จริงจะทำให้ค่า Residual ติดลบ) เป็นฟังก์ชันเป้าหมาย ในการหาจุดที่ดีที่สุดในการแบ่งข้อมูล (Split Point) จากการ Minimized ให้ค่า RSS มีค่าน้อยที่สุด

แบบจำลองต้นไม้การตัดสินใจ (Decision Tree) ประเภทที่สอง คือ แบบจำลองการจำแนก (Classification Tree) ซึ่งมีวัตถุประสงค์หลักในการจำแนกประเภทของข้อมูลผ่านฟังก์ชันเป้าหมาย เช่น Gini Impurity (เป็นมาตรวัดที่ใช้ประเมินระดับความไม่บริสุทธิ์ของกลุ่มข้อมูลที่ได้จากการแบ่งตามตัวแปรใดตัวแปรหนึ่ง โดยค่าดังกล่าวจะยิ่งต่ำเมื่อกลุ่มข้อมูลที่มีความเป็นเนื้อเดียวกันในแง่ของตัวแปรเป้าหมาย หากค่าความไม่บริสุทธิ์ต่ำ แสดงว่าแบบจำลองสามารถแยกประเภทข้อมูลได้ดี) หรือ Entropy เพื่อใช้ในการค้นหาจุดแบ่งข้อมูลที่เหมาะสมที่สุด (Split Point) เมื่อมีการเพิ่มฟังก์ชันเป้าหมายและใช้เกณฑ์ในการแบ่งข้อมูลที่ซับซ้อนมากขึ้น จะส่งผลให้โครงสร้างของต้นไม้มีความซับซ้อนตามไปด้วย แม้จะสามารถเพิ่มความแม่นยำของแบบจำลองได้ แต่ก็อาจทำให้แบบจำลองมีลักษณะเป็น "กล่องดำ" (Black-box) มากขึ้น ซึ่งส่งผลให้ความสามารถในการตีความหรืออธิบายการทำงานของแบบจำลองลดลง

แบบจำลองแบบที่สามคือแบบจำลอง Random Forest เป็นหนึ่งในกลุ่มของแบบจำลอง Ensemble Learning ที่มีหลักการคือพัฒนาแบบจำลองที่เหมือนกันหลายๆ ครั้ง (หลาย Instance) บนข้อมูลชุดเดียวกัน โดยแต่ละครั้งของการเรียนรู้จะเลือกส่วนของข้อมูลที่ใช้ในการพัฒนาแบบจำลองที่ไม่เหมือนกัน แล้วเอาการตัดสินใจของแบบจำลองมาตามหากันว่า Class ไหนถูกเลือกมากที่สุดผ่านแบบจำลองโดยที่ กลไกการรวมการตัดสินใจของแบบจำลองจำนวนมากเข้าด้วยกันจะให้ผลการตัดสินใจที่แม่นยำมากกว่า ทั้งนี้การเรียนรู้แบบ Ensemble นี้จะทำงานได้ดีบนเงื่อนไขว่า แบบจำลองแต่ละตัวจะต้องเรียนรู้อย่างเป็นอิสระต่อกันให้มากที่สุด กลไกนี้เรียกว่า Bagging และ Pasting กระบวนการแบบ Bagging สามารถสุ่มเลือกข้อมูลรายการเดียวกันได้ แต่กระบวนการ Pasting ไม่อนุญาตให้สุ่มรายการซ้ำกันได้ ทำให้ในทางปฏิบัติกระบวนการแบบ Bagging จะช่วยลดความแปรปรวนหรือ Variance ของแบบจำลองได้ดี เพราะมีการเลือกรายการข้อมูลซ้ำ ทำให้ได้แบบจำลองที่เสถียรกว่าและมักจะแม่นยำกว่ากระบวนการ Pasting โดยแบบจำลองในแบบนี้จะช่วยแก้ปัญหาแบบจำลองที่ Overfit ลักษณะของแบบจำลองแบบนี้ถึงแม้จะแก้ปัญหาดังกล่าวได้หลากหลายและมีความแม่นยำของแบบจำลองที่สูงแต่ต้องแลกกับความสามารถในการแปลผลที่ลดลงกว่าแบบจำลองแบบต้นไม้

แบบจำลองสุดท้ายคือกลุ่มแบบจำลองแบบ Boosting เช่นแบบจำลอง XGBoost (Extreme Gradient Boosting) หรือ LightGBM ซึ่งเป็นแบบจำลองที่ได้นำเอาแบบจำลองแบบต้นไม้มาผ่านกระบวนการเรียนรู้ต่อ ๆ กันหลาย ๆ แบบจำลอง โดยที่แต่ละแบบจำลอง จะเรียนรู้จากข้อผิดพลาดหรือ Error ของแบบจำลองก่อนหน้า ทำให้ความแม่นยำของการพยากรณ์ผลของ

แบบจำลองมีความแม่นยำมากขึ้นแบบต่อเนื่อง เมื่อมีกระบวนการการเรียนรู้ต่อเนื่องกันจนมีความลึก (Depth) มากพอ แบบจำลองจะหยุดกระบวนการเรียนรู้เมื่อไม่เหลือรูปแบบ หรือ Pattern ของตัว Error จากแบบจำลองก่อนหน้านี้ให้เรียนรู้แล้ว ข้อแตกต่างของแบบจำลองแบบ XGBoost กับแบบจำลอง Random Forest คือกระบวนการสร้างแบบจำลองจะใช้เทคนิค Boosting เป็นการนำ Weak Classifier หรือ Classifier ที่มีความแม่นยำต่ำมาพยากรณ์กลุ่มข้อมูลที่มีและนำ Weak Classifier ตัวใหม่มาแก้ไข Error ที่แบบจำลองเดิมมี ทำให้ผลรวมของ Classifier จะเกิดเป็น Classifier ใหม่ขึ้นมาและจะทำการทำซ้ำกระบวนการดังกล่าวจนได้แบบจำลองที่ดีที่สุดจากผลรวมของ Classifier ข้อเสียของการใช้เทคนิคแบบ Boosting คือแบบจำลองต้องมีการทำซ้ำกระบวนการของแบบจำลองหลาย ๆ ครั้งและเป็นลำดับจนได้แบบจำลองที่มีประสิทธิภาพมากที่สุด ทำให้ใช้เวลาในการสร้างแบบจำลองที่สูงกว่า โดยสรุปการใช้เทคนิคแบบ Bagging จะช่วยแก้ปัญหา Overfitting ของข้อมูลได้มีประสิทธิภาพ แต่ในขณะที่เทคนิคแบบ Boosting จะช่วยแก้ปัญหาความแม่นยำต่ำ (Bias) ได้มีประสิทธิภาพกว่า

การประยุกต์ใช้เทคนิค Machine Learning ในการสร้างแบบจำลองมีแนวโน้มที่จะให้ค่าความแม่นยำสูงกว่าแบบจำลองสมการถดถอยเชิงเส้นแบบดั้งเดิมอย่างมีนัยสำคัญ อย่างไรก็ตาม ความแม่นยำที่เพิ่มขึ้นนี้มักมาพร้อมกับข้อจำกัดด้านความสามารถในการตีความ (Interpretability) ของแบบจำลอง งานศึกษาจึงมีจุดมุ่งหมายในการเสนอข้อเสนอแนะเชิงนโยบายความสามารถในการแปลผลของแบบจำลองถือเป็นองค์ประกอบสำคัญ เพื่อให้ผลลัพธ์ของแบบจำลองสามารถนำไปใช้สนับสนุนการตัดสินใจเชิงนโยบายได้อย่างมีประสิทธิภาพ จึงได้มีการทบทวนวรรณกรรมเพิ่มเติมในส่วนสุดท้ายของงาน เพื่อสำรวจแนวทางหรือเทคนิคที่สามารถเพิ่มความสามารถในการตีความของแบบจำลอง

2.2.2 Shapley Regression และการตีความแบบจำลอง Machine Learning

การทบทวนวรรณกรรมพบว่าสำหรับแบบจำลอง Machine Learning สามารถใช้การแปลค่า Shapley value เพื่อใช้ในการอธิบายผลของแบบจำลองที่มีความซับซ้อนได้ ค่า Shapley value เป็นการคำนวณภายใต้หลักทฤษฎีเกม (Game Theory) ในรูปแบบทฤษฎีเกมแบบร่วมมือ (Coalitional Game Theory) ในหลักการดังกล่าว มีการมองค่าของฟีเจอร์หรือตัวแปรในแต่ละตัวเป็น “ผู้เล่น” (Player) ของเกม และผลจากการทำนายของแบบจำลองเป็น “ผลลัพธ์” (Payout) ของเกม ค่า Shapley Value เป็นค่าที่ระบุว่าควรแบ่งผลลัพธ์ของเกมให้แก่ผู้เล่นแต่ละคนอย่างไรให้ยุติธรรมโดยอ้างอิงจากสัดส่วนการมีส่วนร่วม (Contribution) ของผู้เล่นแต่ละคน เมื่อนำหลักการดังกล่าวมาใช้ในการวิเคราะห์แบบจำลองจึงสามารถใช้เพื่อบอกว่าแต่ละตัวแปรจะส่งผลกระทบต่อการทำนายของแบบจำลองมากน้อยอย่างไรได้ (Tatsuro, 1983)

งานศึกษาของ Buckmann และ Joseph (2023) ได้เสนอแนวทางการวิเคราะห์ที่ผสมผสานระหว่างความแม่นยำของเทคนิค Machine Learning กับความสามารถในการตีความเชิงสถิติ โดยมุ่งเน้นการประยุกต์ใช้ในบริบทเศรษฐกิจของประเทศ England เช่น การพยากรณ์อัตราการว่างงานของสหรัฐฯ ล่วงหน้า 1 ปี งานศึกษาชิ้นนี้พบว่าแบบจำลอง Machine Learning เช่น Gradient Boosting และ Neural Networks จะมีความสามารถในการพยากรณ์ที่สูงกว่าวิธีการแบบดั้งเดิม แต่ปัญหาสำคัญคือความไม่โปร่งใส ทำให้ยากต่อการเข้าใจกลไกการตัดสินใจภายในของแบบจำลอง ซึ่งเป็นอุปสรรคต่อการนำไปใช้ในการตัดสินใจเชิงนโยบาย ดังนั้นการใช้ Shapley Regression จะช่วยให้สามารถตีความผลลัพธ์ของแบบจำลอง Machine Learning ได้ในลักษณะเดียวกับแบบจำลองถดถอยแบบดั้งเดิม และการเลือกตัวแปรต้นโดยผู้เชี่ยวชาญในสาขานั้น ๆ ช่วยให้ได้แบบจำลองที่มีความสมดุลระหว่างความแม่นยำและความสามารถในการตีความ แสดงให้เห็นถึงความเป็นไปได้ในการผสมผสานความแม่นยำของเทคนิค Machine Learning เข้ากับการตีความเชิงสถิติ ซึ่งเป็นประโยชน์อย่างยิ่งในการวิเคราะห์ข้อมูลที่ซับซ้อนในบริบททางด้านเศรษฐศาสตร์

2.3 สรุปการทบทวนวรรณกรรม

แม้ว่าแบบจำลอง Machine Learning ที่มีความซับซ้อนมากจะทำให้ความแม่นยำของแบบจำลองเพิ่มมากขึ้น แต่การแปลความหมายของแบบจำลองจะมีความซับซ้อนมากในงานศึกษาชี้ว่าสามารถใช้การแปลค่าแบบ Shapley Value ในการแปลผลของแบบจำลองที่มีความซับซ้อนได้ (Rodríguez-Pérez และ Bajorath (2020)) นอกจากนี้การใช้เทคนิค Shapley Regression ยังจะช่วยให้สามารถตีความผลลัพธ์ของเทคนิค Machine Learning ได้ในลักษณะเดียวกับแบบจำลองถดถอยแบบดั้งเดิมและยังสามารถตรวจสอบนัยสำคัญทางสถิติได้

การวัดรายได้ทางอ้อม (Proxy Means Test: PMT) เป็นเทคนิคทางสถิติที่ได้รับความนิยมในการคัดกรองครัวเรือนยากจน โดยใช้ตัวแปรที่มีความสัมพันธ์กับระดับรายได้ เช่น ขนาดครัวเรือน ระดับการศึกษา สภาพที่พักอาศัย และการถือครองทรัพย์สิน แทนการสอบถามรายได้โดยตรงซึ่งมักเผชิญกับปัญหาความไม่ถูกต้องและความยากในการตรวจสอบ (Grosh et al., 2008; Kidd & Wylde, 2011) เทคนิค PMT ได้รับการประยุกต์ใช้ในระดับนานาชาติ เช่น PPI (Poverty Probability Index) ของ Schreiner ซึ่งใช้ข้อมูลจากตัวแปร 10 ตัว เพื่อความประหยัดต้นทุนและสะดวกในการเก็บข้อมูล นอกจากนี้ ในบริบทของประเทศไทย งานของชัยยุทธและคณะ (2560; 2565) ได้พัฒนาแบบจำลอง PMT โดยใช้ข้อมูลจากแบบสอบถาม

และการวิเคราะห์ถดถอยเชิงเส้น เพื่อนำไปใช้ในการจัดสรรเงินอุดหนุนแบบมีเงื่อนไขสำหรับนักเรียนยากจน

แม้ PMT จะมีข้อดีหลายประการ แต่ก็มีจุดอ่อนสำคัญ อาทิเช่น ไม่สามารถสะท้อนระดับความยากจนได้อย่างแท้จริงเมื่อใช้เพียงค่าเฉลี่ยของตัวแปร และก่อให้เกิดข้อผิดพลาดในการวัด (Measurement Error) (Ting, 2022) อย่างไรก็ตาม งานของ Gazeaud (2020) พบว่าความคลาดเคลื่อนแบบสุ่มอาจไม่มีผลกระทบอย่างมีนัยสำคัญต่อผลลัพธ์ของแบบจำลอง PMT

ด้วยข้อจำกัดดังกล่าว แนวโน้มในการพัฒนาแบบจำลอง PMT คือการประยุกต์ใช้เทคนิค Machine Learning ซึ่งสามารถจัดการกับข้อมูลที่ซับซ้อนและมีลักษณะไม่เชิงเส้นได้ดีกว่าแบบจำลองเชิงเส้นแบบดั้งเดิม (Desai, 2023) กลุ่มแบบจำลองที่ได้รับความนิยม ได้แก่ Random Forest, XGBoost, และ LASSO ซึ่งแสดงให้เห็นถึงความแม่นยำที่เหนือกว่า OLS หรือ Logistic Regression ในหลายกรณี (McBride & Nichols, 2016; Houssou et al., 2007) รวมถึงงานของ Kambuya (2017) ที่เปรียบเทียบเทคนิคการเลือกตัวแปรและพบว่า เทคนิค Machine Learning สามารถเลือกตัวแปรที่เกี่ยวข้องกับความยากจนได้อย่างมีประสิทธิภาพ

การศึกษาจากต่างประเทศ เช่น ในปากีสถาน อินโดนีเซีย ฟิลิปปินส์ และบราซิล ได้นำเทคนิค Machine Learning เข้ามาช่วยในการลดข้อผิดพลาดในการคัดกรองกลุ่มเป้าหมาย เช่น การใช้ XGBoost และ Data Augmentation ช่วยลดทั้ง Inclusion และ Exclusion Error ได้อย่างมีนัยสำคัญ (World Bank, 2019; Wobcke & Mariyah, 2023; Carvalho et al., 2022; UNICEF, 2021)

นอกจากประเด็นด้านความแม่นยำแล้ว การตีความแบบจำลอง Machine Learning เป็นประเด็นสำคัญโดยเฉพาะในการประยุกต์ใช้งานเชิงนโยบาย งานของ Buckmann และ Joseph (2023) เสนอการใช้ Shapley Regression เพื่อถอดรหัสกลไกการตัดสินใจของแบบจำลอง Machine Learning โดยอาศัยทฤษฎีเกมแบบร่วมมือในการคำนวณค่าผลกระทบของตัวแปรแต่ละตัว (Shapley value) ซึ่งช่วยให้สามารถเข้าใจว่าแต่ละตัวแปรมีส่วนร่วมต่อผลลัพธ์มากน้อยเพียงใด

โดยสรุป การทบทวนวรรณกรรมชี้ให้เห็นว่าการใช้เทคนิค Machine Learning ในการพัฒนาแบบจำลอง PMT ช่วยเพิ่มความแม่นยำในการคัดกรองครัวเรือนยากจน ลดต้นทุนการเก็บข้อมูล และเพิ่มศักยภาพในการออกแบบนโยบายที่มีเป้าหมายชัดเจน อย่างไรก็ตาม ความสามารถในการตีความผลลัพธ์ยังคงเป็นปัจจัยสำคัญในการเลือกใช้เทคนิคดังกล่าว โดยเฉพาะในบริบทของการกำหนดนโยบายสาธารณะ

บทที่ 3

วิธีการศึกษา


บทนี้จะอธิบายวิธีการศึกษาโดยประกอบไปด้วยขั้นตอนในการศึกษา แบบจำลองที่ใช้ในงานศึกษา วิธีการวัดประสิทธิภาพของแบบจำลอง วิธีการแปลผลการประมาณค่าของแบบจำลอง Machine Learning วิธีการตรวจสอบการอนุมานทางสถิติผ่านการวิเคราะห์แบบ Shapley Regression และข้อมูลที่ใช้ในการศึกษา

3.1 ขั้นตอนในการศึกษา

ขั้นตอนที่ใช้ในงานศึกษาขึ้นนี้สามารถสรุปได้ดังภาพที่ 3.1

ภาพที่ 3.1

สรุปขั้นตอนกระบวนการในการศึกษา



หมายเหตุ เรียบเรียงและออกแบบโดยผู้วิจัย

ขั้นตอนที่ใช้ในงานศึกษาชิ้นนี้ประกอบไปด้วย 7 ขั้นตอน ขั้นตอนแรกเป็นการเตรียมข้อมูลเป็นการรวมระบบฐานข้อมูลสามส่วน ประกอบไปด้วยข้อมูลแบบสำรวจ SES ในระดับครัวเรือน ข้อมูลแบบสำรวจ SES ในระดับบุคคล และข้อมูลตัวชี้วัดรายจังหวัดต่าง ๆ เช่น ข้อมูลผลิตภัณฑ์มวลรวมจังหวัด (Gross provincial product : GPP) ข้อมูลจำนวนประชากรรายจังหวัด ข้อมูลลักษณะอุตสาหกรรมรายจังหวัด เป็นต้น โดยข้อมูลจะถูกรวบรวมเป็นระดับครัวเรือนก่อนนำเข้าไปใช้ในแบบจำลอง

ขั้นตอนที่สองคือการคัดเลือกครัวเรือนยากจนสำหรับใช้เป็นตัวแบบ (Label) ให้แบบจำลอง Machine Learning เรียนรู้

ขั้นตอนที่สามเป็นการสร้างแบบจำลอง Machine Learning สำหรับแบบจำลองแบบ Classification และทำนายรายได้ของครัวเรือนสำหรับแบบจำลองแบบ Regression รวมทั้งมีการสร้างแบบจำลองไว้เปรียบเทียบประสิทธิภาพของแบบจำลองดั้งเดิมผ่าน Logistics Regression โดยแบ่งแบบจำลองเป็นสามรูปแบบประกอบไปด้วยสร้างแบบจำลองแบบปกติ แบบตัดรายได้ และแบบถ่วงน้ำหนัก

ขั้นตอนที่สี่เป็นการสร้างแบบจำลองแบบ random forest เปรียบเทียบกับแบบจำลอง LightGBM พร้อมทั้งเปรียบเทียบแบบจำลองต่าง ๆ หาแบบจำลองที่ดีที่สุด

ขั้นตอนที่ห้าคือกระบวนการแปรผลของตัวแปรต่าง ๆ ที่ได้จากการใช้แบบจำลองผ่านค่า SHAP

ขั้นตอนที่หกเป็นการตรวจสอบค่านัยสำคัญทางสถิติผ่านการทำ SHAP Regression

ขั้นตอนสุดท้ายจะทำการเปรียบเทียบแบบจำลองทั้งหมดผ่านการคำนวณค่า Inclusion Error และ Exclusion Error

3.2 แบบจำลองที่ใช้ในการศึกษา

แบบจำลองที่ใช้ในการศึกษาสำหรับงานวิจัยชิ้นนี้แบ่งแบบจำลองที่ใช้ศึกษาทั้งสิ้นสามแบบจำลองเพื่อเปรียบเทียบหาแบบจำลองที่ดีที่สุดเพื่อใช้สำหรับการพัฒนาแบบจำลองการวัดรายได้ทางอ้อม (PMT) โดยแบบจำลองที่ใช้ในการศึกษาทั้งสามแบบจำลองประกอบไปด้วย แบบจำลอง Logistics Regression แบบจำลอง Random Forest และแบบจำลอง LightGBM มีรายละเอียดของแต่ละแบบจำลองมีดังนี้

3.2.1 แบบจำลอง Logistics Regression

Logistic Regression เป็นเทคนิคการวิเคราะห์ทางสถิติที่ใช้สำหรับการจำแนกทวิ (Binary Classification) โดยมีตัวแปรตาม (Dependent Variable) เป็นตัวแปรคุณภาพที่มีเพียงสองค่า เช่น ผ่าน/ไม่ผ่าน หรือจริง/ปลอม (Lottes et al., 1996) (Kassraian et al., 2016) (Hosmer et al., 2013) แบบจำลอง Logistic Regression เป็นแบบจำลองที่จะสร้างจากความสัมพันธ์ระหว่างตัวแปรตามและตัวแปรอิสระ ผ่านการทำนายโอกาสของการเกิดเหตุการณ์นั้นจากข้อมูลของตัวแปรอิสระ แบบจำลองในลักษณะนี้เป็นแบบจำลองในลักษณะเฉพาะของ Generalized Linear Model

หลักการสำคัญของ Logistic Regression คือ ตัวแปรตาม (ตัวแปรค่า Y) มีค่าเป็นเพียง 0 หรือ 1 ซึ่งแตกต่างจาก Linear Regression ที่ตัวแปรตามสามารถมีค่าเป็นตัวเลขได้ในช่วงกว้าง (Hosmer et al., 2013) โดยสมการของแบบจำลอง Logistic Regression สามารถแสดงได้ดังนี้คือ

$$P(Y=1 | X) = \frac{1}{1+e^{-(\beta_0+\beta_1 X)}} \quad (3.1)$$

เมื่อ $P(Y=1 | X)$ คือโอกาสของการเกิดเหตุการณ์ที่ตัวแปรตามเป็น 1 เมื่อให้ข้อมูลของตัวแปรอิสระ X และ β_0 คือค่าคงที่ และค่า β_1 คือค่าสัมประสิทธิ์ของตัวแปรอิสระ X ในรูปของ Log Odds

การสร้างแบบจำลองสร้างโดยการประมาณค่าสัมประสิทธิ์จากชุดข้อมูลโดยใช้วิธีการประมาณความน่าจะเป็นสูงสุด (Maximum Likelihood Estimation; MLE) ซึ่งต่างจากการวิเคราะห์การถดถอยทั่วไปที่ใช้วิธีกำลังสองน้อยที่สุด (Least Square Method) ที่มีแนวคิดค่าส่วนเหลือ (Residuals) มีการกระจายแบบปกติ ดังนั้นการวิเคราะห์แบบ MLE เพื่อให้ได้ตัวแบบที่เหมาะสมที่สุดจึงใช้กระบวนการวิเคราะห์แบบเวียนซ้ำ (Iterative Process) โดยเริ่มจากการประมาณค่า สัมประสิทธิ์ของตัวแปรเพื่อให้ได้สมการตั้งต้น หลังจากนั้นก็ใช้สมการเพื่อทำนายค่าแล้วนำมาคำนวณซ้ำเพื่อหาค่าสัมประสิทธิ์ใหม่ที่ทำให้ได้ความน่าจะเป็นสูงสุด เพื่อให้สามารถทำนายค่าของตัวแปรตามได้ใกล้เคียงค่าของข้อมูลจริงมากที่สุดจากแบบจำลอง

แบบจำลอง Logistic Regression มีข้อด้อยบางประการ เช่น การตีความค่าสัมประสิทธิ์มีความซับซ้อนกว่า Linear Regression การตีความค่าสัมประสิทธิ์ของ Logistic Regression แสดงถึงผลกระทบของตัวแปรอิสระต่อ Log Odds ของการเกิดผลลัพธ์ที่ตัวแปรตามเท่ากับ 1 แทนที่จะเป็นผลกระทบต่อค่าเฉลี่ยของตัวแปรตาม เช่นในกรณีของ Linear Regression ค่า Odd Ratio คือระดับความสัมพันธ์ระหว่างตัวแปรอิสระที่มีต่อโอกาส

ของตัวแปรตามที x_i มีค่าเท่ากับ 1 แสดงถึงขนาดของผลกระทบของตัวแปรอิสระที่มีต่อตัวแปรตาม โดย Odd Ratio มีสูตรในสมการดังนี้

$$\frac{\hat{p}_y}{1-\hat{p}_y} = e^{\beta_0 + \beta_1 + \beta_2 + \dots + \beta_n} \quad (3.2)$$

ค่าสัมประสิทธิ์ β_i ในแบบจำลองมักใช้ตีความหมายที่เข้าใจได้ในเชิงทิศทางมากกว่าการบอกขนาด

นอกจากนี้ ในการตีความผลของแบบจำลองยังสามารถใช้การวิเคราะห์ Marginal Effects เพื่อประเมินว่าการเปลี่ยนแปลงของตัวแปรอิสระเพียงเล็กน้อยจะส่งผลอย่างไรต่อความน่าจะเป็นของเหตุการณ์ โดยสูตรของ Marginal Effect สำหรับตัวแปรเชิงปริมาณมีลักษณะดังนี้ (Perrailon, 2019)

$$\frac{\partial P(y_i=1)}{\partial x_{ij}} = \beta_j \cdot P(y_i=1) \cdot (1-P(y_i=1)) \quad (3.3)$$

ค่าผลกระทบนี้ช่วยให้สามารถอธิบายว่า ตัวแปรอิสระแต่ละตัวมีผลต่อความน่าจะเป็นของการเกิดเหตุการณ์ (เช่น ความยากจน) มากน้อยเพียงใด

3.2.2 แบบจำลอง Random Forest

ก่อนที่จะอภิปรายแบบจำลอง Random Forest ต้องแสดงถึงแบบจำลอง Decision Tree เพราะแบบจำลอง Random forest เป็นการรวมแบบจำลอง Decision Tree หลาย ๆ แบบจำลองเพื่อสร้างแบบจำลองที่ดีมีประสิทธิภาพสูงที่สุด

แบบจำลอง Decision Tree จะเป็นแบบจำลองที่มีลักษณะเป็น Rule-Based ที่จะสร้างเงื่อนไข ถ้า-แล้ว ขึ้นมาจากข้อมูลเพื่อแบ่งข้อมูลออกเป็นกลุ่มใหม่ที่สามารถอธิบายกลุ่มเป้าหมายได้ดีที่สุด โดยการสร้างเงื่อนไข ถ้า-แล้ว ในแต่ละตัวแปรจะถูกกำหนดด้วยฟังก์ชันเป้าหมาย (Objective Function) แบบจำลอง Decision Tree มีฟังก์ชันเป้าหมายอยู่หลากหลายตามประเภทของ Decision Tree นั้น ๆ แบบจำลอง Decision Tree จะแบ่งออกเป็น 2 ประเภท คือ กลุ่ม Regression Tree ที่ใช้สำหรับการทำโจทย์สมการถดถอยโดยมีค่า Residual Sum Of Squares (RSS) ซึ่งสามารถแสดงได้ดังนี้ (Gareth et al., 2013)

$$\sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2 \quad (3.4)$$

โดยที่ค่า Residual คือ ค่าความคลาดเคลื่อน หรือค่า Error ระหว่างค่าของตัวแปร y ทุก ๆ จุดในข้อมูล กับค่า $\hat{y}$ ที่ได้มาจากการประมาณค่าการคำนวณ Residual ของข้อมูลตัวที่ i และค่า Residual Sum Of Squares (RSS) คือการวัดค่า Residual หรือ ค่า Error ของทุก ๆ จุดในชุดข้อมูล และนำมายกกำลังสอง เพื่อให้ค่า Residual เป็นบวก และเป็นการทำการ Normalize ของผลลัพธ์ ถ้า $\hat{y}$ มีค่ามากกว่าค่า y จริงจะทำให้ค่า Residual ติดลบ ซึ่งเป็นการหาจุดที่ดีที่สุดในการแบ่งข้อมูล (Split Point) จากการ Minimized ให้ค่า RSS มีค่าน้อยที่สุด

แบบจำลอง Decision Tree กลุ่มที่สองคือ Classification Tree ที่ใช้สำหรับทำ Classification โดยใช้ค่า Gini Impurity ซึ่งแสดงได้ดังสมการด้านล่างดังนี้

$$G = \sum_{k=1}^K \hat{p}_{mk} (1 - \hat{p}_{mk}) \quad (3.5)$$

กำหนดให้ Class ของ Target Variable มีทั้งหมด K Class (กรณีของงานศึกษา นี้จะเป็นกรณี Binary Classification คือ $K=2$) , $\hat{p}_{mk}$ คือ สัดส่วนหรือ % ของ Class ภายในกลุ่ม ถ้าหากในกลุ่ม หรือใน Node ของการเรียนรู้ของแบบจำลองที่แบ่งออกมาได้ สามารถแยกกลุ่มของ Target Variable ออกมาได้ 1 กลุ่มอย่างชัดเจนไม่มีกลุ่มอื่นเจือปนจะทำให้ค่า Impurity = 0 เนื่องจาก ค่า $\hat{p}_{mk}$ ของ Class นั้นจะมีค่าเท่ากับ 1 ซึ่งส่งผลทำให้ค่าในวงเล็บของสมการมีค่าเท่ากับ 0 ส่วน Class อื่นๆ จะมีค่าเท่ากับ 0 หรือทำให้ค่านอกวงเล็บ ของสมการมีค่าเท่ากับ 0 ดังนั้น ค่า Gini Impurity คือ การวัดค่า Impurity หรือ ค่าความไม่บริสุทธิ์ในการอธิบาย Target ของกลุ่มที่ถูกแบ่งออกมาจากตัวแปร แสดงว่าค่า Impurity ยิ่งต่ำก็ยิ่งแบ่งข้อมูลออกมาได้มีประสิทธิภาพ

ค่าที่ใช้ในแบบจำลองแบบ Classification นอกจากค่า Gini Impurity คือค่า Entropy สามารถแสดงได้ดังสมการด้านล่างดังนี้

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk} \quad (3.6)$$

หากกำหนดให้ Class ของ Target Variable มีทั้งหมด K Class (โดยในกรณีของงานศึกษาจะเป็นกรณี Binary Classification คือ $K=2$) , $\hat{p}_{mk}$ คือ สัดส่วนหรือ % ของ Class ภายในกลุ่ม ถ้าหากในกลุ่ม หรือใน Node ของการเรียนรู้ของแบบจำลองที่แบ่งออกมาได้ สามารถแยกกลุ่มของ Target Variable ออกมาได้ 1 กลุ่มอย่างชัดเจนไม่มีกลุ่มอื่นเจือปนจะทำให้ค่า Entropy = 0 เนื่องจาก ค่า $\hat{p}_{mk}$ ของ Class นั้นจะมีค่าเท่ากับ 1 ($\log 1 = 0$) ส่วน Class อื่นๆ

จะมีค่าเท่ากับ 0 หรือทำให้ค่าเอนโทรปีของสมการมีค่าเท่ากับ 0 ค่า Entropy เป็นการวัดความไม่แน่นอน (Randomness) ของข้อมูล

การสร้างแบบจำลอง Classification ที่ต้องการทำนายกลุ่มของ Target Variable ให้แม่นยำ จำเป็นต้องลดความไม่แน่นอน หรือ Randomness ให้น้อยที่สุด หรือกล่าวอีกนัยหนึ่งว่าเป็นการพยายามแยกกลุ่มของ Target Variable ให้ได้สัดส่วนของกลุ่มใดกลุ่มหนึ่งมากที่สุดเพื่อเพิ่มความแน่นอนในการทำนาย (เพิ่ม Certainty ลด Randomness)

แบบจำลอง Random forest เป็นหนึ่งในกลุ่มของแบบจำลองที่เรียกว่า Ensemble Learning ที่มีหลักการคือการพัฒนาแบบจำลองที่เหมือนกันหลายๆ ครั้ง (หลาย Instance) บนข้อมูลชุดเดียวกัน แต่ครั้งของการฝึกสอนแบบจำลองจะเลือกส่วนของข้อมูลที่ใช้ในการพัฒนาแบบจำลองที่ไม่เหมือนกัน แล้วนำการตัดสินใจของแบบจำลองเหล่านั้นมาตัดสินใจว่า Class ไหนถูกเลือกมากที่สุดผ่านแบบจำลองโดยที่กลไกการรวมการตัดสินใจของแบบจำลองหลายแบบจำลองบนเงื่อนไขที่ว่า แบบจำลองแต่ละตัวจะต้องเรียนรู้อย่างเป็นอิสระต่อกันให้มากที่สุด โดยที่ใน Machine Learning Algorithm จะมีวิธีการที่ทำให้การตัดสินใจของแต่ละแบบจำลองเป็นอิสระต่อกัน โดยใช้ Algorithm เดียวกัน แต่ให้แต่ละ Instance เรียนรู้จากส่วนของข้อมูลที่ไม่เหมือนกันโดยใช้การสุ่มเลือก ที่เรียกว่า Bagging ซึ่งสามารถแสดงได้ดังสมการด้านล่างนี้ (Ho, 2002)

$$\hat{f} = \frac{1}{B} \sum_{b=1}^B f_b(x') \quad (3.7)$$

อัลกอริทึมการฝึกสอนสำหรับการทำ Bagging มาใช้กับแบบจำลองแบบต้นไม้ เพื่อสร้างแบบจำลอง Random Forest ตามสมการด้านบนสามารถอธิบายได้ดังนี้ กำหนดให้มีชุดข้อมูลฝึกสอน (Training Dataset)

X พร้อมค่าตัวแปรตาม Y กระบวนการ Bagging จะทำการเลือกสุ่มตัวอย่างซ้ำจากชุดข้อมูลฝึกสอน และสร้างแบบจำลองต้นไม้ให้กับตัวอย่างเหล่านี้

สำหรับ $b = 1, \dots, B$:

สุ่มเลือกชุดข้อมูลฝึกสอน n รายการจาก X, Y โดยมีวิธีการสุ่มเรียกว่า X_b, Y_b

กระบวนการเรียนรู้ของแบบจำลองจะสร้างแบบจำลองต้นไม้การจำแนกหรือการถดถอย f_b บน X_b, Y_b

หลังการฝึกสอน การทำนายสำหรับตัวอย่างที่ไม่เคยเห็น x' สามารถทำได้โดยการหาค่าเฉลี่ยของการทำนายจากแบบจำลองต้นไม้การถดถอยแต่ละต้นบน x'

กระบวนการ Bootstrapping แบบ Bagging ทำให้ประสิทธิภาพของแบบจำลองสูงขึ้น จากการลดความแปรปรวนของแบบจำลอง โดยไม่เพิ่มค่า Bias หรือความอคติของแบบจำลอง ขณะที่การทำนายของแบบจำลองต้นไม้แบบจำลองเดียวมีความแปรปรวนจากความไม่คงที่ของข้อมูล หรือ Noise ในชุดข้อมูลฝึกสอน แต่การที่มีการสร้างค่าเฉลี่ยของแบบจำลองต้นไม้หลายแบบจำลอง จะไม่เป็นเช่นนั้น ตรงกันข้ามที่แบบจำลองต้นไม้เหล่านั้น ไม่มีความสัมพันธ์ซึ่งกัน นอกจากนี้ยังสามารถประมาณความไม่แน่นอนของการทำนายได้จากค่าเบี่ยงเบนมาตรฐานของการทำนายจากแบบจำลองต้นไม้การถดถอยแต่ละต้นบน x' ซึ่งแสดงได้ดังสมการด้านล่างนี้

$$\sigma = \sqrt{\frac{\sum_{b=1}^B (f_b(x') - \bar{f})^2}{B-1}} \quad (3.8)$$

จำนวน B ของตัวอย่างเป็นพารามิเตอร์ที่กำหนดได้ แสดงถึงจำนวนของการทำซ้ำแบบจำลองต้นไม้ที่จะขึ้นอยู่กับขนาดและลักษณะของชุดข้อมูลฝึกสอน B โดยสามารถปรับให้เหมาะสมโดยใช้การตรวจสอบแบบ Cross Validation หรือสังเกตจากค่าความผิดพลาดแบบ Out-of-bag และค่าความผิดพลาด หรือค่า Error ในชุดของข้อมูลการฝึกสอน (Training Set) และข้อมูลที่ใช้ในการทดสอบ (Test Set) จะมีแนวโน้มคงที่เมื่อมีจำนวนต้นไม้ที่เหมาะสม

3.2.3 แบบจำลอง LightGBM

แบบจำลอง LightGBM เป็นหนึ่งในรูปแบบของเทคนิคการทำ Boosting เกิดจากการนำแบบจำลองแบบ Decision Tree มาผ่านกระบวนการเรียนรู้ต่อ ๆ กันหลาย ๆ แบบจำลอง แต่ละแบบจำลองจะเรียนรู้จากข้อผิดพลาดหรือ Error ของแบบจำลองตัวก่อนหน้า ทำให้ความแม่นยำของการทำการพยากรณ์ผลของแบบจำลองจะมีความแม่นยำมากขึ้นแบบต่อเนื่อง เมื่อมีกระบวนการการเรียนรู้ของแบบจำลองต่อเนื่องกันจนมีความลึก (Depth) มากพอ แบบจำลองจะหยุดกระบวนการเรียนรู้เมื่อไม่เหลือรูปแบบ หรือ Pattern ของตัว Error จากแบบจำลองก่อนหน้าให้เรียนรู้ (Friedman, 1999)

ภาพรวมการทำงานของเทคนิค Boosting เป็นกระบวนการที่รวมแบบจำลองย่อย (Weak Classifiers) ซึ่งแต่ละตัวอาจมีประสิทธิภาพไม่สูงมาทำงานร่วมกันในลักษณะเสริมกัน เพื่อให้สามารถจำแนกข้อมูลที่มีความซับซ้อนได้อย่างมีประสิทธิภาพสูงขึ้น ข้อจำกัดของเทคนิค Boosting คือจำเป็นต้องดำเนินการฝึกแบบจำลองในลักษณะเชิงลำดับ (Sequential) และใช้กระบวนการหลายรอบเพื่อให้ได้ผลลัพธ์ที่ดีที่สุด ซึ่งแตกต่างจากเทคนิค Bagging ที่สามารถฝึกแบบจำลองแบบขนาน (Parallel) ได้โดยการสุ่มตัวอย่างข้อมูลแล้วสร้างแบบจำลองแยกกันในแต่ละ

ชุดข้อมูล จากลักษณะดังกล่าว เทคนิค Bagging มีความเหมาะสมในการลดปัญหา Overfitting ในขณะที่ Boosting มีแนวโน้มที่จะช่วยลดอคติ (Bias) ของแบบจำลองได้ดีกว่า

อัลกอริทึม Gradient Boosting Decision Trees (GBDTs) คืออัลกอริทึมสำหรับ Machine Learning ที่พัฒนามาจาก Boosting คือการสร้างต้นแบบเริ่มต้นด้วยต้นไม้ตัดสินใจกับชุดข้อมูล แล้วใช้ต้นแบบที่ได้คาดการณ์ชุดข้อมูลนั้น ทำการปรับปรุงต้นแบบโดยสร้างต้นแบบใหม่จากความผิดพลาดของต้นแบบก่อนหน้า ทำกระบวนการนี้ซ้ำเพื่อพัฒนาประสิทธิภาพของต้นแบบจนได้ต้นแบบสุดท้ายที่มีประสิทธิภาพมากที่สุดโดยสามารถสรุปกระบวนการของอัลกอริทึม Gradient Boosting สำหรับการทำแบบจำลองต้นไม้ด้วยตัวแบบคณิตศาสตร์ได้ดังต่อไปนี้

ขั้นตอนแรกสร้างต้นแบบเริ่มต้นด้วยค่าคาดการณ์คงที่ดังสมการด้านล่าง

$$F_0(x) = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma) \quad (3.9)$$

โดยที่ F_0 คือ ค่าคาดการณ์เริ่มต้น

L คือ ค่า Loss

γ คือ ค่าคาดการณ์ของต้นแบบ

y_i คือ ค่าพยากรณ์ของต้นแบบ

$\arg \min_{\gamma}$ คือ การค้นหาค่า γ ที่ทำให้ค่า Loss มีค่าน้อยที่สุด

ขั้นตอนต่อมาคือขั้นตอนการสร้างต้นแบบโดยเรียนรู้จากความผิดพลาดของต้นแบบก่อนหน้าโดยที่ m คือจำนวนครั้งในการสร้างต้นแบบใหม่ ($m=1$ ถึง M) โดยที่จะคำนวณค่าความผิดพลาด (Residuals) ได้ดังสมการด้านล่าง

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right] \text{ for } i=1, \dots, n \quad (3.10)$$

ทำการสร้างต้นแบบจำลองด้วยอัลกอริทึมต้นไม้ตัดสินใจแบบถดถอยด้วย x กับ r แล้วจะได้ Nodes ที่บ่งบอกถึงค่าคาดการณ์จากต้นแบบ

หลังจากนั้นจะขั้นตอนการคำนวณหาค่าคาดการณ์ของต้นแบบที่ทำให้เกิดค่า Loss น้อยที่สุดเพื่อนำมาปรับปรุงต้นแบบจำลองต่อไปดังสมการ

$$\gamma_{jm} = \arg \min_{\gamma} \sum_{x_i \in R_{jm}} L(y_i, F_{m-1}(x_i) + \gamma), \quad \text{for } j=1, \dots, J_m \quad (3.11)$$

โดยที่ y_{jm} คือ ค่าคาดการณ์ต้นแบบที่ทำให้เกิดค่าผิดพลาดน้อยที่สุด

R คือ โหนดใบ

j คือ ลำดับของโหนดใบ

m คือ ลำดับของต้นไม้ตัดสินใจ (จำนวนครั้งที่พัฒนา)

J คือ จำนวนโหนดใบ

ขั้นตอนสุดท้ายคือการสร้างต้นแบบจำลองใหม่เพื่อพัฒนาประสิทธิภาพของต้นแบบให้ได้แบบจำลองที่มีประสิทธิภาพสูงที่สุดได้ดังสมการด้านล่างนี้

$$F_m(x) = F_{m-1}(x) + v \sum_{j=1}^J y_{jm} \cdot 1(x \in R_{jm}) \quad (3.12)$$

โดยที่

F_m คือ ค่า Loss Function ของลำดับของต้นไม้ตัดสินใจที่ m

F_{m-1} คือ ค่า Loss Function ของลำดับของต้นไม้ตัดสินใจที่ $m-1$ (ใช้ค่า Loss Function ของแบบจำลองก่อนหน้านี้เพื่อหา Local Minimum ของ Loss Function)

v คือ Hyperparameter Learning Rate

ตัวแบบคณิตศาสตร์ข้างต้นแสดงให้เห็นถึงความยืดหยุ่นของอัลกอริทึม GBDTs ซึ่งสามารถรองรับปัญหาได้หลายแบบเช่น หากปัญหานั้นต้องการลดค่า MAE แทนค่า MSE ก็สามารถแทนที่ Loss Function ด้วยเมตริก MAE ได้ ผ่านการปรับค่า Hyperparameters ซึ่งค่า Hyperparameters คือค่าพารามิเตอร์ที่ผู้ใช้งานสามารถกำหนดก่อนสร้างต้นแบบ เช่น Learning Rate ในสมการด้านบน โดยการปรับค่า Hyperparameters จะส่งผลไปยังค่าความแม่นยำของแบบจำลอง ความรวดเร็วในการสร้างแบบจำลอง รวมไปถึงการควบคุมปัญหา Overfitting ได้

3.2.4 การปรับปรุงกระบวนการพยากรณ์เพื่อรองรับปัญหาการกระจายตัวของรายได้และความไม่สมดุลของข้อมูล

การสร้างแบบจำลองเพื่อพยากรณ์รายได้ของครัวเรือนผ่านวิธีการวัดรายได้ทางอ้อม (Proxy Means Test: PMT) ข้อมูลรายได้เฉลี่ยต่อคนต่อเดือนที่ใช้เป็นตัวแปรเป้าหมายแสดงให้เห็นถึงความเหลื่อมล้ำในการกระจายตัวสูง กล่าวคือ ข้อมูลรายได้มีลักษณะแบ่งออกเป็นช่วงที่หนาแน่นในกลุ่มรายได้ต่ำ และบางเบาในกลุ่มรายได้สูงนำไปสู่ปัญหาในการประมาณค่ารายได้ด้วยวิธีถดถอยเชิงเส้น หรือการแบ่งกลุ่ม (Classification) สำหรับครัวเรือนยากจนและไม่ยากจน เนื่องจากแบบจำลองอาจเรียนรู้จากกลุ่มข้อมูลส่วนใหญ่ที่ไม่ใช่ครัวเรือนยากจน ส่งผลให้ค่า

พยากรณ์มีความลำเอียง (Bias) และไม่สามารถสะท้อนสถานะของกลุ่มเป้าหมายที่แท้จริงได้อย่างแม่นยำ

งานวิจัยฉบับนี้จึงได้ดำเนินการปรับปรุงกระบวนการพยากรณ์ผ่านเทคนิคย่อย 2 แนวทาง เพื่อเพิ่มความสามารถในการจำแนกครัวเรือนยากจนได้อย่างมีประสิทธิภาพและลดความเอนเอียงของแบบจำลองดังนี้

3.2.4.1 การตัดช่วงรายได้เพื่อจำกัดความเหลื่อมล้ำในการฝึกแบบจำลอง

การศึกษาทบทวนวรรณกรรมของ Wobcke และ Mariyah (2023) พบว่าการจำกัดขอบเขตของรายได้ในการฝึกแบบจำลองให้อยู่ภายในกลุ่มที่มีรายได้ต่ำสุดร้อยละ 40 (Percentile 40%) ของข้อมูลทั้งหมด ช่วยลดความแปรปรวนของค่ารายได้และลดอิทธิพลของข้อมูลที่อยู่นอกช่วง (Outliers) ได้อย่างมีนัยสำคัญ เทคนิคนี้ถูกนำมาใช้ในงานวิจัยฉบับนี้เพื่อปรับปรุงการฝึกแบบจำลองถดถอยให้สามารถพยากรณ์รายได้เฉลี่ยต่อคนต่อเดือนของครัวเรือนยากจนได้อย่างแม่นยำมากขึ้น โดยไม่ถูกรบกวนด้วยข้อมูลจากครัวเรือนที่ไม่ยากจน

3.2.4.2 การถ่วงน้ำหนักเพื่อจัดการกับปัญหาความไม่สมดุลของข้อมูล (Class Imbalance)

การจำแนกสถานะของครัวเรือนว่ายากจนหรือไม่ยากจน พบว่าในชุดข้อมูลที่ใช้ในการฝึกแบบจำลองนั้น ครัวเรือนยากจนมีสัดส่วนต่ำกว่าครัวเรือนทั่วไปอย่างมาก โดยมีอัตราส่วนเฉลี่ยอยู่ที่ประมาณ 1:19.11 ซึ่งถือเป็นปัญหาความไม่สมดุลของคลาสอย่างมีนัยสำคัญ หากไม่จัดการกับปัญหานี้จะส่งผลให้แบบจำลองให้ความสำคัญกับครัวเรือนที่ไม่ยากจนมากกว่า และละเลยความแม่นยำของการพยากรณ์ครัวเรือนยากจน

เพื่อแก้ไขปัญหานี้ งานวิจัยฉบับนี้จึงได้นำเทคนิคการถ่วงน้ำหนัก (Class Weighting) (Kotsiantis, 2006) ทำหน้าที่ ถ่วงน้ำหนักให้กับแต่ละกลุ่มเป้าหมาย โดยเพิ่มความสำคัญให้กับตัวอย่างจากกลุ่มที่พบน้อย เพื่อให้แบบจำลองไม่เพิกเฉยต่อกลุ่มนั้นมาประยุกต์ใช้ โดยเฉพาะในแบบจำลอง LightGBM ซึ่งสามารถกำหนดค่าน้ำหนักของคลาสน้อยได้โดยตรงผ่านสูตร:

$$W_i = \frac{N_{\text{samples}}}{n_{\text{classes}} \times N_i} \quad (3.13)$$

โดย

N_{samples} แสดงจำนวนข้อมูลที่มีทั้งหมด

n_{classes} แสดงจำนวนคลาสทั้งหมด (ในกรณีนี้คือ 2)

N_i แสดงจำนวนตัวอย่างในคลาส i

ทางคณิตศาสตร์ LightGBM จะนำค่าถ่วงน้ำหนักเหล่านี้ไปใช้คำนวณฟังก์ชันการสูญเสีย (Loss Function) เช่น Binary Cross-entropy หรือ Logistic Loss ดังนี้:

$$L = - \sum_{i=1}^N w_i [y_i \log(p_i) + (1-y_i) \log(1-p_i)] \quad (3.14)$$

โดย

w_i คือค่าน้ำหนักของตัวอย่างที่ i ขึ้นอยู่กับคลาสของ y_i

p_i คือความน่าจะเป็นที่แบบจำลองทำนายว่าค่า $y_i = 1$

การใช้ Class Weight ช่วยเพิ่ม Sensitivity ของแบบจำลองต่อกลุ่มเป้าหมายย่อยที่มีความสำคัญเชิงนโยบาย แต่มีสัดส่วนในข้อมูลต่ำ เช่น ครีวเรือนยากจนพิเศษ ส่งผลให้แบบจำลองสามารถจำแนกและพยากรณ์กลุ่มนี้ได้ อย่างแม่นยำมากขึ้น ลดโอกาสของค่าความผิดพลาดแบบพลาดโอกาส (Exclusion Error)

3.3 วิธีการวัดประสิทธิภาพของแต่ละแบบจำลอง

การประเมินผลการชี้วัดมีความสำคัญกับการทำแบบจำลอง Machine Learning เนื่องจากคือสิ่งที่เอาไว้ชี้วัดว่าแบบจำลองนั้น ๆ ทำงานประสิทธิภาพเป็นอย่างไร ประเมินผลว่าทำงานได้น่าพึงพอใจแล้วหรือไม่ รวมถึงยังไว้ใช้เปรียบเทียบระหว่างแบบจำลองเพื่อตอบคำถามว่าควรเลือกใช้แบบจำลองไหนให้เหมาะสมกับโจทย์ที่จะใช้แบบจำลองนั้น ๆ การวัดผลสำหรับแบบจำลองประกอบไปด้วย 2 ประเภทหลัก ๆ คือ การประเมินผลสำหรับแบบจำลองทางด้าน Classification (จำแนกประเภท) และการประเมินผลสำหรับงานด้านสมการถดถอย (ทำนายค่า) โดยมีรายละเอียดดังนี้

3.3.1 วิธีการวัดประสิทธิภาพของแบบจำลองสมการถดถอย

ในการสร้างแบบจำลองทางสถิติหรือการเรียนรู้ของเครื่อง (Machine Learning) ที่มีวัตถุประสงค์ในการพยากรณ์ค่าต่อเนื่อง เช่น ระดับรายได้ของครัวเรือน หรือดัชนีความยากจนของแต่ละครัวเรือน การวัดความคลาดเคลื่อนระหว่างค่าที่พยากรณ์ได้ (Predicted Values) กับค่าจริง (Actual Values) เป็นสิ่งสำคัญอย่างยิ่ง ดังนั้นการประเมินผลของแบบจำลองพยากรณ์ค่าต่อเนื่องสำหรับแบบจำลองสมการถดถอยจำเป็นต้องพิจารณาตัวชี้วัดข้อผิดพลาด (Error Metrics)

ที่เหมาะสม โดยสองตัวชี้วัดที่นิยมใช้กันอย่างแพร่หลาย ได้แก่ Root Mean Squared Error (RMSE) และ Mean Absolute Error (MAE) มีลักษณะการคำนวณที่แตกต่างกันและสะท้อนความคลาดเคลื่อนในรูปแบบที่แตกต่างกัน

นิยามของ MAE :

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.15)$$

ค่า MAE สามารถคำนวณจากค่าเฉลี่ยของขนาดความคลาดเคลื่อนสัมบูรณ์ (Absolute Error) ระหว่างค่าจริงกับค่าที่พยากรณ์ได้ โดยมีลักษณะให้ “น้ำหนักเท่ากัน” กับทุกจุดข้อมูลที่คลาดเคลื่อนไม่ว่าค่าความคลาดเคลื่อนจะมากหรือน้อย

นิยามของ RMSE :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.16)$$

เมื่อ

y_i แสดงค่าจริงของข้อมูลลำดับที่ i

$\hat{y}_i$ แสดงค่าที่แบบจำลองพยากรณ์ได้ในลำดับที่ i

n แสดงจำนวนข้อมูลทั้งหมด

ค่า RMSE มีค่าน้อยหมายถึงแบบจำลองสามารถพยากรณ์ค่าได้ใกล้เคียงกับความจริงมากขึ้น และถือว่าแบบจำลองมีความแม่นยำสูงในการพยากรณ์ค่าต่อเนื่อง นอกจากนี้ค่า RMSE ยังให้ความสำคัญกับความคลาดเคลื่อนที่มีค่าสูงเนื่องจากการยกกำลังสองของค่าความคลาดเคลื่อน

บริบทของการพยากรณ์เพื่อวิเคราะห์รายได้ครัวเรือน หรือ พยากรณ์คะแนนดัชนีความยากจน การเลือกใช้ค่า RMSE มาใช้ในการเปรียบเทียบประสิทธิภาพของแบบจำลองมีข้อได้เปรียบที่สำคัญเหนือ MAE ในหลายแง่มุมประกอบไปด้วย ประการแรกค่า RMSE เป็นค่าที่ยกกำลังสองค่าความคลาดเคลื่อน ทำให้ความผิดพลาดที่มีขนาดใหญ่ถูกแบบจำลอง “ลงโทษ” มากกว่าความผิดพลาดขนาดเล็ก ซึ่งเหมาะกับการใช้งานที่ต้องการความแม่นยำสูงในกลุ่มที่เปราะบางในกรณีที่ต้องการพิจารณาคุณภาพของแบบจำลองในเชิง “ค่าเฉลี่ยของความเสียหายโดยรวม” (Overall Cost Of Error) เช่น เมื่อความคลาดเคลื่อนนำไปสู่การให้หรือไม่ให้สิทธิ์สวัสดิการค่า RMSE

จะแสดงภาพรวมได้ชัดเจนกว่าค่า MAE ประการที่สามค่า RMSE เป็นตัวชี้วัดที่นิยมใช้ในงานวิจัย ซึ่งเอื้อต่อการนำไปเปรียบเทียบกับผลลัพธ์จากแบบจำลองอื่นๆ ได้ง่ายและเป็นมาตรฐาน รวมทั้งมีลักษณะของฟังก์ชันวัตถุ (Loss Function) ที่เอื้อต่อการเรียนรู้ของแบบจำลองในหลายอัลกอริธึม เช่น LightGBM หรือ XGBoost มักใช้ Mean Squared Error (MSE) เป็นฟังก์ชันวัตถุ ซึ่ง RMSE เป็นรากที่สองของ MSE ทำให้สามารถแปลผลค่าความคลาดเคลื่อนให้อยู่ในหน่วยเดียวกับค่าจริงได้

โดยสรุปค่า RMSE เป็นตัวชี้วัดที่เหมาะสมในการประเมินแบบจำลองสมการถดถอยโดยเฉพาะอย่างยิ่งเมื่อความแม่นยำของค่าทำนายเชิงปริมาณมีนัยสำคัญต่อการตัดสินใจเชิงนโยบาย เช่น การกำหนดเกณฑ์รายได้เพื่อจัดกลุ่มครัวเรือนยากจนหรือกำหนดระดับความช่วยเหลือทางเศรษฐกิจ ค่า RMSE ที่ต่ำแสดงถึงความสามารถของแบบจำลองในการพยากรณ์ที่เชื่อถือได้ ทั้งในแบบจำลอง Random Forest และ LightGBM ที่งานวิจัยชิ้นนี้ใช้ในการวิเคราะห์ โดยในทั้งสองแบบจำลองสามารถอภิปรายการคำนวณค่า RMSE ได้ดังนี้

3.3.1.1 แบบจำลอง Random Forest Regression

Random Forest เป็นแบบจำลองที่ใช้เทคนิคการรวมผล (Ensemble Learning) โดยสร้างต้นไม้การตัดสินใจหลายต้น (Decision Trees) และใช้ค่าเฉลี่ยของผลลัพธ์ที่ได้จากต้นไม้แต่ละต้นในการพยากรณ์ค่า $\hat{y}_i$ การประเมินค่า RMSE สำหรับ Random Forest เป็นกระบวนการคำนวณค่า RMSE จากผลลัพธ์ที่ได้จากแบบจำลองรวม (Aggregated Prediction) ดังนี้

$$\hat{y}_i^{(RF)} = \frac{1}{T} \sum_{t=1}^T \hat{y}_i^{(t)} \quad (3.17)$$

$$RMSE_{RF} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i^{(RF)})^2} \quad (3.18)$$

โดย

T แสดงจำนวนต้นไม้ในป่า

$\hat{y}_i^{(RF)}$ แสดงค่าที่พยากรณ์โดยต้นไม้ต้นที่ t

3.3.1.2 แบบจำลอง Light Gradient Boosting Machine (LightGBM)

LightGBM เป็นแบบจำลองการเรียนรู้แบบเพิ่มพูน (Boosting) ที่พัฒนาจากการรวมต้นไม้การตัดสินใจอย่างมีลำดับ โดยแต่ละต้นไม้จะถูกฝึกเพื่อแก้ไขข้อผิดพลาดจากต้นไม้

ก่อนหน้านี้ ซึ่งทำให้สามารถลดค่า RMSE ได้อย่างมีประสิทธิภาพ ผลลัพธ์การพยากรณ์ของ LightGBM จะเป็นผลรวมของการพยากรณ์จากต้นไม้แต่ละต้นซึ่งสามารถแสดงได้ดังนี้

$$\hat{y}_i^{(LGBM)} = \sum_{t=1}^T f_t(x_i) \quad (3.19)$$

$$RMSE_{LGBM} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i^{(LGBM)})^2} \quad (3.20)$$

โดย

$f_t(x_i)$ แสดงฟังก์ชันการพยากรณ์จากต้นไม้ที่ t ในลำดับที่ i

T แสดงจำนวนรอบของการ Boosting

3.3.2 วิธีการวัดประสิทธิภาพของแบบจำลองจำแนกประเภท

มิติของการวัดผลของแบบจำลองทางด้านการจำแนกประเภทนั้น ต้องเริ่มจากการนิยามมิติของประเภทของการชี้วัด 4 กลุ่มย่อยดังนี้คือ

True Positive (TP): กรณีที่แบบจำลองสามารถจำแนกข้อมูลให้อยู่ในกลุ่มเป้าหมายได้อย่างถูกต้อง ตรงกับค่าจริงที่เป็นไปตามความคาดหวัง

True Negative (TN): กรณีที่แบบจำลองสามารถจำแนกข้อมูลว่าไม่อยู่ในกลุ่มเป้าหมายได้อย่างถูกต้อง ตรงกับค่าจริงที่ไม่อยู่ในความคาดหวัง

False Positive (FP): กรณีที่แบบจำลองจำแนกข้อมูลผิด โดยจัดให้อยู่ในกลุ่มเป้าหมาย ทั้งที่ค่าจริงไม่ได้อยู่ในกลุ่มนั้น (เกิดความคลาดเคลื่อนเชิงบวก)

False Negative (FN): กรณีที่แบบจำลองจำแนกข้อมูลผิด โดยจัดว่าไม่อยู่ในกลุ่มเป้าหมาย ทั้งที่ค่าจริงอยู่ในกลุ่มนั้น (เกิดความคลาดเคลื่อนเชิงลบ)

กรณีศึกษาเพื่อสร้างแบบจำลองการวัดรายได้ทางอ้อม สำหรับการจำแนกครัวเรือนยากจนกับครัวเรือนที่ไม่ใช่ โดยที่คาดหวังว่าแบบจำลองจะจำแนกครัวเรือนยากจน (ให้ครัวเรือนยากจนเป็น Positive และครัวเรือนที่ไม่ยากจนเป็น Negative) หากข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็นครัวเรือนยากจนและแบบจำลองได้ทำนายผลว่าเป็นครัวเรือนยากจน กรณีแบบนี้คือ True Positive (TP) ถ้าหากข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็นครัวเรือนที่ไม่ยากจนและแบบจำลองได้ทำนายผลว่าไม่เป็นครัวเรือนยากจน กรณีแบบนี้คือ True Negative (TN) ถ้าหากข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็นครัวเรือนที่ไม่ยากจนและแบบจำลองได้ทำนายผลว่าเป็นครัวเรือนยากจน กรณีแบบนี้คือ False Positive (FP) ถ้าหากข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็น

ครว้เรือนที่ ยากจนและแบบจำลองได้ ทำนายผลว่าไม่เป็นครว้เรือนยากจนกรณีแบบนี้คือ False Negative (FN) ซึ่งโดยปกติแล้วจะมีการนำเสนอจำนวน TP FP TN FN เหล่านี้ด้วย Confusion Matrix ดังรูปด้านล่างนี้

ภาพที่ 3.2

Confusion Matrix

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

หมายเหตุ ประมวลผลโดยผู้วิจัย

การวัดค่าของแบบจำลองว่าทำนายได้ถูกต้องหรือไม่ผ่านการวัดค่าความแม่นยำของแบบจำลองหรือค่า Accuracy แสดงดังสูตรคำนวณด้านล่าง

$$\text{Accuracy} = (TP + TN) / (TP + FP + TN + FN)$$

การชี้วัดโดยการใช้ค่าความแม่นยำมีปัญหาอยู่สองประการ ประการแรกถ้าเป็นการจำแนกประเภทที่มากกว่า 2 กลุ่มขึ้นไปวิธีนี้จะไม่สามารถวัดค่าความแม่นยำบนแต่ละกลุ่มได้ และประการที่สองถ้าชุดข้อมูลที่มีทั้งสองกลุ่มมีขนาดของทั้งสองกลุ่มเบ้ไปที่กลุ่มใดกลุ่มหนึ่งมากเกินไปจะส่งผลให้ผลลัพธ์ของวิธีนี้ผิดพลาดได้ เช่น ชุดข้อมูลมีกลุ่มครว้เรือนที่ไม่ยากจนมากกว่ากลุ่มครว้เรือนยากจนเป็นสัดส่วน 80:20 ส่งผลให้ค่าความแม่นยำของแบบจำลองสูงเพราะตัวปลายทางของการทำนายของแบบจำลองเองก็มีแต่ครว้เรือนที่ไม่ยากจนเป็นส่วนใหญ่ จึงทำให้ไม่ทราบเลยว่าแบบจำลองสามารถแบ่งกลุ่มได้มีประสิทธิภาพหรือไม่

การชี้วัดที่ชุดข้อมูลไม่มีความสมดุลเช่นข้อมูลรายได้ของครว้เรือนที่มีความเหลื่อมล้ำของรายได้จำเป็นต้องใช้ค่าอื่นในการชี้วัดผ่านค่า Precision และค่า Recall

$$\text{Precision} = TP / (TP + FP)$$

$$\text{Recall} = TP / (TP + FN)$$

ค่า Precision มองในมุมว่าแบบจำลองทำนายได้แม่นยำแค่ไหนในค่าที่สนใจ เช่น ในผลการทำนายที่เป็นครัวเรือนยากจนทั้งหมดแบบจำลองจะทำนายว่าเป็นครัวเรือนยากจนได้อย่างถูกต้องมากน้อยแค่ไหน ในขณะที่ค่าของ Recall มองในมุมว่าแบบจำลองทำนายได้ถูกต้องแค่ไหน เช่น ในผลการทำนายที่ทั้งถูกและผิดแบบจำลองทำนายว่าเป็นครัวเรือนยากจนได้อย่างถูกต้องมากน้อยแค่ไหน ซึ่งการปรับค่าทั้งสองค่าต้องเลือกกว่าจะเพิ่มประสิทธิภาพของแบบจำลองแบบไหน กรณีของการหาครัวเรือนยากจนนโยบายต้องการหาคนจนให้ได้มากที่สุด โดยที่ทางนโยบายยอมรับได้กับการที่มีครัวเรือนที่ไม่ใช่ยากจนปะปนมาด้วยสามารถใช้ค่า Recall เป็นหลัก แต่ถ้าหากนโยบายต้องการหาเฉพาะคนยากจนเท่านั้นไม่ต้องการที่จะต้องการที่จะมีคนที่ไม่ใช่ยากจนปะปนเข้ามา และยอมรับได้กับการที่จะมีครัวเรือนยากจนหลุดออกไปจากนโยบาย จะใช้ค่า Precision ในการชี้วัดแบบจำลองเป็นหลัก นอกจากการชี้วัดแบบจำเพาะในแต่ละกรณีแล้วนั้นยังสามารถชี้วัดแบบจำลองผ่านค่า F1-Score โดยมีสูตรการคำนวณดังนี้

$$F1\text{-Score} = 2 * ((\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall}))$$

การเลือกว่าแบบจำลองไหนมีประสิทธิภาพมากกว่าจำเป็นจะต้องมีค่าที่ใช้สำหรับตัดสินใจได้ ผ่านการนำ Precision และ Recall มาหาค่าเฉลี่ยแบบฮาร์โมนิก ซึ่งยิ่ง 2 ค่านี้สูงก็จะทำให้ F1 สูงตามไปด้วย งานศึกษาครั้งนี้จะชี้วัดแบบจำลองจำแนกผ่านทั้งสามค่า คือ ค่า Precision ค่า Recall และ ค่า F1-score

3.3.3 วิธีการวัดประสิทธิภาพโดยภาพรวมสำหรับทุกแบบจำลอง

งานศึกษาชิ้นนี้มีการใช้แบบจำลองที่มีความหลากหลายไม่ว่าจะเป็น Logistic Regression สำหรับแบบจำลองในการทำไว้เปรียบเทียบประสิทธิภาพ แบบจำลองแบบที่เป็นลักษณะสมการถดถอยเพื่อใช้ในการทำนายรายได้ของครัวเรือน และแบบจำลองประเภทการแยกประเภทครัวเรือนยากจนและครัวเรือนที่ไม่ยากจน การวัดประสิทธิภาพกลางจึงมีความจำเป็นผ่านการใช้ค่า Inclusive Error และค่า Exclusive Error

การกำหนดกลุ่มเป้าหมายครัวเรือนยากจน (Poverty Targeting) เพื่อตัดสินใจว่าครัวเรือนใดควรได้รับสวัสดิการหรือความช่วยเหลือจากรัฐ ความแม่นยำของแบบจำลองไม่ได้เป็นเพียงปัจจัยเดียวที่ต้องพิจารณา แต่ต้องให้ความสำคัญกับประเภทของข้อผิดพลาดที่อาจส่งผลกระทบต่อ *ความยุติธรรม* และ *ประสิทธิภาพของนโยบาย* เพิ่มเติม ผ่านข้อผิดพลาดสองประเภทที่ควรพิจารณาคือ Inclusive Error และ Exclusive Error ซึ่งสามารถเชื่อมโยงกับดัชนีวัดผลของแบบจำลองที่ได้ทำการอภิปรายในส่วนก่อนหน้าอย่าง Precision และ Recall ได้ดังนี้

ค่า Inclusive Error หมายถึง ความผิดพลาดที่เกิดจากการรวมครัวเรือนที่ไม่ยากจนเข้ามาอยู่ในกลุ่มผู้ได้รับสวัสดิการโดยไม่ควร เช่น ครัวเรือนที่มีรายได้เกินเกณฑ์

แต่แบบจำลองทำนายผิดว่าเป็น "ยากจน" จัดอยู่ในกลุ่มของ False Positive (FP) โดยมีความสัมพันธ์กับค่า Precision คือ

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP}) \Rightarrow \text{Inclusive Error} = 1 - \text{Precision}$$

TP: ครั้วเรือนยากจนที่แบบจำลองระบุถูกต้อง

FP: ครั้วเรือนไม่ยากจนที่แบบจำลองระบุผิดว่าเป็นยากจน

ในบริบทเชิงนโยบาย Inclusive Error สะท้อนถึงความเสี่ยงของงบประมาณ (Leakage) และการจัดสรรทรัพยากรที่ไม่ตรงเป้าทำให้ครั้วเรือนที่สมควรได้รับสวัสดิการถูกเบียดบังโดยกลุ่มที่ไม่ควรได้รับ

ค่า Exclusive Error หมายถึง ความผิดพลาดจากการ ละเว้นครั้วเรือนที่ยากจนจริงโดยแบบจำลองทำนายว่าไม่ยากจน จัดอยู่ในกลุ่ม False Negative (FN) ซึ่งสัมพันธ์กับค่า Recall คือ

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN}) \Rightarrow \text{Exclusive Error} = 1 - \text{Recall}$$

FN: ครั้วเรือนยากจนที่แบบจำลองระบุผิดว่าไม่ยากจน

ค่า Exclusive Error ถือเป็นความล้มเหลวด้านความเป็นธรรมเชิงสังคมที่ทำให้ครั้วเรือนยากจนที่สมควรได้รับความช่วยเหลือถูกมองข้ามหรือถูกตัดสิทธิ์โดยไม่ตั้งใจ ข้อผิดพลาดทั้งสองแบบสามารถสรุปได้ดังตารางที่ 3.1

ตารางที่ 3.1

ความเชื่อมโยงของข้อผิดพลาดกับเมตริกการจำแนกและผลกระทบเชิงนโยบาย

ประเภทของข้อผิดพลาด	คำอธิบาย	เมตริกที่เกี่ยวข้อง	ผลกระทบเชิงนโยบายสังคม
Inclusive Error	คัดเลือกครัวเรือน “ไม่ยากจน” มารับสิทธิผิดพลาด	1 – Precision	ทรัพยากรถูกใช้กับกลุ่มที่ไม่ควรได้รับ / งบประมาณรั่วไหล
Exclusive Error	ครัวเรือน “ยากจนจริง” ไม่ได้ได้รับความช่วยเหลือ	1 – Recall	ขาดความเป็นธรรมทางสังคม / กลุ่มเปราะบางถูกตัดสิทธิ์

หมายเหตุ: ประมวลผลโดยผู้วิจัย

การพิจารณาความสมดุลระหว่าง Inclusive และ Exclusive Error เป็นสิ่งสำคัญในการออกแบบนโยบายกำหนดกลุ่มเป้าหมาย โดยหากรัฐบาลมีข้อจำกัดด้านงบประมาณและต้องการลดการรั่วไหล อาจเน้นไปที่การลด Inclusive Error (เพิ่ม Precision) แต่หากต้องการเน้นความครอบคลุมและความยุติธรรมทางสังคมหรือนโยบายอาจเน้นไปที่การลด Exclusive Error (เพิ่ม Recall) ดังนั้น การเลือกแบบจำลองและเกณฑ์ตัดสินใจขึ้นถึงลักษณะเป้าหมายเชิงนโยบายและบริบทของความเสี่ยงต่อความล้มเหลวในการเข้าถึงสิทธิของกลุ่มเปราะบางด้วย

3.4 วิธีการแปลผลการประมาณค่าของแบบจำลอง Machine Learning

นอกเหนือจากการชี้วัดของแบบจำลองแล้วแบบจำลองในลักษณะของ Machine Learning จำเป็นต้องมีการแปลผลนอกเหนือจากสัมประสิทธิ์ของตัวแปรหรือค่า Coefficient โดยในกรณีของแบบจำลองที่มีความซับซ้อนแบบนี้ต้องใช้การแปลผลของการประมาณค่าเพื่อหาค่าทิศทางของค่าตัวแปรผ่านการทำ Shapley Value ซึ่งมีรายละเอียดดังนี้

ค่า Shapley Value จะเป็นการคำนวณภายใต้หลักทฤษฎีเกม (Game Theory) ในรูปแบบทฤษฎีเกมแบบร่วมมือ (Cooperate Game Theory) โดยในหลักการดังกล่าว จะมีการมองค่าของฟีเจอร์หรือตัวแปรในแต่ละตัวเป็น “ผู้เล่น” (Player) ของเกม และผลจากการทำนายของแบบจำลองเป็น “ผลลัพธ์” (Payoff) ของเกม ซึ่งค่า Shapley Value เป็นค่าที่ระบุว่าควรแบ่งผลลัพธ์ของเกมให้แก่ผู้เล่นแต่ละคนอย่างไรให้ยุติธรรมโดยอ้างอิงจากสัดส่วนการมีส่วนร่วม (Contribution) ของผู้เล่นแต่ละคน เมื่อนำหลักการดังกล่าวมาใช้ในการวิเคราะห์แบบจำลอง

ค่านี้จึงสามารถใช้เพื่อบอกว่าแต่ละฟีเจอร์จะส่งผลกระทบต่อการทำนายของแบบจำลองมากหรือน้อย การหาขนาดของผลกระทบค่า Shapley Value สำหรับตัวแปรที่ j ซึ่งแสดงถึงค่าผลกระทบเชิงส่วนเพิ่มของฟีเจอร์นั้นที่มีต่อผลลัพธ์ของแบบจำลอง สามารถเขียนได้ในรูปของสมการด้านล่าง (Tatsuro, 1983) :

$$\varphi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(|N|-|S|-1)!}{|N|!} [f_{S \cup \{j\}}(x_{S \cup \{j\}}) - f_S(x_S)] \quad (3.21)$$

โดยที่

φ_j คือ ค่า Shapley Value ของตัวแปรที่ j

N คือ เซตของตัวแปรทั้งหมด

$S \subseteq N \setminus \{j\}$ คือเซตย่อยของตัวแปรทั้งหมดที่ไม่รวมตัวแปร j

$f_S(x_S)$ คือ ค่าทำนายของแบบจำลองเมื่อพิจารณาเฉพาะตัวแปรในเซต S

$f_{S \cup \{j\}}(x)$ คือ ค่าทำนายของแบบจำลองเมื่อรวมตัวแปร j เข้าไปในเซต S

สมการนี้แสดงถึงค่าเฉลี่ยถ่วงน้ำหนักของความเปลี่ยนแปลงที่เกิดจากการเพิ่มตัวแปร j เข้าไปในทุกเซตย่อยที่เป็นไปได้ของตัวแปรอื่น ๆ โดยค่าน้ำหนักในแต่ละกรณีจะพิจารณาจากจำนวนของชุดข้อมูลย่อยที่สามารถสร้างได้ (Lundberg & Lee, 2017) เมื่อนำค่า Shapley Value ของทุกตัวแปร φ_j มารวมกัน จะได้ค่าที่เท่ากับความแตกต่างระหว่างค่าทำนายของแบบจำลอง สำหรับข้อมูลเฉพาะจุดนั้นกับค่าเฉลี่ยของการทำนายทั้งหมดของแบบจำลอง ซึ่งสะท้อนถึงการอธิบายแบบจำลองเชิงพยากรณ์ในลักษณะการแยกส่วนผลกระทบของแต่ละตัวแปรได้อย่างเป็นระบบ

3.4.1 วิธีการตรวจสอบการอนุมานทางสถิติผ่านการวิเคราะห์แบบ Shapley

Regression

การศึกษานี้ผู้วิจัยได้นำเสนอวิธีการวิเคราะห์ที่เรียกว่า Shapley Regression อ้างอิงจากงานศึกษาของ Buckmann และ Joseph (2023) เป็นเทคนิคที่ผสมผสานคุณสมบัติของแบบจำลอง Machine Learning เข้ากับการวิเคราะห์ทางสถิติแบบดั้งเดิม เพื่อให้สามารถตีความความสัมพันธ์ระหว่างตัวแปรต้นและตัวแปรตามได้อย่างมีความหมายในเชิงเศรษฐมิติ วิธี Shapley Regression เป็นเทคนิคที่นำค่า Shapley Values ที่ได้จากแบบจำลอง Machine Learning มาใช้เป็นตัวแปรอิสระในการวิเคราะห์ถดถอยเชิงเส้น เพื่อประเมินอิทธิพลของแต่ละตัวแปรต่อค่าผลลัพธ์อย่างมีนัยสำคัญทางสถิติ โดยมีขั้นตอนในการวิเคราะห์ดังต่อไปนี้

ขั้นตอนแรกการคำนวณค่า Shapley Values เมื่อได้แบบจำลองที่มีประสิทธิภาพแล้ว จะนำมาใช้ในการคำนวณค่า Shapley Values สำหรับแต่ละตัวแปรในแต่ละข้อมูล ด้วยวิธีการที่อิงจากทฤษฎีเกมเชิงความร่วมมือ (Cooperative Game Theory) ค่า Shapley Value ที่ได้จะสะท้อนถึงอิทธิพลเฉพาะตัวของแต่ละตัวแปรที่มีต่อค่าการพยากรณ์ของแบบจำลอง หลังจากนั้นจะเป็นการจัดรูปแบบข้อมูลสำหรับการวิเคราะห์ถดถอย โดยนำค่าของ Shapley Values ที่ได้จากแต่ละตัวแปรจะถูกจัดรูปแบบให้อยู่ในลักษณะของเมทริกซ์ (Matrix) โดยแถวแทนตัวอย่างข้อมูล และคอลัมน์แทนค่า Shapley ของแต่ละตัวแปร เมทริกซ์นี้จะใช้เป็นชุดข้อมูลใหม่สำหรับการวิเคราะห์ถดถอย และจึงนำค่า Shapley Values เหล่านี้ไปใช้เป็นตัวแปรต้นในการวิเคราะห์ถดถอยเชิงเส้นแบบหลายตัวแปร โดยมีวัตถุประสงค์เพื่อประเมินความมีนัยสำคัญทางสถิติของแต่ละตัวแปรในการอธิบายผลลัพธ์ของแบบจำลอง

รูปแบบของสมการสามารถแสดงได้ดังนี้:

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j \varphi_{ij} + \epsilon_i \quad (3.22)$$

โดยที่:

y_i แทนค่าจริงของตัวแปรเป้าหมายสำหรับข้อมูลตัวอย่างที่ i

φ_{ij} คือค่า Shapley Value ของตัวแปรที่ j สำหรับตัวอย่างที่ i

β_j คือค่าสัมประสิทธิ์ที่แสดงผลกระทบของตัวแปรที่ j

ϵ_i คือค่าความคลาดเคลื่อน (Residual)

แนวทางนี้ช่วยให้สามารถวิเคราะห์ข้อมูลจากแบบจำลองมีลักษณะเป็น “กล่องดำ” ได้ในลักษณะเชิงตีความและตรวจสอบได้เชิงสถิติ ทำให้สามารถระบุได้ว่าตัวแปรใดมีผลกระทบที่มีนัยสำคัญต่อผลลัพธ์ที่คาดการณ์และสามารถนำไปใช้ในการทดสอบสมมติฐานด้วยการวิเคราะห์ความแปรปรวนหรือการทดสอบค่าความมีนัยเชิงสถิติอื่น ๆ ได้อย่างเป็นระบบ ขั้นตอนสุดท้ายคือการทดสอบสมมติฐานของค่าสัมประสิทธิ์ β_j โดยใช้สถิติ t-test เพื่อพิจารณาว่าค่าที่ประมาณได้แตกต่างจากศูนย์อย่างมีนัยสำคัญหรือไม่ หากค่า p-value ต่ำกว่าระดับนัยสำคัญที่กำหนด จะถือว่าตัวแปรดังกล่าวมีอิทธิพลอย่างมีนัยสำคัญ

3.5 ข้อมูลที่ใช้ในการศึกษา

ข้อมูลที่ใช้ในการศึกษาจะประกอบไปด้วยข้อมูล 3 ส่วนคือข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ส่วนภาคครัวเรือน

ข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ส่วนภาคข้อมูลรายบุคคล และข้อมูลคุณลักษณะของจังหวัดต่าง ๆ ในแต่ละส่วนของข้อมูลมีรายละเอียดดังนี้

3.5.1 ข้อมูลส่วนภาคครัวเรือน

ข้อมูลหลักที่ใช้ในงานศึกษาชิ้นนี้จะใช้ข้อมูลการสำรวจประชากรของสำนักงานสถิติแห่งชาติ หรือข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ชุดข้อมูลดังกล่าวทางสำนักงานสถิติแห่งชาติได้มีการจัดทำการสำรวจภาวะเศรษฐกิจและสังคมของครัวเรือนตั้งแต่ปี พ.ศ. 2500 โดยจัดทำทุก 5 ปี แต่เนื่องจากสภาพทางเศรษฐกิจของประเทศมีการขยายตัวอย่างรวดเร็ว และสภาพทางสังคมมีการเปลี่ยนแปลง จึงได้กำหนดให้มีการสำรวจทุก 2 ปี ตั้งแต่ปี พ.ศ. 2530 และจะจัดทำทุกปีตั้งแต่ปี พ.ศ. 2549 เป็นต้นไป

ข้อมูลการสำรวจดังกล่าวถูกนำมาใช้เพื่อเก็บรวบรวมข้อมูลที่สำคัญด้านเศรษฐกิจและสังคมของครัวเรือน เช่น ค่าใช้จ่าย สินทรัพย์ โครงสร้างของสมาชิกในครัวเรือน ลักษณะที่อยู่อาศัย ตลอดจนการได้รับสวัสดิการ/ความช่วยเหลือจากรัฐ และใช้บริการของภาครัฐ เป็นต้น ขอบข่ายและคุ่มรวมของการสำรวจนี้คุ่มรวมครัวเรือนส่วนบุคคล ในทุกจังหวัดทั่วประเทศ ทั้งที่อยู่ในเขตเทศบาลและนอกเขตเทศบาล (ยกเว้น ครัวเรือนทูต ผู้แทนต่างประเทศ และผู้อยู่อาศัยในประเทศไทยชั่วคราว)

ข้อมูลจะประกอบไปด้วยองค์ประกอบหลักทั้งสิ้นสี่ส่วนคือ ส่วนที่ 1 สมาชิกของครัวเรือน ส่วนที่ 2 ลักษณะที่อยู่อาศัย ส่วนที่ 3 ค่าใช้จ่ายสินค้าและบริการ และส่วนที่ 4 ค่าใช้จ่ายอาหาร เครื่องดื่มและยาสูบ ในงานศึกษาชิ้นนี้จะใช้ข้อมูลชุดนี้ของปี พ.ศ. 2566 ข้อมูลลักษณะของครัวเรือนที่จะใช้สามารถแบ่งรายละเอียดได้ดังนี้

สรุปข้อมูลครัวเรือน (Summary of Household Information) ประกอบไปด้วยข้อมูลการทำงานของสมาชิกและสถานะทางเศรษฐกิจของครัวเรือน ข้อมูลจำนวนสมาชิกในครัวเรือน ข้อมูลรายได้ของครัวเรือนเพื่อใช้สำหรับตัดแบ่งครัวเรือนยากจนเพื่อใช้ในการเรียนรู้ของแบบจำลอง และข้อมูลคุณลักษณะของสมาชิกในครัวเรือน เช่น เพศ จำนวนเด็กในครัวเรือน จำนวนผู้พิการ เป็นต้น

ข้อมูลลักษณะที่อยู่อาศัย (Housing Characteristics) ข้อมูลที่ใช้ประกอบไปด้วย ประเภทที่อยู่อาศัย ลักษณะที่อยู่อาศัย สถานภาพการครอบครองที่อยู่อาศัย ค่าเช่าที่อยู่อาศัย ต่อเดือน จำนวนห้องในที่อยู่อาศัย ไฟฟ้าภายในที่อยู่อาศัย จำนวนสมาชิกที่มีการใช้งานอินเทอร์เน็ต เชื้อเพลิงที่ใช้ในการปรุงอาหาร น้ำดื่ม น้ำ ประเภทของสิ่งของต่าง ๆ ที่ใช้ในครัวเรือนที่มีอยู่ใน

ครอบครอง อาทิเช่น เตาอบไมโครเวฟ กระจกต้มน้ำไฟฟ้า กาต้มน้ำไฟฟ้า ตู้เย็น เตาไรต์ไฟฟ้า หม้อหุงข้าวไฟฟ้า เป็นต้น

ข้อมูลค่าใช้จ่ายสินค้าและบริการ (Expenditure on Goods and Services) ประกอบไปด้วยค่าใช้จ่ายด้านการอุปโภคบริโภค เช่นค่าเช่าบ้าน ค่าใช้จ่ายทางการศึกษา ค่าเดินทาง ค่าธรรมเนียมต่าง ๆ

ข้อมูลค่าใช้จ่ายอาหาร เครื่องดื่ม และยาสูบ (Expenditure on Food, Beverages and Tobacco)

ข้อมูลสินทรัพย์ และหนี้สินของครัวเรือน (Assets and Liabilities of Household) ประกอบไปด้วยข้อมูลสองส่วนหลักคือ ข้อมูลมูลค่าสินทรัพย์ของครัวเรือนประกอบด้วย

มูลค่า บ้าน ที่ดิน สิ่งปลูกสร้าง

มูลค่า ยานพาหนะ (ครัวเรือนเป็นเจ้าของ)

มูลค่า สินทรัพย์ทางการเงิน (บาท) สินทรัพย์ทางการเงินเพื่อการออม สินทรัพย์ทางการเงินเพื่อการลงทุน สินทรัพย์อื่นๆ

และข้อมูลภาระทางการเงินของครัวเรือน อาทิเช่น ความสามารถในการกู้ หรือยืมเงินเพื่อทำธุรกิจหรือทำการเกษตร การกู้หรือยืมเงินเพื่อใช้จ่ายฉุกเฉิน และภาวะหนี้สินของครัวเรือน

ข้อมูลการย้ายถิ่นและการส่งเงิน (Migration and Remittance) ว่าในครัวเรือนนั้น ๆ มีการย้ายถิ่นฐาน และถ้ามีการย้ายถิ่นฐานมีการส่งเงินกลับไปหรือไม่

3.5.2 ข้อมูลส่วนบุคคล

ข้อมูลในส่วนของบุคคลใช้ข้อมูลคุณลักษณะรายบุคคลของข้อมูลการสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 นำไปสร้างเป็นตัวแปรเพิ่มเติมให้กับครัวเรือน เพื่อใช้ในการศึกษาเพิ่มเติมโดยข้อมูลจะอยู่ในส่วนของข้อมูลสมาชิกของครัวเรือน (Household Member) ซึ่งประกอบไปด้วย ความสัมพันธ์กับหัวหน้าครัวเรือน เพศ อายุ ศาสนา ลักษณะว่าเป็นผู้พิการหรือไม่ สภาพสมรส สถานะการศึกษา ระดับการศึกษาสูงสุดในครัวเรือน สวัสดิการทางด้านการรักษาพยาบาล การได้รับโครงการช่วยเหลือของรัฐบาลหรือไม่ การได้กู้ยืมเงินจากกองทุนต่าง ๆ หรือไม่ สภาพของการทำงาน และข้อมูลประเภทของอุตสาหกรรมที่ทำงานอยู่

3.5.3 ข้อมูลคุณลักษณะรายจังหวัด

ข้อมูลส่วนสุดท้ายเป็นข้อมูลคุณลักษณะรายจังหวัดที่ใส่เพิ่มเข้าไปในแต่ละครัวเรือนของแต่ละจังหวัดประกอบไปด้วยข้อมูลสามส่วนคือ ข้อมูลสถิติจำนวนประชากร

ของกรมการปกครองกระทรวงมหาดไทย ปี พ.ศ. 2566 ข้อมูลสถิติผลิตภัณฑ์ภาคและจังหวัด
ของสำนักงานสภาพัฒนาการเศรษฐกิจและสังคมแห่งชาติ ปี พ.ศ. 2565 และข้อมูลสถิติโรงงาน
อุตสาหกรรม ของกรมโรงงานอุตสาหกรรม รายจังหวัด ปี พ.ศ. 2566

ตัวแปรที่ใช้ในการศึกษาครั้งนี้ได้จำกัดเฉพาะตัวแปรที่สะท้อนถึงทรัพย์สิน
ภายในครัวเรือน สภาพที่อยู่อาศัย วัสดุที่ใช้ในการก่อสร้างที่พักอาศัย ลักษณะของแหล่งน้ำ
เพื่อการบริโภคและอุปโภค การมีไฟฟ้าและสุขาภิบาล ตลอดจนตัวแปรที่สะท้อนระดับการใช้จ่าย
เฉลี่ยต่อคนภายในครัวเรือน ซึ่งมักถูกใช้ในงานศึกษาที่ผ่านมาเท่านั้น หากแต่ยังสามารถครอบคลุม
ถึงตัวแปรอื่น ๆ ที่มีศักยภาพในการพยากรณ์ฐานะของครัวเรือนได้อีกด้วย เนื่องจากการประยุกต์ใช้
เทคนิค Machine Learning ในการวิเคราะห์ข้อมูลนั้น มีจำเป็นต้องคำนึงถึงปัญหา
ภาวะร่วมเส้นตรงเชิงพหุ (Multicollinearity) อันเป็นข้อจำกัดสำคัญของแบบจำลองเชิงเส้นแบบ
ดั้งเดิม



บทที่ 4

ผลการศึกษา

บทนี้แสดงผลการศึกษาสองรูปแบบจำลองประกอบไปด้วย แบบจำลองที่มีตัวแปรเป้าหมาย (Target variable) สองแบบคือแบบที่เป็นแบบจำลอง Classification ที่แบ่งว่าเป็นครัวเรือนยากจนหรือไม่ยากจนเป็นค่า 0 และ 1 ตามลำดับ และตัวแบบที่สองคือการทำนายค่ารายได้ของครัวเรือนที่มีลักษณะเป็นค่าต่อเนื่อง (Continuous) โดยในทั้งสองแบบจำลองจะมีการเปรียบเทียบผลของแบบจำลองทั้งแบบที่ผ่านเทคนิค LightGBM กับเทคนิค Random Forest และนำผลของแบบจำลอง Machine Learning ที่ได้มาเปรียบเทียบกับแบบจำลอง Logistic Regression ที่เป็น Based-line

4.1 สรุปข้อมูลวิเคราะห์ทางสถิติ

วิทยานิพนธ์ฉบับนี้มีเป้าประสงค์หลักที่จะทำนายหาครัวเรือนยากจนว่าจะเป็นครัวเรือนยากจนหรือไม่ หรือเป็นการทำนายรายได้โดยตรง ดังนั้นค่าสถิติของรายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคนจึงเป็นประเด็นสำคัญซึ่งสามารถสรุปค่าทางสถิติข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ได้ดังตารางที่ 4.1

ตารางที่ 4.1

สรุปค่าสถิติของตัวแปรค่าเฉลี่ยรายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคน


ค่าสถิติ	บาทต่อครัวเรือนต่อเดือน
ค่าต่ำสุด (Min)	0
ค่าสูงสุด (Max)	968,046
ค่ามัธยฐาน (Median)	8,477
ค่าเฉลี่ย (Mean)	12,037
ค่าเบี่ยงเบนมาตรฐาน (SD)	15,195
ควอไทล์ที่ 25 (Q1)	5,336
ควอไทล์ที่ 75 (Q3)	14,009

หมายเหตุ: ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566

ตารางสรุปค่าสถิติพบว่ารายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคนอยู่ที่ประมาณ 12,037 บาท ซึ่งสูงกว่าค่ามัธยฐานที่ 8,477 บาท แสดงให้เห็นว่า ข้อมูลมีการกระจายแบบเบ้ขวา (Right-skewed) กล่าวคือ มีบางครัวเรือนที่มีรายได้สูงมากจนอาจถึงค่าเฉลี่ยขึ้น โดยมีค่าสูงสุดถึง 968,046 บาท และค่าต่ำสุดอยู่ที่ 0 บาท และมีค่าส่วนเบี่ยงเบนมาตรฐานสูง (15,195 บาท) สะท้อนถึงการกระจายตัวของรายได้ที่สูง และควรพิจารณาทำการแปลงข้อมูล (เช่น Log Transform) หรือการตัดกลุ่มรายได้เมื่อนำไปวิเคราะห์ในขั้นต่อไป

ภาพที่ 4.1

ค่าการกระจาย Histogram ของรายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคน



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566

ภาพที่ 4.1 แสดงการกระจายตัวของรายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคน หลังจากตัดรายได้สูงที่สุดที่เปอร์เซ็นต์ไทล์ที่ 95 ขึ้นไปออก พบว่าลักษณะของข้อมูลเบ้ไปทางขวา แสดงถึงการกระจายตัวของรายได้ที่กระจุกตัวในกลุ่มรายได้ไม่สูงมาก ถ้าหากทำการตัดครัวเรือนยากจนจากเกณฑ์รายได้ที่ 3,000 บาทต่อครัวเรือนต่อเดือน (อ้างอิงจากการทบทวนวรรณกรรม)

จะมีจำนวนครัวเรือนทั้งสิ้น 2,598 ครัวเรือนจากทั้งหมด 49,646 ครัวเรือนซึ่งคิดเป็นเพียงร้อยละ 5.23

การสรุปข้อมูลวิเคราะห์ทางสถิติทำให้เห็นว่ารายได้ครัวเรือนเฉลี่ยต่อเดือนต่อคนมีความเหลื่อมล้ำที่สูง ดังนั้นไม่ว่าจะเป็นการพยากรณ์แบบแบ่งกลุ่ม (Classification) หรือการพยากรณ์รายได้ของครัวเรือนโดยตรงจำเป็นต้องมีกระบวนการเพิ่มเติมเพื่อให้การพยากรณ์ของแบบจำลองมีความไม่ Bias ต่อครัวเรือนที่ไม่ยากจนมากเกินไป งานวิจัยชิ้นนี้ปรับแบบจำลองโดยการตัดรายได้และการปรับค่าถ่วงน้ำหนักครัวเรือนยากจน

4.2 แบบจำลองแบบ Classification

การสร้างแบบจำลองแบบ Classification โดยแบ่งตัวแปรเป้าหมายออกเป็นค่า 0 และค่า 1 โดยใช้เกณฑ์ในการคัดกรองคือรายได้ต่ำกว่า 3000 บาทต่อครัวเรือนต่อเดือน ถ้าหากเกินกว่าเกณฑ์ที่กำหนดจะมีค่าเป็น 0 แล้วนำเข้าตัวแบบจำลองโดยแบ่งเป็น Training กับ Test Set ผ่านการทำ K-fold Validation เพื่อหาสัดส่วนของการแบ่ง Train และ Test Set ที่เหมาะสมโดยได้สัดส่วนเป็น 70:30 โดยข้อมูลร้อยละ 70 จะเป็นข้อมูลสำหรับให้ตัวแบบเรียนรู้ ในขณะที่อีกร้อยละ 30 จะใช้เพื่อตรวจสอบประสิทธิภาพของแบบจำลอง

4.2.1 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง

ตารางที่ 4.2

แสดงผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง Random Forest กับ LightGBM แบบ Classification

แบบจำลอง	Precision	Recall	F1-score
Random Forest	0.53	0.33	0.49
LightGBM	0.74	0.62	0.69
LightGBM – ตัดรายได้ครัวเรือนที่ต่ำกว่า 8,000 บาทต่อคนต่อเดือน	0.74	0.65	0.70
LightGBM - ปรับค่าถ่วงน้ำหนัก Class Weight	0.70	0.90	0.79

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ผลการเทียบประสิทธิภาพของแบบจำลอง Random Forest และ LightGBM จะเปรียบเทียบผ่านการใช้ค่า F1-score ซึ่งเป็นค่าที่นำ Precision และ Recall มาหาค่าเฉลี่ยแบบฮาร์โมนิก โดยจะเปรียบเทียบเฉพาะผลการทำนายค่าเฉพาะการทำนายค่าคร้วเรือนยากจนเท่านั้น ผลแบบจำลองแบบ random forest มีค่า F1-score เท่ากับ 0.49 ในขณะที่แบบจำลอง LightGBM จะมีค่าเท่ากับ 0.69 สะท้อนว่าแบบจำลองแบบ LightGBM ได้ผลการทำนายที่มีความแม่นยำกว่า

แบบจำลองการแบ่งกลุ่มแบบ LightGBM ผ่านการปรับค่าถ่วงน้ำหนัก Class Weight จะได้แบบจำลองที่มีประสิทธิภาพสูงที่สุดมีค่า F1-score อยู่ที่ 0.79 และมีค่า Recall ของแบบจำลองที่เพิ่มขึ้นสูง ขณะที่การตัดรายได้คร้วเรือนที่ต่ำกว่า 8,000 บาทต่อคนต่อเดือน ส่งผลให้ประสิทธิภาพของแบบจำลองที่ไม่เพิ่มมากนักเมื่อเทียบกับการสร้างแบบจำลอง LightGBM แบบปกติ ดังนั้นแบบจำลองแบบจำแนก (Classification) จะทำการอภิปรายแค่ผลของแบบจำลองที่ดีที่สุดคือแบบจำลอง LightGBM ผ่านการปรับค่าถ่วงน้ำหนัก Class Weight

4.2.2 อภิปรายผลของแบบจำลอง LightGBM แบบ Classification

ผลของแบบจำลอง Machine Learning ของแบบจำลอง LightGBM แบบ Classification สามารถสรุปผลของแบบจำลองได้ดังนี้

ภาพที่ 4.2

แสดงค่า Confusion Matrix ของแบบจำลอง LightGBM แบบ Classification

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	708	75
	Negative (0)	362	13755

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของคร้วเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ผลของแบบจำลองที่เป็นส่วนของ Test Set สามารถสรุปได้ดังนี้ จากจำนวนข้อมูลทั้งสิ้น 14,900 ครั้วเรือน ค่าตัวแปรเป้าหมาย (Target Label) ถ้ามีค่าเป็น 1 หมายถึงครั้วเรือนยากจน และถ้ามีค่าเป็น 0 หมายถึงไม่ใช่ครั้วเรือนยากจน ค่า True Positive (TP) แสดงข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็นครั้วเรือนที่ยากจนและแบบจำลองได้ทำนายผลว่าเป็นครั้วเรือนยากจนมีทั้งสิ้น 708 ครั้วเรือนจากครั้วเรือนที่เป็นครั้วเรือนยากจนทั้งสิ้น 1,070 ครั้วเรือน ค่า True Negative (TN) แสดงข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็นครั้วเรือนที่ไม่ยากจนและแบบจำลองได้ทำนายผลว่าไม่เป็ครั้วเรือนยากจนมีจำนวนทั้งสิ้น 13,755 ครั้วเรือนจากครั้วเรือนที่ไม่ยากจนทั้งสิ้น 13,830 ครั้วเรือน ส่วนที่สามคือค่า False Negative (FN) แสดงข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็นครั้วเรือนยากจนและแบบจำลองได้ทำนายผลว่าเป็นครั้วเรือไม่ยากจน โดยมีจำนวนทั้งสิ้น 362 ครั้วเรือนจากครั้วเรือนที่แบบจำลองทำนายว่าเป็นครั้วเรือนยากจนทั้งสิ้น 1,070 ครั้วเรือน และส่วนสุดท้ายคือค่า False Positive (FP) แสดงข้อมูลที่ส่งเข้าให้กับแบบจำลองเป็นครั้วเรือนที่ไม่ยากจนและแบบจำลองได้ทำนายผลว่าเป็นครั้วเรือนยากจนมีจำนวนทั้งสิ้น 75 ครั้วเรือน จากครั้วเรือนที่ไม่เป็ครั้วเรือนยากจนทั้งสิ้น 13,830 ครั้วเรือน จากผลของค่า Confusion Matrix สามารถสร้างเป็นค่าสรุปผลของแบบจำลองได้ดังนี้

ภาพที่ 4.3

แสดงค่าสรุปผลของแบบจำลอง LightGBM แบบ Classification

	precision	recall	f1-score	support
0	0.99	0.98	0.99	14117
1	0.70	0.90	0.79	783
accuracy			0.97	14900
macro avg	0.85	0.94	0.89	14900
weighted avg	0.98	0.97	0.98	14900

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครั้วเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง


ภาพที่ 4.3 ค่า 1 หมายถึงการทำนายกลุ่มครั้วเรือนยากจน ค่า 0 หมายถึงการทำนายว่าไม่ใช่ครั้วเรือนยากจน ค่า Precision สะท้อนแบบจำลองว่าทำนายได้แม่นยำแค่ไหนในค่าที่สนใจ โดยในส่วนของผลการทำนายที่เป็นครั้วเรือนยากจน (Label เป็น 1) พบว่าแบบจำลองมีความแม่นยำอยู่ที่ร้อยละ 70 แสดงถึงจากจำนวนครั้วเรือนยากจนทั้งสิ้น 100 ครั้วเรือนแบบจำลอง

จะสามารถทายครัวเรือนยากจนได้ถูกต้องทั้งสิ้น 70 ครัวเรือน หรือมีค่า Inclusion Error เท่ากับ $1-0.7 = 0.3$ ในขณะที่ผลการทำนายที่เป็นครัวเรือนไม่ยากจน (label เป็น 0) พบว่าแม่นยำอยู่ที่ร้อยละ 99 แสดงถึงจากจำนวนครัวเรือนไม่ยากจนทั้งสิ้น 100 ครัวเรือน แบบจำลองจะสามารถทายครัวเรือนไม่ยากจนได้ถูกต้องทั้งสิ้น 99 ครัวเรือน

ค่าของ Recall สะท้อนแบบจำลองว่าทำนายได้ถูกต้องแค่ไหน ในผลการทำนายที่ทั้งถูกและผิด โดยในส่วนของการทำนายที่เป็นครัวเรือนยากจน (Label เป็น 1) พบว่าแบบจำลองมีความแม่นยำอยู่ที่ร้อยละ 90 แสดงถึงจากจำนวนครัวเรือนยากจนทั้งสิ้น 100 ครัวเรือน แบบจำลองจะสามารถทายครัวเรือนยากจนได้ครอบคลุมทั้งสิ้น 90 ครัวเรือน ซึ่งคิดเป็นค่า Exclusion error อยู่ที่ $1-0.9 = 0.1$ ในขณะที่ผลการทำนายครัวเรือนไม่ยากจน (Label เป็น 0) พบว่าแม่นยำอยู่ที่ร้อยละ 98 แสดงถึงจากจำนวนครัวเรือนไม่ยากจนทั้งสิ้น 100 ครัวเรือนแบบจำลองจะสามารถทายครัวเรือนไม่ยากจนได้ครอบคลุมทั้งสิ้น 98 ครัวเรือน แบบจำลองในงานศึกษาชิ้นนี้ไม่ได้ปรับแต่งแบบจำลองให้เน้นไปที่ค่าใดค่าหนึ่งแบบชัดเจนแต่เน้นไปที่ค่า F1-score เพื่อหาค่าเหมาะสมระหว่างค่า Precision และ Recall แสดงได้ดังภาพที่ 4.4

ภาพที่ 4.4

การตัดสินใจของแบบจำลองผ่านค่า Precision และ Recall



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

แบบจำลองนี้ได้ค่า Macro Precision อยู่ที่ 0.85 และ ค่า Macro Recall อยู่ที่ 0.94 มีค่าเฉลี่ยของค่า F1-score อยู่ที่ร้อยละ 89 โดยความแม่นยำของแบบจำลองในการทายว่าเป็นครัวเรือนยากจนจะมีความแม่นยำน้อยกว่าการเลือกว่าเป็นครัวเรือนไม่ยากจน (0.99 เปรียบเทียบกับ 0.70) เนื่องจากการสร้างแบบจำลองมีชุดข้อมูลจำนวนครัวเรือนที่เป็นครัวเรือนยากจนมีจำนวนน้อยกว่าครัวเรือนไม่ยากจนมากถึงแม้จะมีการใช้เทคนิคถ่วงน้ำหนักแล้วก็ตาม


4.2.3 อภิปรายผลของแบบจำลอง LightGBM แบบ Classification ผ่านค่า SHAP

4.2.3.1 อภิปรายของของแต่ละตัวแปรผ่านค่า SHAP

การอภิปรายผลของแต่ละตัวแปรผ่านค่า SHAP สามารถแสดงได้ดังรูปด้านล่างนี้โดยจะทำการอภิปรายเฉพาะตัวแปรที่ส่งผลมากที่สุด 20 ตัวแรก เพื่อให้การอภิปรายผลสามารถอภิปรายผลได้ง่ายมากขึ้นทางผู้วิจัยได้ทำการปรับค่า SHAP จากค่าดิบ (Raw) เป็นค่าความน่าจะเป็นในช่วงระหว่าง 0-1 แทน โดยถ้าค่าเข้าใกล้ค่า 0 หมายถึงมีโอกาสจะไม่เป็นครัวเรือนยากจนมากยิ่งขึ้น ในขณะที่ถ้ามีค่าเข้าใกล้ 1 จะส่งผลทำให้มีโอกาสที่จะเป็นครัวเรือนยากจนเพิ่มมากขึ้น

ภาพที่ 4.5

แสดงค่า SHAP ของแบบจำลอง Classification ของ LightGBM โดยที่เลือกตัวแปรที่สำคัญ 20 อันดับแรก



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ตัวแปรที่ส่งผล 20 อันดับแรกของแบบจำลอง LightGBM ที่มีความสำคัญต่อการทำนายครัวเรือนยากจนสามารถเรียงความสำคัญจากมากไปน้อยได้ดังนี้ จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1), จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05), จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11), ค่าเช่าบ้านต่อเดือน (HH05), จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06), อายุของหัวหน้าครัวเรือน (C02), จำนวนหลอดตะเกียบ (HH44), จำนวนสมาชิกในครัวเรือนรวม (A04), เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19), จำนวนหลอดไฟนีออน (HH42), เป็นเจ้าของรถมอเตอร์ไซด์หรือไม่ (HH17), จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05), จำนวนเครื่องปรับอากาศ (HH35), จำนวนสมาร์ตโฟน (HH41), เชื้อเพลิงที่ใช้ในการปรุงอาหาร (HH10), จำนวนหลอด LED (HH45), จำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้น (C24), จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10), จำนวนห้องที่อยู่อาศัยทั้งหมด (HH07) และจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาว (C25)

จากภาพที่ 4.5 สามารถอภิปรายผลของแต่ละตัวแปรผ่านค่า SHAP ในภาพรวมได้ดังนี้

จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1) ถ้าหากจำนวนในครัวเรือนรวมยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะเป็นครัวเรือนยากจนเพิ่มมากขึ้น ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีจำนวนที่น้อยจะมีโอกาสที่จะไม่ใช่ครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05) ถ้าหากจำนวนในครัวเรือนที่ทำงานและได้รับค่าจ้างยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่ทำงานและได้รับค่าจ้างมีจำนวนที่น้อยหรือไม่มีเลยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11) ถ้าหากจำนวนสมาชิกที่มีสิทธิบัตรทองยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะเป็นครัวเรือนยากจนเพิ่มมากขึ้น ในขณะที่ถ้าจำนวนสมาชิกที่มีสิทธิบัตรทองมีจำนวนที่น้อยจะมีโอกาสที่จะไม่ใช่ครัวเรือนยากจนมากขึ้น

ค่าเช่าบ้านต่อเดือน (HH05) ถ้าหากค่าเช่าบ้านต่อเดือนมีค่าเช่าที่เพิ่มขึ้นจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าค่าเช่าบ้านต่อเดือนมีค่าเช่าที่น้อยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06) ถ้าหากจำนวนในครัวเรือนที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรยังมีจำนวน

ที่มากจะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรมีจำนวนที่น้อยหรือไม่มีเลย จะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

อายุของหัวหน้าครัวเรือน (C02) ถ้าหากครัวเรือนมีหัวหน้าครัวเรือนที่มีอายุไม่มากจะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีหัวหน้าครัวเรือนที่อายุมากจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนหลุดตะเกียบ (HH44) ถ้าหากครัวเรือนมีจำนวนหลุดตะเกียบที่มากจะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีจำนวนหลุดตะเกียบที่น้อยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกในครัวเรือนรวม (A04) ถ้าหากจำนวนในครัวเรือนรวมยังมีจำนวนที่มากจะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะเป็นครัวเรือนยากจนเพิ่มมากขึ้น ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีจำนวนที่น้อยจะมีโอกาสที่จะไม่ใช่ครัวเรือนยากจนมากขึ้น

เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19) ถ้าหากครัวเรือนเป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้ จะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนไม่เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้ จะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนหลอดไฟนีออน (HH42) ถ้าหากครัวเรือนมีจำนวนหลอดไฟนีออนที่มากจะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีจำนวนหลอดไฟนีออนที่น้อยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

เป็นเจ้าของรถมอเตอร์ไซด์หรือไม่ (HH17) ถ้าหากครัวเรือนเป็นเจ้าของรถมอเตอร์ไซด์ จะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนไม่เป็นเจ้าของรถมอเตอร์ไซด์จะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05) ปี ถ้าหากจำนวนในครัวเรือนมีอายุน้อยกว่า 15 ปียังมีจำนวนที่มากจะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะเป็นครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีอายุน้อยกว่า 15 ปีมีจำนวนที่น้อยจะมีโอกาสที่จะไม่ใช่ครัวเรือนยากจนมากขึ้น

จำนวนเครื่องปรับอากาศ (HH35) ถ้าหากครัวเรือนมีเครื่องปรับอากาศ จะยังเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนไม่มีเครื่องปรับอากาศ จะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาร์ตโฟน (HH41) ผลของตัวแปรนี้ถ้าหากมองการกระจายตัวแล้วผลมีความกระจายตัวสูงโดยรายละเอียดจะแสดงในส่วนถัดไป

เชื้อเพลิงที่ใช้ในการปรุงอาหาร (HH10) ถ้าหากครัวเรือนไม่ได้ประกอบอาหารจะมีแนวโน้มที่ครัวเรือนนั้น ๆ มีแนวโน้มที่จะไม่ใช่ครัวเรือนยากจนเพิ่มมากขึ้น ในขณะที่ถ้าครัวเรือนนั้นประกอบอาหารโดยใช้เชื้อเพลิงประเภทต่าง ๆ จะยังมีแนวโน้มที่ครัวเรือนนั้นจะเป็นครัวเรือนยากจน

จำนวนหลอด LED (HH45) ถ้าหากครัวเรือนมีจำนวนหลอด LED ที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีจำนวนหลอด LED ที่น้อยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้น (C24) ถ้าหากจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้นยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่สมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้นที่น้อยหรือไม่มีเลยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10) ถ้าหากจำนวนในครัวเรือนที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ ยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจมีจำนวนที่น้อยหรือไม่มีเลยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น


จำนวนห้องที่อยู่อาศัยทั้งหมด (HH07) ถ้าหากครัวเรือนมีจำนวนห้องที่อยู่อาศัยทั้งหมดที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีจำนวนห้องที่อยู่อาศัยทั้งหมดที่น้อยหรือไม่มีเลยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

จำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาว (C25) ถ้าหากจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาวยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นจะไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่สมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาวที่น้อยหรือไม่มีเลยจะมีโอกาสที่จะเป็นครัวเรือนยากจนมากขึ้น

นอกเหนือจากการอธิบายผลกระทบของแต่ละตัวแปรผ่านภาพรวมของค่า SHAP ในภาพรวมข้างต้นไปแล้ว ยังสามารถอธิบายผลของการใช้ SHAP ผ่านการสร้างกราฟแบบ Scatter Plot เพื่อดูผลของแต่ละตัวแปรผ่านค่า SHAP แบบละเอียดของแต่ละตัวแปรได้ แต่ละตัวแปรสามารถอธิบายผลของ SHAP โดยละเอียดได้ดังนี้

ภาพที่ 4.6

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.6 ในภาพรวมถ้าหากจำนวนในครัวเรือนรวมยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นเป็นครัวเรือนยากจนเพิ่มมากขึ้นในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีจำนวนที่น้อยจะมีโอกาสที่ไม่ใช่ครัวเรือนยากจนมากขึ้น แต่การวิเคราะห์เชิงลึกพบว่าถ้าหากจำนวนสมาชิกดังกล่าวมีไม่เกิน 2 คนมีโอกาสที่จะไม่ใช่ครัวเรือนยากจน แต่ถ้าหากเกินตั้งแต่สามคนขึ้นไปจะเริ่มมีโอกาสเป็นครัวเรือนยากจนมากขึ้น

ภาพที่ 4.7

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.7 ในภาพรวมถ้าหากจำนวนในครัวเรือนที่ทำงานและได้รับค่าจ้างยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่ทำงานและได้รับค่าจ้างมีจำนวนที่น้อยหรือไม่มีเลยมีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น โดยที่ถ้าไม่มีเลยมีโอกาสจนมากที่สุดถ้าเริ่มมีมากขึ้นมีโอกาสจนน้อยลงไปเรื่อย ๆ จนมากที่สุดที่มีจำนวนสมาชิกที่ได้รับค่าจ้างเท่ากับสามคน และโอกาสที่ไม่ใช่ครัวเรือนยากจนจากตัวแปรดังกล่าวจะเริ่มลดลงเมื่อสี่คนเป็นต้นไป

ภาพที่ 4.8

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.8 ถ้าหากจำนวนสมาชิกที่มีสิทธิบัตรทองยังมีจำนวนที่มากจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นเป็นครัวเรือนยากจนเพิ่มมากขึ้นในขณะที่ถ้าจำนวนสมาชิกที่มีสิทธิบัตรทองมีจำนวนที่น้อยมีโอกาสที่ไม่ใช่ครัวเรือนยากจนมากขึ้น โดยถ้าจำนวนสมาชิกที่มีสิทธิบัตรทองมีในช่วง 0-1 คน มีโอกาสเป็นครัวเรือนที่จนน้อยกว่า และผลเริ่มส่งผลกลับด้านเป็นครัวเรือนยากจนเพิ่มขึ้นตั้งแต่สองคนขึ้นไปจนถึง 7 คนต่อครัวเรือน

ภาพที่ 4.9

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของค่าเช่าบ้านต่อเดือน (HH05)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.9 ถ้าหากค่าเช่าบ้านต่อเดือนมีค่าเช่าที่เพิ่มสูงขึ้นจะยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน โดยที่จากกราฟดังกล่าวแสดงค่าเช่าถึงไม่เกิน 40,000 บาทต่อเดือนเพื่อให้่ายต่อการวิเคราะห์ ถ้าค่าเช่าบ้านต่อเดือนมีค่าเช่าที่น้อยมีโอกาที่จะเป็นครัวเรือนยากจนมากขึ้น และเริ่มไม่ส่งผลเมื่อค่าเช่าบ้านต่อเดือนอยู่ในช่วง 10,000 บาทขึ้นไป ถ้าไม่มีค่าเช่าบ้าน (มีค่าเท่ากับ 0) ผลกระทบเป็นได้ทั้งทางบวกและทางลบขึ้นอยู่กับปัจจัยอื่น ๆ อาทิเช่น เป็นเจ้าของบ้านของตนเองก็มีแนวโน้มไม่ใช่ครัวเรือนยากจน หรือถ้าหากไม่มีที่อยู่เป็นหลักแหล่งก็มีแนวโน้มเป็นครัวเรือนยากจน เป็นต้น

ภาพที่ 4.10

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรกร (A06)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ภาพที่ 4.10 ถ้าหากจำนวนในครัวเรือนที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรยังมีจำนวนที่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรมีจำนวนที่น้อยหรือไม่มีเลยมีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น ถ้าไม่มีเลยมีแนวโน้มเป็นครัวเรือนยากจนมากที่สุด ถ้าเริ่มมี 1 คนเป็นต้นไปส่งผลต่อโอกาสที่ไม่ใช่ครัวเรือนยากจนมากที่สุด และผลเริ่มลดลงไปจนถึง 4 คน

ภาพที่ 4.11

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของอายุของหัวหน้าครัวเรือน (C02)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ภาพที่ 4.11 ถ้าหากครัวเรือนมีหัวหน้าครัวเรือนที่มีอายุไม่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีหัวหน้าครัวเรือนที่อายุมากมีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น โดยเกณฑ์กลางของอายุที่ใช้ในการแบ่งเกณฑ์อยู่ที่ประมาณอายุ 40 ปี ถ้าหากเริ่มอายุมากกว่า 40 เป็นต้นไปมีแนวโน้มที่เป็นครัวเรือนยากจนมากกว่า แต่ทั้งนี้ต้องสอดคล้องกับจำนวนสมาชิกในครัวเรือนด้วย

ภาพที่ 4.12

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนหลอดตะเกียบ (HH44)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.12 จำนวนหลอดตะเกียบ ถ้าหากครัวเรือนมีจำนวนหลอดตะเกียบที่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีจำนวนหลอดตะเกียบที่น้อยมีโอกาที่เป็นครัวเรือนยากจนมากขึ้น โดยผลกระทบทางบวกเริ่มส่งผลตั้งแต่ 1 หลอดเป็นต้นไป

ภาพที่ 4.13

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกในครัวเรือนรวม (A04)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.13 ถ้าหากจำนวนในครัวเรือนรวมยังมีจำนวนที่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นเป็นครัวเรือนยากจนเพิ่มมากขึ้น ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีจำนวนที่น้อยมีโอกาสน้อยที่ครัวเรือนยากจนมากขึ้น ถ้าหากสมาชิกในครัวเรือนรวมไม่เกิน 2 คน จะมีแนวโน้มไม่ใช่ครัวเรือนยากจน แต่ถ้าเกินตั้งแต่สามคนขึ้นไปเริ่มมีโอกาเป็นครัวเรือนยากจน แต่ทั้งนี้ขึ้นอยู่กับสัดส่วนของตัวแปรอื่น ๆ ด้วย

ภาพที่ 4.14

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของเป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ภาพที่ 4.14 ถ้าหากครัวเรือนเป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้เพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนไม่เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้ มีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น ถ้าไม่มีเลยเป็นครัวเรือนยากจน แต่ถ้าเริ่มมี 1 คันต่อครัวเรือนเพิ่มโอกาสที่ไม่ใช่ครัวเรือนยากจนมากขึ้น และถ้าเริ่มมีมากกว่า 2 คัน เป็นต้นไปผลยังเป็นบวกแต่ส่งผลน้อยกว่าเมื่อเปรียบเทียบกับมีเพียง 1 คัน

ภาพที่ 4.15

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนหลอดไฟนีออน (HH42)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.15 ถ้าหากครัวเรือนมีจำนวนหลอดไฟนีออนที่มากเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนมีจำนวนหลอดไฟนีออนที่น้อย มีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น โดยผลกระทบเริ่มส่งผลต่อโอกาสที่ไม่ใช่ครัวเรือนยากจนเมื่อจำนวนหลอดไฟมีตั้งแต่ 7 ดวงต่อครัวเรือนเป็นต้นไป และเพิ่มขึ้นเรื่อย ๆ โดยที่ถ้าหากจำนวนหลอดไฟมากกว่า 12 ดวงเป็นต้นไปผลกระทบเริ่มน้อยลง

ภาพที่ 4.16

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของเป็นเจ้าของรถยนต์ใช้หรือไม่ (HH17)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.16 ถ้าหากครัวเรือนเป็นเจ้าของรถยนต์ไฮบริด ยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนไม่เป็นเจ้าของรถยนต์ไฮบริดมีโอกาที่เป็นครัวเรือนยากจนมากขึ้น โดยผลกระทบเริ่มมีตั้งแต่สองคนขึ้นไป แต่ทั้งนี้ ผลกระทบน้อยลงเมื่อมีมากกว่า 4 คนขึ้นไป นอกจากนี้ครัวเรือนที่มีมอเตอร์ไซด์ในช่วง 0 ถึง 1 คัน มีโอกาสเป็นครัวเรือนยากจนสูงขึ้น

ภาพที่ 4.17

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.17 ถ้าหากจำนวนในครัวเรือนมีอายุน้อยกว่า 15 ปี ยังมีจำนวนที่มากยิ่งเพิ่มโอกาสที่ครัวเรือนเป็นครัวเรือนยากจน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีอายุน้อยกว่า 15 ปีมีจำนวนที่น้อยมีโอกาที่ไม่ใช่ครัวเรือนยากจนมากขึ้น ถ้าหากมีจำนวนสมาชิกในครัวเรือนมีอายุน้อยกว่า 15 ปี ส่งผลกระจายทั้งบวกและลบ ในขณะที่ไม่มีเลยมีแนวโน้มไม่ใช่ครัวเรือนยากจนมากที่สุด แต่ถ้ามีมากกว่าสองคนเป็นต้นไปมีแนวโน้มเป็นครัวเรือนยากจนที่มากกว่า

ภาพที่ 4.18

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนเครื่องปรับอากาศ (HH35)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ภาพที่ 4.18 ถ้าหากครัวเรือนมีเครื่องปรับอากาศเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจนสูงมากขึ้น แต่ถ้าเริ่มมี 1 เครื่องเป็นต้นไปผลกระทบเริ่มลดลง ในขณะที่ถ้าครัวเรือนไม่มีเครื่องปรับอากาศมีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น

ภาพที่ 4.19

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาร์ทโฟน (HH41)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.19 ผลของจำนวนสมาร์ทโฟนต่อความยากจนของครัวเรือน มีผลกระจาย ถ้าหากมี 0 เครื่องมีโอกาสที่ไม่ใช่ครัวเรือนยากจน ถ้าอยู่ที่ช่วง 1-2 เครื่องเพิ่มโอกาสในการเป็นครัวเรือนยากจน และเริ่มส่งผลให้มีโอกาสไม่ใช่ครัวเรือนยากจนตั้งแต่ 3 เครื่องเป็นต้นไป

ภาพที่ 4.20

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของเชื้อเพลิงที่ใช้ในการปรุงอาหาร (HH10)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.20 ถ้าหากครัวเรือนไม่ได้ประกอบอาหารมีแนวโน้มที่ครัวเรือนนั้น ๆ ไม่ใช่ครัวเรือนยากจน ในขณะที่ถ้าครัวเรือนนั้นประกอบอาหารโดยใช้เชื้อเพลิงประเภทต่าง ๆ มีแนวโน้มที่ครัวเรือนนั้นเป็นครัวเรือนยากจน โดยผลของครัวเรือนที่ใช้แก๊สในการปรุงอาหารมีจำนวนครัวเรือนที่ใช้มากที่สุดแต่ผลต่อการเป็นครัวเรือนยากจนมีแนวโน้มที่ไม่ใช่ครัวเรือนยากจนมากกว่า

ภาพที่ 4.21

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนหลอดไฟนีออน (HH45)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.21 ถ้าหากครัวเรือนมีจำนวนหลอดไฟ LED ที่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจนเมื่อจำนวนหลอดไฟมีตั้งแต่ 2 ดวงต่อครัวเรือนเป็นต้นไป และหากจำนวนหลอดไฟ LED มากกว่า 6 ดวงเป็นต้นไปผลกระทบจะเริ่มลดลง

ภาพที่ 4.22

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้น (C24)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.22 ถ้าหากจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้น อาทิเช่น โครงการคนละครึ่ง มีจำนวนที่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน แต่ผลจะลดลงตามจำนวนสมาชิกในครัวเรือนที่เพิ่มไปตั้งแต่ 3 คนเป็นต้นไป ในขณะที่ถ้าหากจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้นไม่มีเลยมีโอกาasที่เป็นครัวเรือนยากจนมากขึ้น

ภาพที่ 4.23

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.23 ถ้าหากจำนวนในครัวเรือนที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจยังมีจำนวนที่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน แต่ผลจะเริ่มลดลงตามจำนวนคนที่เพิ่มตั้งแต่ 3 คนเป็นต้นไป ในขณะที่ถ้าครัวเรือนไม่มีจำนวนสมาชิกในครัวเรือนที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจเลยมีโอกาasที่เป็นครัวเรือนยากจนมากขึ้น

ภาพที่ 4.24

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนห้องที่อยู่อาศัยทั้งหมด (HH07)




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.24 ถ้าหากครัวเรือนมีจำนวนห้องที่อยู่อาศัยทั้งหมดที่มากยิ่งขึ้นเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน (ตั้งแต่ 4 ห้องเป็นต้นไป) ในขณะที่ถ้าครัวเรือนมีจำนวนห้องที่อยู่อาศัยทั้งหมดที่น้อยหรือไม่มีเลยมีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น ยกเว้นกรณีจำนวนห้องเป็น 1 ผลกระทบกระจายตัวเนื่องจากถ้าเป็น 1 ห้อง เช่น คอนโดมีเนียมก็มีโอกาสที่ไม่ใช่ครัวเรือนยากจน หรือถ้าหากมีเพียง 1 ห้องต่อบ้าน 1 หลัง ก็มีโอกาสเป็นครัวเรือนยากจนมากขึ้น

ภาพที่ 4.25

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของจำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C25)



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.25 ถ้าหากครัวเรือนมีจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาวยิ่งเพิ่มโอกาสที่ครัวเรือนนั้นไม่เป็นครัวเรือนยากจน แต่ผลจะลดลงตามจำนวนสมาชิกในครัวเรือนที่เพิ่มไปตั้งแต่ 2 คนเป็นต้นไป ในขณะที่ถ้าหากครัวเรือนไม่มีจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาวมีโอกาสที่เป็นครัวเรือนยากจนมากขึ้น

4.2.3.2 ตัวอย่างของผลกระทบของแต่ละตัวแปรต่อการตัดสินใจของแบบจำลอง


เพื่อให้เห็นผลกระทบของการทำงานของ การตัดสินใจของแบบจำลองว่าครัวเรือนเป็นครัวเรือนยากจนผ่านการยกตัวอย่างของครัวเรือนที่แบบจำลองตัดสินใจว่าเป็นครัวเรือนยากจนมาสองครัวเรือนประกอบไปด้วยกรณีแรกแบบจำลองตัดสินใจว่าไม่ใช่ครัวเรือนยากจน และกรณีที่สองแบบจำลองตัดสินใจว่าเป็นครัวเรือนยากจน

จากภาพที่ 4.26 ด้านล่าง มีจำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05) ทั้งหมด 1 คนเพิ่มโอกาสที่ไม่ใช่ครัวเรือนยากจน 0.03 มีค่าเช่าบ้านต่อเดือน (HH05) 3,500 บาทต่อเดือน เพิ่มโอกาสที่ไม่ใช่ครัวเรือนยากจน 0.02 มีจำนวนหลอดตะเกียบ (HH44) ทั้งหมด 5 หลอดเพิ่มโอกาสที่ไม่ใช่ครัวเรือนยากจน 0.02 มีจำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1) ทั้งหมด 1 คนเพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.01 มีจำนวนสมาชิกที่มีสิทธิประกันสังคม ม.33, ม.39 (C12) ทั้งหมด 1 คนเพิ่มโอกาสที่ไม่ใช่ครัวเรือนยากจน 0.01 และมีจำนวนรถยนต์ส่วนบุคคล (HH18) ทั้งหมด 1 คันเพิ่มโอกาสที่ไม่ใช่ครัวเรือนยากจน 0.01

หลังจากคำนวณผลกระทบของแต่ละตัวแปรแล้วได้ค่าความน่าจะเป็นสุดท้ายคือ 0.084 ซึ่งแบบจำลองตัดสินใจว่าเป็นไม่ใช่ครัวเรือนยากจน

ภาพที่ 4.26

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจครัวเรือนนี้ไม่ใช่ครัวเรือนยากจน




หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

จากภาพที่ 4.27 ด้านล่างแบบจำลองตัดสินใจว่าครัวเรือนนี้เป็นครัวเรือนยากจนโดยผลของแต่ละตัวแปร มีดังนี้ มีจำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1) ทั้งหมด 4 คนเพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.22 ไม่มีจำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05) เพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.13 มีจำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11) ทั้งหมด 4 คนเพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.05 ไม่มีจำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพอื่นที่ไม่ใช่เกษตร (A06) เพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.05 มีจำนวนสมาชิกที่ได้รับบัตรสวัสดิการแห่งรัฐ (C21) ทั้งหมด 4 คนเพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.05 ไม่มีผลลดตะเกียบ (HH44) เพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.04 มีจำนวนสมาชิกในครัวเรือนรวม (A04) ทั้งหมด 4 คนเพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.04 มีจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาว (C25) ทั้งหมด 4 คนเพิ่มโอกาสที่ไม่ใช่ครัวเรือนยากจน 0.04 และใช้ไม่เป็นที่ใช้ในการปรุงอาหาร (HH10) เพิ่มโอกาสที่เป็นครัวเรือนยากจน 0.03 โดยที่ตัวแปรอื่น ๆ อีก 62 ตัวแปรส่งผล

ต่อโอกาสเป็นครัวเรือนยากจน 0.20 โดยที่ค่าฟังก์ชันตั้งต้นคือค่า 0.084 หลักจากคำนวณผลกระทบของแต่ละตัวแปรแล้วจะได้ค่าความน่าจะเป็นสุดท้ายคือ 0.935 ซึ่งแบบจำลองตัดสินใจว่าเป็นครัวเรือนยากจน

ภาพที่ 4.27

แสดงค่าผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจครัวเรือนนี้เป็นครัวเรือนยากจน



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง


4.1.3.3 ค่าเฉลี่ยของผลกระทบของแต่ละตัวแปรต่อการตัดสินใจของแบบจำลอง

ค่าเฉลี่ยของผลกระทบของแต่ละตัวแปรต่อการตัดสินใจของแบบจำลองสามารถคำนวณได้โดยหาค่าเฉลี่ยของแต่ละตัวแปรที่จะส่งผลกระทบต่อแบบจำลองแล้วนำมาใส่ค่าสัมบูรณ์ โดยค่าเฉลี่ยของ SHAP เปรียบเทียบได้กับการหาค่าสัมประสิทธิ์ของแบบจำลองแบบสมการถดถอย ค่าเฉลี่ยสัมบูรณ์ของ SHAP สามารถแสดงได้ดังภาพที่ 4.28 ด้านล่าง เรียงตามขนาดของผลกระทบของการทำนายครัวเรือนยากจนสามารถเรียงความสำคัญจากมากไปน้อยได้ดังนี้ จำนวนสมาชิกใน

ครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1), จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05), จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11), ค่าเช่าบ้านต่อเดือน (HH05), จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรกร (A06), อายุของหัวหน้าครัวเรือน (C02), จำนวนหลอดตะเกียบ (HH44), จำนวนสมาชิกในครัวเรือนรวม (A04), เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19), จำนวนหลอดไฟนีออน (HH42), เป็นเจ้าของมอเตอร์ไซค์หรือไม่ (HH17), จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05), จำนวนเครื่องปรับอากาศ (HH35), จำนวนสมาร์ทโฟน (HH41), เชื้อเพลิงที่ใช้ในการปรุงอาหาร (HH10), จำนวนหลอด LED (HH45), จำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้น (C24), จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10), จำนวนห้องที่อยู่อาศัยทั้งหมด (HH07) และจำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาว (C25)

ภาพที่ 4.28

แสดงค่าเฉลี่ยผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจของแบบจำลอง LightGBM แบบ Classification



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

4.2.4 สรุปผลของตัวแปรในแบบจำลองว่ามีความสำคัญทางสถิติหรือไม่

ตารางที่ 4.3

แสดงผลของ *Shapley Regression* เพื่อตรวจสอบนัยสำคัญทางสถิติของตัวแปรของแบบจำลอง *LightGBM* แบบ *Classification*

ตัวแปร/Features	p-value
จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1)	0.000
จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05)	0.000
จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11)	0.000
ค่าเช่าบ้านต่อเดือน (HH05)	0.000
จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06)	0.000
อายุของหัวหน้าครัวเรือน (C02)	0.427
จำนวนหลอดตะเกียบ (HH44)	0.121
จำนวนสมาชิกในครัวเรือนรวม (A04)	0.000
เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19)	0.000
จำนวนหลอดไฟนีออน (HH42)	0.193
เป็นเจ้าของรถยนต์ไฮบริดหรือไม่ (HH17)	0.021
จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05)	0.000
จำนวนเครื่องปรับอากาศ (HH35)	0.000
จำนวนสมาร์ทโฟน (HH41)	0.291
เชื้อเพลิงที่ใช้ในการปรุงอาหาร (HH10)	0.000
จำนวนหลอด LED (HH45)	0.000
จำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะสั้น (C24)	0.002
จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10)	0.000
จำนวนห้องที่อยู่อาศัยทั้งหมด (HH07)	0.000
จำนวนสมาชิกที่ได้ประโยชน์จากโครงการภาครัฐระยะยาว (C25)	0.000

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

เพื่อให้สามารถสรุปผลของตัวแปรแต่ละตัวว่ามีผลนัยสำคัญทางสถิติหรือไม่ทางผู้วิจัยจะอ้างอิงจากงานศึกษาของ Buckman and Joseph (2023) ที่ได้สร้างการทำสถิติอนุมาน (Statistical Inference) ดำเนินการเพื่อทำความเข้าใจว่าตัวแปรใดมีส่วนช่วยอย่างมีนัยสำคัญทางสถิติต่อความแม่นยำของแบบจำลองซึ่งให้ระดับความมั่นใจสำหรับการตีความของแบบจำลองและเรื่องราวที่เกี่ยวข้องกับการตีความเหล่านั้น การอนุมานนี้ใช้การวิเคราะห์การถดถอยแบบพารามตริก (Parametric Regression Analysis) ทำให้อธิบายผลลัพธ์ของแบบจำลองทางสถิติได้อย่างเป็นมาตรฐาน นอกจากนี้ ยังสามารถทำ Robustness Checks ได้เพื่อแก้ไขข้อบกพร่องที่จะเกิดขึ้นเมื่อมีการใช้เทคนิค Machine Learning การวิเคราะห์การทำสถิติอนุมานนี้จะใช้เทคนิค Shapley Regression ทำการตรวจสอบที่ระดับนัยสำคัญที่ 95

ผลของการตรวจสอบตัวแปรที่มีความสำคัญ 20 อันดับแรกแสดงดังตารางที่ 4.3 พบว่ามีตัวแปรจำนวนทั้งสิ้น 4 ตัวแปรที่ไม่มีผลนัยสำคัญทางสถิติที่ระดับ 95 ประกอบไปด้วยตัวแปรอายุของหัวหน้าครัวเรือน จำนวนหลอดตะเกียบ จำนวนหลอดไฟนีออน และจำนวนสมาร์ตโฟน

4.3 แบบจำลองแบบ Regression

ในการสร้างแบบจำลองแบบ Regression เพื่อทำนายรายได้ต่อครัวเรือนต่อเดือน โดยที่ตัวแปร จะเป็นแบบต่อเนื่อง (Continuous) แบบจำลองแบ่งเป็น Training กับ Test Set ผ่านการทำ K-fold Validation เพื่อหาสัดส่วนของการแบ่ง Train และ Test Set ที่เหมาะสมโดยได้สัดส่วนเป็น 70:30 โดยข้อมูลร้อยละ 70 เป็นข้อมูลสำหรับให้ตัวแบบเรียนรู้ ในขณะที่อีกร้อยละ 30 ใช้เพื่อตรวจสอบประสิทธิภาพของแบบจำลอง เพื่อให้สอดคล้องกับการสร้างแบบจำลองแบบ Classification

4.3.1 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง

การเปรียบเทียบประสิทธิภาพของแบบจำลอง Machine Learning แบบ Regression อาศัย RMSE (Root Mean Square Error) เป็นการหาค่ารากที่สองของค่า MSE เพื่อให้ได้ค่า Loss ที่มีหน่วยเดียวกับตัวแปร y ทำให้ค่า RMSE แปลผลแบบมีประสิทธิภาพมากที่สุด โดยถ้าค่า RMSE เท่ากับ 10 แปลว่าโดยเฉลี่ยแบบจำลองทำนายค่า y ผิดไป ± 10 จุด แต่ถ้า RMSE เท่ากับ 0 แปลว่าแบบจำลองสามารถทำนายค่า y ได้ถูกต้องทั้งหมดไม่มีข้อผิดพลาดเลย

ตารางที่ 4.4

แสดงผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง Random Forest กับ LightGBM แบบ Regression

แบบจำลอง	RMSE
Random Forest	1,347.901
LightGBM	989.709
LightGBM – ตัดรายได้ครัวเรือนที่ต่ำกว่า 8000 บาทต่อคนต่อเดือน	612.892
LightGBM - ปรับค่าถ่วงน้ำหนัก Class Weight	892.909

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ตารางที่ 4.4 แสดงการเปรียบเทียบค่า RMSE ของแบบจำลองแบบ Random Forest และแบบจำลอง LightGBM พบว่าแบบจำลองแบบ Random Forest มีค่า RMSE เท่ากับ 1,347.901 ในขณะที่แบบจำลองแบบ LightGBM มีค่า RMSE เท่ากับ 989.709 สะท้อนว่าแบบจำลองแบบ LightGBM ได้ผลการทำนายที่มีความแม่นยำกว่า

จากตารางที่ 4.4 แบบจำลอง Regression LightGBM การใช้เทคนิค LightGBM ผ่านการตัดรายได้ครัวเรือนที่ต่ำกว่า 8,000 บาทต่อคนต่อเดือน จะได้แบบจำลองที่มีประสิทธิภาพมากที่สุดมีค่า RMSE เท่ากับ 612.892 ในขณะที่การใช้เทคนิคปรับค่าถ่วงน้ำหนัก Class Weight ได้ประสิทธิภาพของแบบจำลองที่ไม่สูงมากนักเมื่อเทียบกับการสร้างแบบจำลอง LightGBM แบบปกติ ดังนั้นในส่วนถัดไปจะทำการอภิปรายผลลัพธ์ของแบบจำลองที่ดีที่สุดคือแบบจำลอง LightGBM ผ่านการตัดรายได้ครัวเรือนที่ต่ำกว่า 8,000 บาทต่อคนต่อเดือน

4.3.2 อภิปรายผลของแบบจำลอง LightGBM แบบ Regression

4.3.2.1 อภิปรายผลของแบบจำลอง LightGBM แบบ Regression ผ่านค่า


SHAP

การอภิปรายผลของแต่ละตัวแปรผ่านค่า SHAP สามารถแสดงได้ดังรูปด้านล่างนี้โดยจะทำการอภิปรายเฉพาะตัวแปรที่ส่งผลมากที่สุด 20 ตัวแรก โดยในการอภิปรายผลของแบบจำลองแบบ Regression สามารถใช้ค่า SHAP จากค่าดิบ (Raw) ในการอธิบายผลของแบบจำลองที่มีผลต่อการทำนายรายได้ได้โดยไม่ต้องแปลงผลเป็นความน่าจะเป็น ถ้าค่าเข้าใกล้ค่าศูนย์ 0 หมายถึงค่าของตัวแปรนั้นส่งผลเป็นลบต่อรายได้จะยิ่งทำให้เกิดโอกาสเป็นครัวเรือนยากจนมากยิ่งขึ้น ในขณะที่ถ้าหากค่ามีค่ามากกว่า 0 ส่งผลทำให้รายได้เพิ่มขึ้นสะท้อนว่ามีโอกาสที่จะเป็นครัวเรือนที่ไม่ยากจนเพิ่มมากขึ้น ตัวอย่างเช่นถ้ามีค่าในตัวแปรนั้นมีผลของค่า SHAP

เป็น 100 หมายความว่าตัวแปรนั้นส่งผลให้ครัวเรือนนั้นมีรายได้เพิ่มขึ้น 100 บาท และถ้าค่า SHAP เป็น -100 หมายความว่าตัวแปรนั้นส่งผลให้ครัวเรือนนั้นมีรายได้ลดลง 100 บาททำให้อาจจะมีโอกาสเป็นครัวเรือนยากจนเพิ่มมากขึ้น

ภาพที่ 4.29

แสดงค่า SHAP ของแบบจำลอง Regression ของ LightGBM โดยที่เลือกตัวแปรที่สำคัญ 20 อันดับแรก



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ตัวแปรที่ส่งผล 20 อันดับแรกของแบบจำลอง LightGBM แบบ Regression ที่ส่งผลต่อการทำนายรายได้สามารถเรียงความสำคัญจากมากไปน้อยได้ดังนี้ จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1), ระดับการศึกษาของหัวหน้าครัวเรือน (C04), จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11), ค่าเช่าบ้านต่อเดือน (HH05), เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19), เป็นเจ้าของรถยนต์ส่วนตัวหรือไม่ (HH18), จำนวนสมาชิกในครัวเรือนรวม (A04), จำนวนเครื่องปรับอากาศ (HH35), จำนวนสมาชิกที่ได้รับบัตรสวัสดิการแห่งรัฐ (C21), จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05), จำนวนสมาชิกที่ได้เบี้ยผู้สูงอายุ (C17), จำนวนผู้ที่ทำงานหารายได้และผู้ที่ช่วยธุรกิจครัวเรือน โดยไม่ได้รับค่าจ้าง (A02), อายุของหัวหน้าครัวเรือน (C02), จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05), จำนวนสมาชิกที่มีประกันสุขภาพเอกชน (C14), จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06), จำนวนเตาไมโครเวฟ (HH25), จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10), จำนวนผู้ที่ทำงานหารายได้และผู้ที่ช่วยธุรกิจครัวเรือน โดยไม่ได้รับค่าจ้าง ไม่รวมคนใช้ (A02_1) และจำนวนคอมพิวเตอร์ (HH37)

จากภาพที่ 4.29 สามารถอธิบายผลของแต่ละตัวแปรผ่านค่า SHAP ในภาพรวมได้ดังนี้

จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1) ถ้าหากจำนวนในครัวเรือนรวมยังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือนมากขึ้น ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีจำนวนที่น้อยจะลดรายได้ของครัวเรือน

ระดับการศึกษาของหัวหน้าครัวเรือน (C04) ถ้าหากระดับการศึกษาของหัวหน้าครัวเรือนยิ่งสูงจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าระดับการศึกษาของหัวหน้าครัวเรือนต่ำจะลดรายได้ของครัวเรือน

จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11) ถ้าหากจำนวนสมาชิกที่มีสิทธิบัตรทองยังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวนสมาชิกที่มีสิทธิบัตรทองมีจำนวนที่น้อยจะลดรายได้ของครัวเรือน

ค่าเช่าบ้านต่อเดือน (HH05) ถ้าหากค่าเช่าบ้านต่อเดือนมีค่าเช่าที่เพิ่มขึ้นจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าค่าเช่าบ้านต่อเดือนมีค่าเช่าที่น้อยจะลดรายได้ของครัวเรือน

เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19) ถ้าหากครัวเรือนเป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้ จะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าครัวเรือนไม่เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้ จะมีลดรายได้ของครัวเรือน

เป็นเจ้าของยนต์ส่วนบุคคลหรือไม่ (HH18) ถ้าหากครัวเรือนเป็นเจ้าของ ยนต์ส่วนบุคคลจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าครัวเรือนไม่เป็นเจ้าของรถยนต์ส่วนบุคคล จะลดรายได้ของครัวเรือน

จำนวนสมาชิกในครัวเรือนรวม (A04) ถ้าหากจำนวนในครัวเรือนรวมยังมี จำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนมีจำนวนที่น้อยจะ ลดรายได้ของครัวเรือน

จำนวนเครื่องปรับอากาศ (HH35) ถ้าหากครัวเรือนมีเครื่องปรับอากาศ จะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าครัวเรือนไม่มีเครื่องปรับอากาศจะลดรายได้ของครัวเรือน

จำนวนสมาชิกที่ได้รับบัตรสวัสดิการแห่งรัฐ (C21) ถ้าหากจำนวนสมาชิก ที่ได้รับบัตรสวัสดิการแห่งรัฐยังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือนขึ้น ในขณะที่ถ้าได้รับบัตร สวัสดิการแห่งรัฐมีจำนวนที่น้อยจะลดรายได้ของครัวเรือน

จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05) ถ้าหากจำนวนใน ครัวเรือนที่ทำงานและได้รับค่าจ้างยังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวน สมาชิกในครัวเรือนที่ทำงานและได้รับค่าจ้างมีจำนวนที่น้อยหรือไม่มีเลยจะลดรายได้ของครัวเรือน

จำนวนสมาชิกที่ได้เบี้ยผู้สูงอายุ (C17) ถ้าหากจำนวนสมาชิกที่ได้เบี้ย ผู้สูงอายุมียังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าเบี้ยผู้สูงอายุมียังมีจำนวนที่น้อยจะลด รายได้ของครัวเรือน

จำนวนผู้ที่ทำงานหารายได้และผู้ช่วยธุรกิจในครัวเรือน (A02) โดยไม่ได้ รับค่าจ้าง ถ้าหากจำนวนในครัวเรือนที่ทำงานหารายได้และผู้ช่วยธุรกิจในครัวเรือน โดยไม่ได้รับ ค่าจ้างยังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่ทำงาน หารายได้และผู้ช่วยธุรกิจในครัวเรือน โดยไม่ได้รับค่าจ้างมีจำนวนที่น้อยหรือไม่มีเลยจะลดรายได้ ของครัวเรือน

อายุของหัวหน้าครัวเรือน (C02) ถ้าหากครัวเรือนมีหัวหน้าครัวเรือนที่มี อายุไม่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าครัวเรือนมีหัวหน้าครัวเรือนที่อายุมากจะมีลด รายได้ของครัวเรือน

จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05) ถ้าหากจำนวน ในครัวเรือนมีอายุน้อยกว่า 15 ปียังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวน สมาชิกในครัวเรือนมีอายุน้อยกว่า 15 ปีมีจำนวนที่น้อยจะลดรายได้ของครัวเรือน

จำนวนสมาชิกที่มีประกันสุขภาพเอกชน (C14) ถ้าหากจำนวนใน ครัวเรือนที่มีประกันสุขภาพเอกชนยังมีจำนวนที่มากจะยิ่งเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้า

จำนวนสมาชิกในครัวเรือนที่มีประกันสุขภาพเอกชนมีจำนวนที่น้อยหรือไม่มีเลยจะลดรายได้ของครัวเรือน

จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06) ถ้าหากจำนวนในครัวเรือนที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรยังมีจำนวนที่มากจะยังเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตรมีจำนวนที่น้อยหรือไม่มีเลยจะลดรายได้ของครัวเรือน

จำนวนเตาไมโครเวฟ (HH25) ถ้าหากครัวเรือนมีจำนวนเตาไมโครเวฟที่มากจะยังเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าครัวเรือนมีจำนวนเตาไมโครเวฟที่น้อยจะลดรายได้ของครัวเรือน

จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10) ถ้าหากจำนวนในครัวเรือนที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ ยังมีจำนวนที่มากจะยังเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวนสมาชิกในครัวเรือนที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจมีจำนวนที่น้อยหรือไม่มีเลยจะลดรายได้ของครัวเรือน

จำนวนผู้ที่ทำงานหารายได้และผู้ช่วยธุรกิจในครัวเรือน โดยไม่ได้รับค่าจ้าง ไม่รวมคนใช้ (A02_1) ถ้าหากจำนวนในครัวเรือนดังกล่าวที่ยังมีจำนวนที่มากจะยังเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าจำนวนสมาชิกดังกล่าวที่น้อยหรือไม่มีเลยจะลดรายได้ของครัวเรือน

จำนวนคอมพิวเตอร์ (HH37) ถ้าหากครัวเรือนมีจำนวนคอมพิวเตอร์ที่มากจะยังเพิ่มรายได้ของครัวเรือน ในขณะที่ถ้าครัวเรือนมีจำนวนคอมพิวเตอร์ที่น้อยหรือไม่มีเลยจะลดรายได้ของครัวเรือน


4.3.2.2 ค่าเฉลี่ยของผลกระทบของแต่ละตัวแปรต่อการตัดสินใจของแบบจำลอง

ค่าเฉลี่ยของผลกระทบของแต่ละตัวแปรต่อการทำนายรายได้สามารถคำนวณได้โดยหาค่าเฉลี่ยของแต่ละตัวแปรที่จะส่งผลต่อแบบจำลองแล้วนำมาใส่ค่าสัมบูรณ์โดยค่าเฉลี่ยของ SHAP เปรียบเทียบได้กับการหาค่าสัมประสิทธิ์ของแบบจำลองแบบสมการถดถอย ค่าเฉลี่ยสัมบูรณ์ของ SHAP สามารถแสดงได้ดังภาพที่ 4.30 ด้านล่าง เรียงตามขนาดของผลกระทบของการทำนายครัวเรือนยากจนจากมากไปน้อยได้ดังนี้ จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1), ระดับการศึกษาของหัวหน้าครัวเรือน (C04), จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11), ค่าเช่าบ้านต่อเดือน (HH05), เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19), เป็นเจ้าของรถยนต์ส่วนตัวหรือไม่ (HH18), จำนวนสมาชิกในครัวเรือนรวม (A04), จำนวนเครื่องปรับอากาศ (HH35), จำนวนสมาชิกที่ได้รับบัตรสวัสดิการแห่งรัฐ (C21), จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05), จำนวนสมาชิกที่ได้เบี้ยผู้สูงอายุ (C17), จำนวนผู้ที่ทำงานหารายได้

และผู้ช่วยธุรกิจในครัวเรือน โดยไม่ได้รับค่าจ้าง (A02), อายุของหัวหน้าครัวเรือน (C02), จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05), จำนวนสมาชิกที่มีประกันสุขภาพเอกชน (C14), จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06), จำนวนเตาไมโครเวฟ (HH25), จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10), จำนวนผู้ที่ทำงานหารรายได้และผู้ช่วยธุรกิจในครัวเรือน โดยไม่ได้รับค่าจ้าง ไม่รวมคนใช้ (A02_1) และจำนวนคอมพิวเตอร์ (HH37)

ภาพที่ 4.30

แสดงค่าเฉลี่ยผลกระทบของตัวแปรผ่านค่า SHAP ของการตัดสินใจของแบบจำลอง LightGBM แบบ Regression



หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

4.3.3 สรุปผลของตัวแปรในแบบจำลองว่ามีความสำคัญทางสถิติหรือไม่

ตารางที่ 4.5

แสดงผลของ *Shapley Regression* เพื่อตรวจสอบนัยสำคัญทางสถิติของตัวแปรของแบบจำลอง *LightGBM* แบบ *Regression*

ตัวแปร/Features	p-value
จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้ (A04_1)	0.000
ระดับการศึกษาของหัวหน้าครัวเรือน (C04)	0.000
จำนวนสมาชิกที่ได้สิทธิบัตรทอง (C11)	0.000
ค่าเช่าบ้านต่อเดือน (HH05)	0.000
เป็นเจ้าของรถบรรทุกเล็ก/ปิคอัพ/รถตู้หรือไม่ (HH19)	0.000
เป็นเจ้าของรถยนต์ส่วนตัวหรือไม่ (HH18)	0.000
จำนวนสมาชิกในครัวเรือนรวม (A04)	0.000
จำนวนเครื่องปรับอากาศ (HH35)	0.000
จำนวนสมาชิกที่ได้รับบัตรสวัสดิการแห่งรัฐ (C21)	0.000
จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05)	0.000
จำนวนสมาชิกที่ได้เบี้ยผู้สูงอายุ (C17)	0.009
จำนวนผู้ที่ทำงานหารายได้และผู้ที่ช่วยธุรกิจครัวเรือน โดยไม่ได้รับค่าจ้าง (A02)	0.421
อายุของหัวหน้าครัวเรือน (C02)	0.348
จำนวนสมาชิกในครัวเรือนที่มีอายุน้อยกว่า 15 ปี (C05)	0.001
จำนวนสมาชิกที่มีประกันสุขภาพเอกชน (C14)	0.000
จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร (A06)	0.000
จำนวนเตาไมโครเวฟ (HH25)	0.000
จำนวนสมาชิกที่มีสิทธิเบิกค่ารักษาจากหน่วยงานรัฐ/รัฐวิสาหกิจ (C10)	0.000
จำนวนผู้ที่ทำงานหารายได้และผู้ที่ช่วยธุรกิจครัวเรือน โดยไม่ได้รับค่าจ้าง ไม่รวมคนใช้ (A02_1)	0.439

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

เพื่อให้สามารถสรุปผลของตัวแปรแต่ละตัวว่ามีผลนัยสำคัญทางสถิติหรือไม่ของแบบจำลองประเภท Regression อ้างอิงจากงานศึกษาของ Buckman and Joseph (2023) เช่นเดียวกันกับในกรณีของการทำ Classification ที่ได้สร้างการทำสถิติอนุมาน (Statistical Inference) ผ่านเทคนิค Shapley Regression ทำการตรวจสอบที่ระดับนัยสำคัญที่ 95

ผลของการตรวจสอบตัวแปรที่มีความสำคัญ 20 อันดับแรกพบว่าตัวแปรจำนวนทั้งสิ้น 3 ตัวแปรที่ไม่มีผลนัยสำคัญทางสถิติที่ระดับ 95 ประกอบไปด้วยตัวแปรจำนวนผู้ที่ทำงานหารายได้และผู้ช่วยธุรกิจในครัวเรือน โดยไม่ได้รับค่าจ้าง (A02) จำนวนผู้ที่ทำงานหารายได้และผู้ช่วยธุรกิจในครัวเรือน โดยไม่ได้รับค่าจ้าง ไม่รวมคนใช้ (A02_1) และอายุของหัวหน้าครัวเรือน (C02)

4.4 เปรียบเทียบแบบจำลองกับ Based-line Logistic Regression

ตารางที่ 4.6

แสดงผลการเปรียบเทียบแบบจำลองกับ Based-line Logistic Regression

แบบจำลอง	Inclusion Error	Exclusion Error
Based-line - Logistics	0.41	0.84
Classificaton - LightGBM	0.26	0.38
Regression ML - LightGBM	0.37	0.74
Based-line - Logistics Tune Weight	0.35	0.61
Classificaton - LightGBM Tune Weight	0.30	0.10
Regression ML - LightGBM Tune Weight	0.27	0.49
Based-line - Logistics Cut Income	0.37	0.73
Classificaton - LightGBM Cut Income	0.24	0.34
Regression ML - LightGBM Cut Income	0.17	0.31

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

ตารางที่ 4.6 แสดงการเปรียบเทียบแบบจำลองทั้งหมดกับ Based-line ของ Logistics Regression ผ่านมิติของค่า Inclusion Error และค่า Exclusion Error พบว่า แบบจำลอง Machine Learning สามารถลดค่า Inclusion และค่า Exclusion ได้จริง แบบจำลอง

Classification - Light GBM Tune Weight การใช้เทคนิคการถ่วงน้ำหนักทำให้ประสิทธิภาพของแบบจำลองดีที่สุดโดยลดค่า Exclusion Error จากค่า 0.38 ลดลงเหลือ 0.10 ในขณะที่ค่า Inclusion Error เพิ่มขึ้นเล็กน้อยจากค่า 0.26 เป็นค่า 0.30 ในขณะที่สำหรับแบบจำลอง Regression ML - LightGBM Cut Income การตัดรายได้ช่วยให้แบบจำลองมีประสิทธิภาพดีที่สุดโดยที่ลดค่า Exclusion Error จากค่า 0.37 ลดลงเหลือ 0.17 และค่า Inclusion Error ลดลงจากค่า 0.74 เป็นค่า 0.31

นอกจากนี้การวิเคราะห์เพิ่มเติมพบว่า หากมีการนำข้อมูลที่ตัวแบบใช้ในการทำนาย (Test) ตัดเฉพาะครัวเรือนที่มีรายได้ต่ำกว่า 8,000 บาทต่อคนต่อเดือน ไม่ได้ใช้ข้อมูลที่มีรายได้ทุกช่วง ดังเช่นในตารางที่ 4.6 จะช่วยให้แบบจำลองมีประสิทธิภาพสูงขึ้นอย่างมีนัยสำคัญ ทั้งในมิติของการลดค่า Inclusion Error และ Exclusion Error พร้อมกัน ซึ่งเป็นผลมาจากการลดความแปรปรวนของข้อมูลรายได้ที่อยู่ในช่วงสูงและมักมีลักษณะเป็น outlier หรือเบ้ขวา (Right-skewed) ซึ่งส่งผลกระทบเชิงลบต่อกระบวนการเรียนรู้ของแบบจำลองทั้งเชิงถดถอยและการจำแนก

ตารางที่ 4.7 แสดงประสิทธิภาพของแบบจำลองเมื่อใช้พยากรณ์เฉพาะครัวเรือนที่มีรายได้ต่ำกว่า 8,000 บาทต่อคนต่อเดือน แบบจำลอง Classification - LightGBM Cut Income มีค่าความผิดพลาดลดลงจาก Inclusion error เดิมที่อยู่ 0.24 เหลือเพียง 0.17 และ Exclusion Error ลดลงจาก 0.34 เหลือ 0.25 และแบบจำลอง Regression ML - LightGBM Cut Income แสดงผลลัพธ์ที่ดีขึ้นเช่นกัน โดย Inclusion error ลดลงจาก 0.17 เหลือ 0.12 และ Exclusion Error ลดลงจาก 0.31 เหลือ 0.22 ซึ่งสะท้อนถึงประสิทธิภาพของกระบวนการลดขอบเขตของข้อมูลเพื่อให้แบบจำลองสามารถเจาะจงไปที่กลุ่มเป้าหมายที่แท้จริงได้ดียิ่งขึ้น

ตารางที่ 4.7

แสดงผลการเปรียบเทียบแบบจำลองที่ใช้พยากรณ์เฉพาะครัวเรือนที่มีรายได้ต่ำกว่า 8,000 บาทต่อครัวเรือนต่อเดือน

แบบจำลอง	Inclusion Error	Exclusion Error
Based-line - Logistics Cut Income	0.27	0.57
Classification - LightGBM Cut Income	0.17	0.25
Regression ML - LightGBM Cut Income	0.12	0.22

หมายเหตุ ประมวลผลจากข้อมูลสำรวจภาวะเศรษฐกิจสังคมของครัวเรือน (SES: Socio Economic Survey) ปี พ.ศ. 2566 ผ่านการสร้างแบบจำลอง

4.5 สรุปผล

งานศึกษาชิ้นนี้อาศัยข้อมูลสามส่วนจากแบบสำรวจ SES ในระดับครัวเรือน ข้อมูลแบบสำรวจ SES ในระดับบุคคล และข้อมูลตัวชี้วัดรายจังหวัดต่าง ๆ เช่น ข้อมูลผลิตภัณฑ์มวลรวมจังหวัด (Gross Provincial Product : GPP) ข้อมูลจำนวนประชากรรายจังหวัด ข้อมูลลักษณะอุตสาหกรรมรายจังหวัด เป็นต้น มาสร้างแบบจำลอง Random Forest และ แบบจำลอง LightGBM รวมทั้งมีการสร้างแบบจำลองไว้เปรียบเทียบประสิทธิภาพของแบบจำลองดั้งเดิมผ่าน Logistic Regression โดยแบ่งแบบจำลองเป็นสามรูปแบบประกอบไปด้วยสร้างแบบจำลองแบบปกติ แบบใช้เทคนิคตัดรายได้ และแบบใช้เทคนิคถ่วงน้ำหนัก

ผลการศึกษาพบว่าการใช้เทคนิค Machine Learning สามารถลดทั้งค่า Inclusion Error และ Exclusion Error อย่างมีประสิทธิภาพได้มากกว่า Baseline อย่าง Logistic Regression และเมื่อมีการใช้เทคนิคการถ่วงน้ำหนัก หรือการตัดรายได้ยิ่งทำให้แบบจำลองมีประสิทธิภาพที่ดียิ่งขึ้น ซึ่งสอดคล้องกับงานศึกษาของ Wobcke และ Mariyah (2023) และงานศึกษาของ Ysobel และ Ting (2024)

การเลือกใช้แบบจำลองในรูปแบบไหนขึ้นอยู่กับนโยบายของภาครัฐ หากรัฐบาลมีข้อจำกัดด้านงบประมาณและต้องการลดการรั่วไหล เน้นไปที่การลด Inclusive Error จึงควรใช้แบบจำลองในเทคนิคสมการถดถอยผ่านเทคนิคการตัดรายได้ แต่หากต้องการความครอบคลุมและความยุติธรรมทางสังคมอาจเน้นไปที่ การลด Exclusive Error ผ่านการใช้แบบจำลอง Classification ผ่านเทคนิคการใช้เทคนิคถ่วงน้ำหนัก

การจำกัดช่วงรายได้สำหรับการพยากรณ์ (Test Set) เป็นวิธีที่ช่วยให้แบบจำลองสามารถทำนายกลุ่มเป้าหมายยากจนที่แท้จริงได้อย่างมีประสิทธิภาพ โดยเฉพาะอย่างยิ่งในแบบจำลองเชิงถดถอย ซึ่งมีความอ่อนไหวต่อค่าสุดขั้ว (Extreme) มากกว่าการจำแนก เนื่องจากการประมาณค่าเฉลี่ยในเชิงตัวเลขมักถูกรบกวนโดยกลุ่มที่มีรายได้สูง หากไม่ได้ควบคุมหรือจำกัดช่วงของข้อมูลก่อนการวิเคราะห์

อย่างไรก็ดี แนวทางนี้มีข้อพึงระวังในทางปฏิบัติ โดยเฉพาะในบริบทของการประยุกต์ใช้จริงในการคัดกรองครัวเรือนยากจน เนื่องจากการตัดช่วงรายได้เพื่อฝึกแบบจำลองจำเป็นต้องมีการทราบค่ารายได้ล่วงหน้า หรือมีข้อมูลอ้างอิงที่น่าเชื่อถือในการระบุกลุ่มเป้าหมายล่วงหน้า ซึ่งในหลายกรณีอาจไม่สอดคล้องกับบริบทของการปฏิบัติในพื้นที่จริง โดยเฉพาะในพื้นที่ที่การรายงานรายได้อาจมีข้อจำกัดเชิงข้อมูล หรือมีความคลาดเคลื่อนจากการรายงานตนเอง

ดังนั้น การจำกัดช่วงรายได้ในการฝึกแบบจำลองช่วยเพิ่มประสิทธิภาพของแบบจำลองในเชิงเทคนิคได้อย่างชัดเจน แต่ความเหมาะสมของการใช้งานจริงยังขึ้นอยู่กับข้อจำกัดเชิงนโยบาย

และโครงสร้างข้อมูลที่มีอยู่ในแต่ละพื้นที่ หากสามารถออกแบบกระบวนการคัดกรองที่มีข้อมูลประกอบเพียงพอสำหรับการตัดช่วงรายได้เบื้องต้น แนวทางนี้อาจช่วยเพิ่มความแม่นยำและลดค่าใช้จ่ายในการดำเนินงานได้อย่างมีนัยสำคัญ อย่างไรก็ตามหากบริบทการใช้งานไม่เอื้อต่อการตัดข้อมูลรายได้ตั้งแต่ต้น อาจจำเป็นต้องอาศัยเทคนิคอื่นที่ยืดหยุ่นมากขึ้น เช่น การถ่วงน้ำหนักหรือการใช้แบบจำลองผสมที่รองรับความไม่แน่นอนของข้อมูลมากขึ้น



บทที่ 5

ข้อเสนอแนะเชิงนโยบายและข้อเสนอแนะ

ผลการศึกษาที่ได้นำเสนอในบทที่ 4 แสดงให้เห็นว่าการประยุกต์ใช้แบบจำลอง Machine Learning ในลักษณะของแบบจำลองการจำแนก (Classification) และแบบจำลองสมการถดถอย (Regression) สามารถวิเคราะห์สถานการณ์ความยากจนของครัวเรือนได้อย่างมีประสิทธิภาพมากขึ้นกว่าวิธีแบบดั้งเดิม โดยมีตัวแปรสำคัญที่ช่วยในการอธิบายความแตกต่างด้านรายได้และสถานะความยากจนของครัวเรือนอย่างชัดเจน ข้อเสนอแนะเชิงนโยบายจากผลการวิเคราะห์จึงสามารถแบ่งได้เป็นประเด็นหลัก ๆ ดังต่อไปนี้

5.1 ข้อเสนอแนะเชิงนโยบาย

5.1.1 การออกแบบมาตรการนโยบายต่าง ๆ ผ่านตัวแปรที่บ่งชี้ความยากจน

การออกแบบมาตรการต่าง ๆ ผ่านตัวแปรที่บ่งชี้ความยากจนควรพิจารณาในหลากหลายมิติของข้อมูลเชิงลึกที่สะท้อนถึงสถานการณ์ทางเศรษฐกิจและสังคมของครัวเรือนอย่างรอบด้าน โดยเฉพาะการใช้ตัวแปรที่เกี่ยวข้องกับโครงสร้างของครัวเรือน ข้อมูลทรัพย์สิน รวมถึงลักษณะทางประชากรของหัวหน้าครัวเรือน ซึ่งแต่ละกลุ่มตัวแปรมีศักยภาพในการบ่งชี้ความเปราะบางทางเศรษฐกิจที่ต่างกันและสามารถนำไปสู่การออกแบบมาตรการนโยบายที่แม่นยำและมีประสิทธิภาพมากยิ่งขึ้น

ในมิติของโครงสร้างครัวเรือน ตัวแปรเช่น จำนวนสมาชิกทั้งหมดในครัวเรือน (A04, A04_1) จำนวนสมาชิกที่มีอายุต่ำกว่า 15 ปี (C05) และจำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง (A05) เป็นตัวแทนสำคัญของภาระการเลี้ยงดูและศักยภาพในการหารายได้ของครัวเรือน ข้อมูลเหล่านี้สามารถใช้ในการกำหนดมาตรการที่เฉพาะเจาะจง เช่น การอุดหนุนทางการเงินตามจำนวนผู้พึ่งพิง การให้สิทธิพิเศษหรือการเข้าถึงโปรแกรมฝึกอบรมอาชีพสำหรับครัวเรือนที่มีแรงงานพร้อมแต่ยังไม่สามารถเข้าสู่ตลาดแรงงานได้อย่างมีประสิทธิภาพ

สำหรับมิติของข้อมูลภูมิหลังของหัวหน้าครัวเรือน ตัวแปรอายุ (C02) และระดับการศึกษา (C04) สามารถใช้เพื่อจำแนกกลุ่มเป้าหมายย่อยในเชิงลึก เช่น ครัวเรือนที่มีหัวหน้าครัวเรือนเป็นผู้สูงอายุที่ขาดโอกาสในการพัฒนาทักษะใหม่ หรือกลุ่มแรงงานวัยกลางคนที่ยังสามารถพัฒนาเพื่อต่อยอดศักยภาพการทำงานได้ การออกแบบนโยบายในลักษณะนี้จะช่วยเพิ่มประสิทธิผลของการจัดสรรงบประมาณ และตอบโจทย์การพัฒนาอย่างยั่งยืน

ในด้านของฐานะทางเศรษฐกิจและความเป็นอยู่ ตัวแปรที่เกี่ยวกับทรัพย์สิน และเครื่องใช้ในครัวเรือน เช่น การเป็นเจ้าของรถยนต์ (HH18), มอเตอร์ไซค์ (HH17), เครื่องปรับอากาศ (HH35), สมาร์ทโฟน (HH41) หรือคอมพิวเตอร์ (HH37) เป็นดัชนีที่ช่วยสะท้อนระดับความมั่งคั่งและคุณภาพชีวิตได้แม้ในกรณีที่ไม่สามารถตรวจสอบรายได้โดยตรง การนำตัวแปรเหล่านี้มาวิเคราะห์ร่วมกับข้อมูลรายได้จะช่วยพัฒนาวิธีการ “วัดรายได้ทางอ้อม” ซึ่งมีความยืดหยุ่นและเหมาะสมกับบริบทของข้อมูลภาคสนามในประเทศไทย

5.1.2 การใช้แบบจำลองเชิงทำนายเพื่อลดการรั่วไหลของงบประมาณ

การจำแนกครัวเรือนที่ยากจนอย่างแม่นยำถือเป็นปัจจัยสำคัญในการเพิ่มประสิทธิภาพของการใช้งบประมาณภาครัฐ โดยการใช้แบบจำลอง Machine Learning ในรูปแบบการจำแนก (Classification) และสมการการถดถอย (Regression) จะช่วยลดความคลาดเคลื่อนที่เกิดจากการระบุเป้าหมายผิดพลาด ทั้งในลักษณะของ False Positive และ False Negative

จากงานศึกษาชิ้นนี้สามารถสรุปได้ว่าแบบจำลอง Machine Learning แบบการจำแนก (Classification) ช่วยลดความผิดพลาดในการไม่สามารถช่วยเหลือผู้ที่ควรได้รับสิทธิ (Exclusive Error) ซึ่งมีความสำคัญหากนโยบายมีเป้าหมายในการสร้างความยุติธรรมทางสังคม ในขณะที่แบบจำลอง Machine Learning แบบสมการการถดถอย (Regression) มีความเหมาะสมสำหรับกรณีที่รัฐมีข้อจำกัดทางงบประมาณและต้องการลดการรั่วไหล หรือ Inclusive Error ซึ่งเกิดจากการจัดสิทธิให้กับผู้ที่ไม่ได้ยากจนจริง

การเลือกใช้แบบจำลองจึงควรขึ้นอยู่กับลักษณะของนโยบายว่ามุ่งเน้นเป้าหมายทางเศรษฐกิจหรือเป้าหมายทางสังคมเป็นหลัก การผสมผสานทั้งสองแนวทางเข้าด้วยกันสามารถสร้างระบบการคัดกรองที่ทั้งมีประสิทธิภาพและมีความเป็นธรรมได้อย่างมีประสิทธิภาพ

5.1.3 ข้อเสนอแนะเชิงระบบฐานข้อมูล

เพื่อรองรับการใช้แบบจำลอง Machine Learning ในการระบุครัวเรือนที่ยากจนอย่างแม่นยำ รัฐควรให้ความสำคัญกับการพัฒนาระบบฐานข้อมูลขนาดใหญ่ (Big Data) ที่สามารถเชื่อมโยงข้อมูลระหว่างหน่วยงานต่าง ๆ เช่น กรมพัฒนาสังคมและสวัสดิการ สำนักงานประกันสังคม และสำนักงานสถิติแห่งชาติ การบูรณาการข้อมูลในลักษณะนี้จะช่วยให้การวิเคราะห์ข้อมูลมีความทันสมัย และนำไปสู่การตัดสินใจเชิงนโยบายที่อิงกับหลักฐานอย่างแท้จริง

นอกจากนี้ ควรมีการลงทุนในด้านเทคโนโลยีสารสนเทศ และบุคลากรที่มีความเชี่ยวชาญในการพัฒนาแบบจำลอง AI และ Machine Learning รวมถึงมีการปรับปรุงระบบการจัดเก็บข้อมูลภาคสนามให้มีความครบถ้วน สม่าเสมอ และเป็นระบบ เพื่อเพิ่มคุณภาพของข้อมูลที่จะนำมาใช้ในการบวนการวิเคราะห์และคัดกรองครัวเรือนกลุ่มเปราะบาง

ในระยะยาว การส่งเสริมให้เกิดการเชื่อมโยงข้อมูลระหว่างหน่วยงานควบคู่กับการประยุกต์ใช้เทคโนโลยีสมัยใหม่ จะช่วยสร้างกลไกการให้สวัสดิการที่มีความยืดหยุ่น ลดความสูญเสียของงบประมาณ และตอบสนองต่อความต้องการของประชาชนได้อย่างแท้จริง

5.2 ข้อเสนอแนะสำหรับงานศึกษาขั้นถัดไป

จากผลการศึกษาครั้งนี้ พบว่าการใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) สามารถช่วยเพิ่มประสิทธิภาพในการคัดกรองและวิเคราะห์สถานการณ์ความยากจนของครัวเรือนได้อย่างมีนัยสำคัญ อย่างไรก็ตาม เพื่อให้การประยุกต์ใช้เทคโนโลยีดังกล่าวมีความแม่นยำ และสามารถสะท้อนความเป็นจริงของปัญหาเชิงสังคมในระยะยาวได้ดียิ่งขึ้น งานศึกษาขั้นถัดไปควรพิจารณาพัฒนาในแนวทางต่อไปนี้

5.2.1 การนำข้อมูลแบบช่วงเวลา (Panel Data) มาใช้ในการวิเคราะห์พลวัตของความยากจน

งานศึกษาครั้งนี้ใช้ข้อมูลแบบตัดขวาง (Cross-sectional Data) ซึ่งแม้จะมีข้อดีในการประมวลผลและเข้าใจสถานะในช่วงเวลาใดเวลาหนึ่ง แต่ยังขาดความสามารถในการติดตามการเปลี่ยนแปลงเชิงเวลา การนำข้อมูลแบบ Panel data มาใช้จะช่วยให้สามารถวิเคราะห์ “พลวัตของความยากจน” (Poverty Dynamics) ได้ชัดเจนยิ่งขึ้น เช่น การวิเคราะห์การตกหล่น (Falling Into Poverty) และการหลุดพ้นจากความยากจน (Escaping Poverty) รวมถึงการประเมินผลกระทบของนโยบายรัฐในช่วงเวลาต่าง ๆ ได้แม่นยำมากขึ้น ทั้งนี้การใช้ Panel Data จะช่วยให้สามารถประเมิน Causal Impact ของนโยบายที่มีต่อกลุ่มเป้าหมายได้อย่างน่าเชื่อถือยิ่งขึ้น

5.2.2 การใช้ Hybrid Technique เพื่อเพิ่มประสิทธิภาพของแบบจำลอง

การปรับปรุงแบบจำลองให้มีประสิทธิภาพมากยิ่งขึ้นสามารถทำได้ โดยเฉพาะในบริบทที่มีการนำการตัดช่วงรายได้ (Income Truncation) มาผนวกเข้ากับเทคนิคการปรับค่าถ่วงน้ำหนัก (Class Weighting) อย่างเป็นลำดับขั้น กล่าวคือ หากมีการกำหนดช่วงรายได้ให้แคบลงก่อน (เช่น ตัดเฉพาะครัวเรือนที่มีรายได้ต่ำกว่า 8,000 บาท) แล้วจึงดำเนินการปรับค่าถ่วงน้ำหนักสำหรับครัวเรือนยากจนในขั้นตอนต่อมา จะยิ่งช่วยเพิ่มประสิทธิภาพของแบบจำลองในการจำแนกกลุ่มเป้าหมายได้ดียิ่งขึ้น

เหตุผลสำคัญคือ การตัดช่วงรายได้จะช่วยลดความเหลื่อมล้ำภายในข้อมูล ซึ่งช่วยให้แบบจำลองสามารถเรียนรู้ลักษณะของกลุ่มเป้าหมายได้อย่างลึกซึ้งยิ่งขึ้น ในขณะที่การถ่วงน้ำหนักจะเป็นกลไกเสริมที่ช่วยชดเชยจำนวนตัวอย่างที่ไม่สมดุลของคลาสย่อยภายในช่วงข้อมูล

ที่คัดเลือกมาแล้วนั้น ส่งผลให้แบบจำลองไม่เพียงลดข้อผิดพลาดในการคัดกรอง แต่ยังสามารถรักษาสมดุลระหว่างความแม่นยำ (Precision) และความครอบคลุม (Recall) ได้ดียิ่งขึ้น โดยเฉพาะในกรณีที่กลุ่มยาจนมีขนาดเล็กมาก

ดังนั้น การผสานแนวทางการตัดช่วงรายได้ล่วงหน้า และการปรับค่าถ่วงน้ำหนักเข้าด้วยกันในการคัดกรองครัวเรือนยากจน ควรได้รับการพิจารณาในงานวิจัยและการประยุกต์ใช้งานจริงในอนาคต เพื่อยกระดับความแม่นยำและความยุติธรรมของระบบการคัดกรองผู้มีสิทธิเข้าร่วมโครงการสวัสดิการภาครัฐให้มีประสิทธิภาพมากยิ่งขึ้น

5.2.3 การสร้างตัวแปรสังเคราะห์เพื่อเพิ่มประสิทธิภาพของแบบจำลอง

อีกแนวทางหนึ่งในการเพิ่มศักยภาพของแบบจำลอง คือการสร้างตัวแปรใหม่ (Feature Engineering) โดยการรวมกลุ่มตัวแปรที่เกี่ยวข้องกัน เช่น การรวมหลอดไฟประเภทต่าง ๆ (หลอดตะเกียบ หลอด LED หลอดนีออน) เข้าด้วยกันเป็นตัวแปร "แสงสว่างภายในครัวเรือน" เพื่อให้สามารถตีความได้ง่ายขึ้นและลดปัญหาความซ้ำซ้อนของตัวแปร นอกจากนี้ ยังสามารถสร้างตัวแปรเชิงดัชนีที่สะท้อนคุณภาพชีวิต เช่น “ดัชนีความสะดวกสบายในชีวิตประจำวัน” จากการรวมตัวแปรเกี่ยวกับเครื่องใช้ไฟฟ้า การเข้าถึงบริการพื้นฐาน หรือการเคลื่อนที่ภายในพื้นที่ว่าใช้พาหนะใด เป็นต้น

5.2.4 การจัดการกับตัวแปรที่มีความสัมพันธ์กันสูง (High Correlation)

ในการวิเคราะห์แบบจำลองเชิง Machine Learning ตัวแปรที่มีความสัมพันธ์กันสูงในระดับ 80-90% ขึ้นไปอาจก่อให้เกิดปัญหาการเรียนรู้ซ้ำซ้อน ซึ่งส่งผลต่อความแม่นยำและเสถียรภาพของแบบจำลอง การใช้วิธีการเชิงสถิติเพื่อตรวจสอบ Multicollinearity และการเลือกตัดตัวแปรที่ซ้ำซ้อนออกอย่างเป็นระบบ เช่น การใช้ Principal Component Analysis (PCA) หรือ Variance Inflation Factor (VIF) จะช่วยให้แบบจำลองเรียนรู้จากความแตกต่างของข้อมูลได้อย่างมีประสิทธิภาพมากขึ้น โดยเฉพาะในกรณีที่มีตัวแปรจำนวนมาก

5.2.5 การบูรณาการข้อมูลหลากหลายมิติเพื่อเพิ่มความครอบคลุมของตัวแบบ

งานวิจัยในอนาคตควรขยายมิติวิเคราะห์จากเพียงปัจจัยทางเศรษฐกิจไปสู่ตัวแปรที่สะท้อนคุณภาพชีวิตโดยรวม เช่น ตัวแปรด้านสุขภาพกายและจิต การเข้าถึงการศึกษาของสมาชิกในครัวเรือน หรือระดับความพึงพอใจต่อชีวิตและสภาพแวดล้อม การนำตัวแปรเหล่านี้มาใช้ในแบบจำลองจะช่วยสร้างความเข้าใจเชิงลึกและรอบด้านยิ่งขึ้นเกี่ยวกับสาเหตุเชิงโครงสร้างของความยากจน และสามารถนำไปสู่การออกแบบนโยบายแบบองค์รวม (Holistic Policy Design) ที่ตอบโจทย์ความเปราะบางในหลายมิติได้ดียิ่งขึ้น

รายการอ้างอิง

วิทยานิพนธ์และงานวิจัย

- ชัยยุทธ ปัญญสวัสดิ์สุทธิ์ และคณะ (2560), รายงานฉบับสมบูรณ์ โครงการพัฒนาระบบสารสนเทศเพื่อหลักประกันโอกาสทางการเรียนรู้: พัฒนาระบบสารสนเทศเพื่อหลักประกันโอกาสทางการเรียนรู้ (หลักเกณฑ์และวิธีการคัดกรอง), ศูนย์บริการวิชาการเศรษฐศาสตร์ คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์
- ชัยยุทธ ปัญญสวัสดิ์สุทธิ์ และคณะ. (2562). โครงการวิจัยเพื่อติดตามและปรับปรุง กระบวนการคัดกรองและการจัดสรรเงินอุดหนุนอย่างมีเงื่อนไข ในสถานศึกษาสังกัดสำนักงานคณะกรรมการการศึกษาขั้นพื้นฐานและองค์กรปกครองส่วนท้องถิ่น.
- ชัยยุทธ ปัญญสวัสดิ์สุทธิ์ และคณะ. (2565). โครงการวิจัยเพิ่มประสิทธิภาพหลักเกณฑ์คัดกรองความยากจนด้วยวิธีการวัดรายได้ทางอ้อม เพื่อจัดสรรเงินอุดหนุนแบบมีเงื่อนไขประจำปีการศึกษา 2565.
- สำนักงานสถิติแห่งชาติ กระทรวงดิจิทัลเพื่อเศรษฐกิจและสังคม. (2023). *สรุปผลที่สำคัญ การสำรวจภาวะเศรษฐกิจและสังคมของครัวเรือน พ.ศ. 2566* สำนักงานสถิติแห่งชาติ กระทรวงดิจิทัลเพื่อเศรษฐกิจและสังคม.

Thesis and research

- Athey, S. (2018). *The Impact of Machine Learning on Economics*.
- Friedman, J. H. (February 1999). *Greedy Function Approximation: A Gradient Boosting Machine*.
- Gareth James; Daniela Witten; Trevor Hastie; Robert Tibshirani (2013). *An Introduction to Statistical Learning*.
- Grosh, M., del Ninno, C., Tesliuc, E., & Ouerghi, A. (2008). *For Protection and Promotion: The Design and Implementation of Effective Safety Nets*. The World Bank.

- Grosh, Margaret E.; Baker, Judy L.. *Proxy means tests for targeting social programs : simulations and speculation (English)*. Living standards measurement study (LSMS) working paper|no. LSM 118 Washington, D.C.: The World Bank. <http://documents.worldbank.org/curated/en/750401468776352539>
- Houssou, N., Zeller, M., Alcaraz, G., Schwarze, S., & Johannsen, J. (2007). *Proxy Means Tests for Targeting the Poorest Households Applications to Uganda Pro-poor development in low-income countries: Food, agriculture, trade, and environment*.
- Kambuya, P. (2017). *Better Model Selection for Poverty Targeting through Machine Learning: A Case Study in Thailand (Vol. 38, Issue 1)*.
- Kidd, S., & Wylde, E. (2011). *Targeting the Poorest: An Assessment of the Proxy Means Test Methodology*. AusAID & Development Pathways.
- Mcbride, L., & Nichols, A. (2016). *Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning*. <http://econ.worldbank.org>.
- Tapanat Pailboonsin. (2018). *TARGETING POOR STUDENTS IN THAILAND WITH PROXY MEANS TEST*.
- UNICEF. (2021). *Improving poverty targeting using Machine Learning: A case study from the Philippines*. UNICEF Social Policy Working Paper Series.
- World Bank. (2019). *Targeting poor households in Pakistan: Combining PMT with Machine Learning*. World Bank Technical Note Series.
- Ysobel, D., & Ting, P. (2024). *Applying an Unsupervised Machine Learning Approach to Analyze the Non-Income Poverty Indicators Used in the Listahanan 2*.

Articles

- Araujo, M. C., Bosch, M., & Schady, N. (2017). *Can cash transfers help households escape an inter-generational poverty trap? In the Economics of Poverty Traps*. University of Chicago Press.
- Attanasio, O. P., Meghir, C., & Santiago, A. (2011). *Education choices in Mexico: using a structural model and a randomized experiment to evaluate Progresa*. The Review of Economic Studies, 79(1), 37-66.

- Baird, S., Ferreira, F. H., Özler, B., & Woolcock, M. (2014). *Conditional, unconditional and everything in between: a systematic review of the effects of cash transfer programmed on schooling outcomes*. *Journal of Development Effectiveness*, 6(1), 1-43.
- Behrman, J. R., Parker, S. W., & Todd, P. E. (2009). *Schooling impacts of conditional cash transfers on young children: Evidence from Mexico*. *Economic development and cultural change*, 57(3), 439-477.
- Behrman, J. R., Parker, S. W., & Todd, P. E. (2011). *Do conditional cash transfers for schooling generate lasting benefits? A five-year followup of PROGRESA/Oportunidades*. *Journal of Human Resources*, 46(1), 93-122.
- Behrman, J. R., Sengupta, P., & Todd, P. (2005). *Progressing through PROGRESA: An impact assessment of a school subsidy experiment in rural Mexico*. *Economic development and cultural change*, 54(1), 237-275.
- Carvalho, M., Silva, A., & Lima, T. (2022). *Enhancing social assistance targeting using spatial Machine Learning: Evidence from Brazil*. *World Bank Policy Research Working Paper No. 10243*. <https://doi.org/10.1596/1813-9450-10243>
- Poulin, C., Trimmer, J., Press-Williams, J., Yachori, B., Khush, R., Peletz, R., & Delaire, C. (2022). *Performance of a novel Machine Learning-based proxy means test in comparison to other methods for targeting pro-poor water subsidies in Ghana*. *Development Engineering*, 7, 100098. <https://doi.org/10.1016/J.DEVENG.2022.100098>
- Wobcke, W., & Mariyah, S. (2023). *Improving proxy means tests using Machine Learning and data augmentation*. *Statistical Journal of the IAOS*, 39(2), 435–447. <https://doi.org/10.3233/SJI-230033>

Books

- Kotsiantis, S., Kanellopoulos, D., & Pintelas, P. (2006). *Handling imbalanced datasets: A review*. *GESTS International Transactions on Computer Science and Engineering*, 30(1), 25–36.
- Tatsuro (1983). *Game Theory for Economic Analysis*. New York: Academic Press. pp.

Electronic media

Dell, M. (2024). *Deep Learning for Economists*. <http://arxiv.org/abs/2407.15339>

Duval, A. (2019). *Explainable Artificial Intelligence (XAI)*.

<https://doi.org/10.13140/RG.2.2.24722.09929>

