

Create proxy mean test by using Machine Learning technique

Bhawin Teveyanun¹

¹ Faculty of Economics, Thammasat University, Thailand

plyebhawin@gmail.com

Abstract

This study aims to develop a model for PMT using Machine Learning techniques. It starts by reviewing the weaknesses of the traditional model for measuring PMT, then develops a model for measuring PMT using Machine Learning techniques to find the most efficient model. The study also analyzes the impact of each variable on the model, which the traditional Machine Learning model cannot explain, using the SHAP value. The results of the study on the efficiency of the model in predicting whether a household is poor or not, show that the model accurately predicts 91% of the households identified as poor, while the model only covers 50% of the total poor households, and the overall model accuracy is 65% (F1-score). These results are significantly more efficient than the traditional methods, and policy recommendations can be made based on the top ten variables with the highest impact on the prediction.

Keywords : Proxy means test (PMT), Machine Learning, Poverty

การสร้างแบบจำลองการวัดรายได้ทางอ้อมด้วยวิธี Machine Learning

ภวินทร์ เตรียนันท์¹

¹นักศึกษาระดับปริญญาโท คณะเศรษฐศาสตร์ สาขาวิชาเศรษฐศาสตร์ มหาวิทยาลัย
ธรรมศาสตร์

plyebhawin@gmail.com

บทคัดย่อ

งานศึกษาต้องการพัฒนาการสร้างแบบจำลองการวัดรายได้ทางอ้อมผ่านการใช้เทคนิค Machine Learning เริ่มจากการทบทวนจุดอ่อนของแบบจำลองการวัดรายได้ทางอ้อมโดยวิธีปกติ จากนั้นพัฒนาแบบจำลองการวัดรายได้ทางอ้อมผ่านการใช้เทคนิค Machine Learning เพื่อหาแบบจำลองการวัดรายได้ทางอ้อมที่มีประสิทธิภาพมากที่สุด นอกจากนี้งานศึกษายังวิเคราะห์ผลกระทบของแต่ละตัวแปรต่อแบบจำลองที่ปกติแบบจำลองแบบ Machine Learning ไม่สามารถอธิบายได้ผ่านการใช้ค่า SHAP ผลลัพธ์จากงานศึกษาประสิทธิภาพของแบบจำลองในการทำนายว่าครัวเรือนนั้นเป็นครัวเรือนยากจนหรือไม่ พบว่าผลการทำนายที่เป็นครัวเรือนยากจนทั้งหมดแบบจำลองจะทำนายว่าเป็นครัวเรือนยากจนได้อย่างถูกต้องร้อยละ 91 ในขณะที่ครัวเรือนที่ทำนายถูกต้องว่าเป็นครัวเรือนยากจนจะครอบคลุมครัวเรือนยากจน

เพียงร้อยละ 50 ของครัวเรือนยากจนทั้งหมด และแบบจำลองมีค่าความแม่นยำของแบบจำลองโดยรวมอยู่ที่ร้อยละ 65 (F1-score) ซึ่งผลดังกล่าวมีประสิทธิภาพมากกว่าการใช้วิธีการแบบปกติสูงมาก และยังสามารถนำเสนอข้อเสนอแนะเชิงนโยบายตามตัวแปรที่ส่งผลกระทบต่อการทำนายสูงสุดสิบอันดับแรก

คำสำคัญ : แบบจำลองการวัดรายได้ทางอ้อม, การเรียนรู้ของเครื่อง, ความยากจน

บทนำ

ปัญหาความยากจนเป็นปัญหาหลักที่พบได้ทั่วไปในโลก โดยเฉพาะประเทศกลุ่มกำลังพัฒนาอย่างประเทศไทย ความยากจนไม่ใช่เพียงปัญหาทางด้านโครงสร้างเท่านั้น แต่ยังเป็นปัญหาทางด้านความเหลื่อมล้ำทางสังคม โดยหนึ่งในเครื่องมือที่ทางภาครัฐนิยมใช้เป็นเครื่องมือหลักในการช่วยเหลือคนยากจนคือ การอุดหนุนทางการเงินแบบมีเงื่อนไข (CONDITIONAL CASH TRANSFERS: CCT)

การอุดหนุนทางการเงินแบบมีเงื่อนไขมีจุดสำคัญคือค้นหาว่าใครเป็นคนจน และเกณฑ์การคัดกรองควรจะเป็นเช่นไรเพื่อให้นโยบายมีประสิทธิภาพผลและมีการรั่วไหลออกมาน้อยที่สุด ดังนั้นอาจจะกล่าวได้ว่าการค้นหาตัวคนจนจึงเป็นประเด็นที่สำคัญมากที่สุดสำหรับนโยบายการช่วยเหลือคนจน

เครื่องมือที่ใช้ในการตามหาคนจนนั้นมีหลากหลายเครื่องมือ แต่วิธีที่ได้รับความนิยมและใช้กันอย่างแพร่หลายคือวิธีการวัดรายได้โดยอ้อม หรือที่เรียกว่า PROXY MEANS TEST (PMT) เป็นวิธีการทางสถิติเพื่อใช้ในการกำหนดเกณฑ์ว่าครัวเรือนใดเป็นครัวเรือนยากจน ผ่านการวิเคราะห์ทางสถิติเพื่อกำหนดตัวชี้วัดอื่น ๆ ที่ไม่ใช่รายได้ แต่มีความสามารถในการบ่งบอกระดับรายได้ (ในทางกลับกันตรงข้ามกับรายได้คือความยากจน)

จากงานศึกษาเรื่องเพิ่มประสิทธิภาพหลักเกณฑ์คัดกรองความยากจนด้วยวิธีการวัดรายได้ทางอ้อมของชัยยุทธและคณะ (2565) โดยวิธีการสร้างแบบจำลองการวัดรายได้ทางอ้อมแบบดั้งเดิมพบว่ามีข้อจำกัดที่จำเป็นต้องพึงพาการเลือกตัวแปรที่มีคุณภาพมาก ทำให้วิธีดังกล่าวยังมีข้อจำกัดในการเลือกตัวแปรที่สนใจมาใช้แทนรายได้ของครัวเรือน เช่น ขั้นตอนการเลือกตัวแปรที่มีข้อจำกัดต้องเลือกผ่านตัวแปรที่คิดว่าสามารถชี้วัดรายได้ได้จากตัวแปรหลายร้อยตัว หรือยังไม่มีมุมมองของการพัฒนาตัวแปรที่ใช้ในการศึกษาหรือเทคนิคที่เรียกว่า feature engineering ซึ่งก็คือการปรับเปลี่ยนข้อมูลให้อยู่ในรูปแบบที่มีประโยชน์ (features) และตัวแปรที่เลือกยังต้องคำนึงถึงปัญหาภาวะร่วมเส้นตรงเชิงพหุอีกด้วย

โดยในปัจจุบันการเลือกตัวแปรให้มีประสิทธิภาพมากยิ่งขึ้นสามารถใช้เทคนิคที่ใช้การประมวลผลทางคอมพิวเตอร์ที่มีประสิทธิภาพมากยิ่งขึ้นผ่านการใช้เทคนิคที่เรียกว่า Machine learning งานศึกษาของ Athley (2018) พบว่าการใช้เทคนิค machine learning กับการสร้างแบบจำลองในงานศึกษาทางด้านเศรษฐศาสตร์จะสามารถให้ได้แบบจำลองที่มีความ robust มากกว่าและยังสร้างแบบจำลองที่มีความเสถียรมากกว่า รวมทั้งยังสามารถแก้ไขปัญหาด่าง ๆ ของแบบจำลองได้มากขึ้น ซึ่งเป็นที่มาของโจทยวิจัยชิ้นนี้

แบบจำลองที่ใช้ในสร้างแบบจำลองการวัดรายได้ทางอ้อมในงานศึกษาครั้งนี้จะใช้แบบจำลองแบบการแบ่งกลุ่ม (Classification) ในลักษณะของ Binary โดยคำตอบมี 2 คำตอบ คือเป็นการทำนายสิ่งที่ใกล้เคียงกับข้อมูลที่ป้อน ว่าการจำแนกกลุ่มของครัวเรือนเป็น “ครัวเรือนยากจน” และ “ครัวเรือนรายได้สูง” ในรูปแบบของเทคนิคการทำ gradient boosting และศึกษาผลกระทบของแต่ละตัวแปรผ่านการวิเคราะห์จากการคำนวณค่า Shapley values (ตามแบบจำลองของทฤษฎีเกม) เพื่อให้ได้มิติมุมมองเรื่องการคัดกรองครัวเรือนยากจนที่หลากหลายมากขึ้น

ในงานศึกษามีวัตถุประสงค์สองประการคือ เพื่อพัฒนาแบบจำลองการวัดรายได้ทางอ้อมโดยอาศัยเทคนิค machine learning เพื่อเพิ่มประสิทธิภาพการประมาณค่าที่วัดจากค่าอัตราการพลาดโอกาส (Exclusion error) และอัตราการรั่วไหล (Inclusion error) เพื่อศึกษาผลกระทบของแต่ละตัวแปรต่อตัวแบบจำลองผ่านการวิเคราะห์ผ่านค่า Shapley values

การทบทวนวรรณกรรม

Proxy Means Test เป็นเทคนิคทางสถิติที่ใช้ในการระบุครัวเรือนยากจน โดยพิจารณาจากตัวชี้วัดอื่นๆ นอกเหนือจากรายได้ที่มีความสัมพันธ์กับระดับความยากจนของครัวเรือน แทนที่จะสอบถามรายได้โดยตรง วิธีการนี้มีข้อดีคือ ตัวชี้วัดที่นำมาใช้ในการประเมินต้องวัดและตรวจสอบได้ง่าย มีความน่าเชื่อถือ และยากต่อการปกปิดข้อมูลจริง ซึ่งเป็นปัญหาหากใช้การสอบถามรายได้โดยตรง วิธี PMT จึงเป็นทางเลือกที่มีประสิทธิภาพในการระบุครัวเรือนยากจน และได้รับการนำมาใช้อย่างแพร่หลายในหลายประเทศ ดังนั้น วิธี PMT นี้จะช่วยให้สามารถระบุครัวเรือนยากจนได้อย่างมีประสิทธิภาพ และเป็นเครื่องมือสำคัญในการกำหนดนโยบายและมาตรการช่วยเหลือครัวเรือนที่มีฐานะทางเศรษฐกิจและสังคมที่ยากจน

หนึ่งใน PMT ที่มีชื่อเสียง คือ ดัชนีความน่าจะเป็นที่จะยากจน (Poverty Probability Index: PPI) ของ Schreiner (2006, 2015, 2017) ซึ่งถูกสร้างขึ้นเพื่อใช้ในการคัดกรองคนยากจนในกว่า 60 ประเทศทั่วโลก โดยอิงคะแนนความยากจน (Poverty Scorecard) ในแต่ละประเทศ ถูกสร้างขึ้น ผ่านการใช้วิธีการทางสถิติในการประมาณค่าแบบโลจิสติก (Logistic Regression) และมีการจำกัดตัวแปรที่ใช้เป็นตัวชี้วัดความยากจนเพียงแค่ 10 ตัวแปรเท่านั้น ซึ่งช่วยในด้านของความสะดวกและลดต้นทุนในการเก็บข้อมูล

สำหรับการคัดกรองคนยากจนด้วยวิธีการวัดรายได้ทางอ้อมในประเทศไทย งานศึกษาของชัยยุทธและคณะ (2565) ได้ทำการสร้างคะแนนความยากจนโดยอาศัยหลักการของ PMT ขึ้น เพื่อใช้ในการคัดกรองนักเรียนยากจนใน 10 จังหวัดของประเทศไทย โดยใช้วิธีการประมาณค่าแบบกำลังสองน้อยที่สุด (Least Squares Regression) เพื่อหาความสัมพันธ์ระหว่างรายได้ครัวเรือนเฉลี่ยต่อหัวต่อเดือน และ

ทางด้านสถานะทางด้านครัวเรือน โดยมีการใช้ตัวแปรหุ่น (Dummy Variables) ของจังหวัด

ถึงแม้ว่าการใช้เทคนิค proxy mean test เป็นวิธีการที่นิยมใช้ในการวิเคราะห์และประเมินภาวะความยากจนในระดับครัวเรือน แต่อย่างไรก็ตาม วิธีการดังกล่าวก็มีจุดอ่อนอยู่หลากหลายประการ อาทิเช่นการใช้ PMT อาจทำให้เกิดความคลาดเคลื่อนในการประเมินภาวะความยากจน เนื่องจากตัวแปรที่ใช้เป็นตัวแทนอาจจะไม่สามารถสะท้อนความเป็นจริงของความยากจนได้อย่างแท้จริง ทำให้ผลการวิเคราะห์และการประเมินภาวะความยากจนอาจไม่ตรงกับความเป็นจริง (Ysobel & Ting, 2022)

งานศึกษาของ Houssou และคณะ (2007) มีการสร้างแบบจำลองการวัดรายได้ทางอ้อมผ่านเทคนิคอื่น ๆ นอกเหนือจากวิธี Ordinary least square (OLS) ประกอบไปด้วยแบบจำลอง Linear Probability Mode แบบจำลอง Probit และแบบจำลอง Quantile regressions ผลการศึกษาพบว่าแบบจำลอง Quantile regressions สามารถใช้ในการสร้างแบบจำลองการวัดรายได้ทางอ้อมได้ดีที่สุด

งานศึกษาของ McBride และ Nichols (2016) มีการใช้เทคนิค machine learning มาเปรียบเทียบกับแบบจำลองการวัดรายได้ทางอ้อมแบบดั้งเดิมเพื่อที่จะกำหนดเป้าหมายกลุ่มคนยากจนเพื่อได้รับนโยบาย water subsidy ในประเทศกานา โดยในงานศึกษาชิ้นนี้มีการนำเทคนิค LASSO (Least Absolute Shrinkage and Selection Operator) มาใช้ในการเลือกตัวแปรสำหรับการทำแบบจำลองการวัดรายได้ทางอ้อมพบว่าการใช้เทคนิค machine learning ดังกล่าวมีผลของความแม่นยำในการชี้วัดครัวเรือนยากจนได้มากกว่าการใช้แบบจำลองการวัดรายได้ทางอ้อมแบบดั้งเดิมอย่างมีนัยสำคัญ ทั้งนี้ในงานศึกษาชิ้นนี้ยังมีข้อเสนอแนะเพิ่มเติมอีกว่าหากจำนวนของข้อมูลมีขนาดที่ใหญ่มากยิ่งขึ้นจะทำให้ผลของการใช้เทคนิคดังกล่าวมีประสิทธิภาพมากยิ่งขึ้น

การศึกษาของ Kambuya (2017) ได้ประยุกต์ใช้แนวคิดของ Proxy Mean Test เพื่อคัดกรองครัวเรือนที่ประสบปัญหาความยากจน โดยเปรียบเทียบประสิทธิภาพของเทคนิคการคัดเลือกตัวแปรชี้วัดความยากจนด้วย 3 วิธี ได้แก่ Stepwise Regression, LASSO และ Random Forest โดยใช้ข้อมูลครัวเรือนจากการสำรวจภาวะเศรษฐกิจและสังคมของครัวเรือน (Household Socio-Economic Survey: SES) ปี พ.ศ. 2559 ของสำนักงานสถิติแห่งชาติ ผลการศึกษาพบว่า ทั้งสามวิธีสามารถคัดเลือกตัวแปรชี้วัดความยากจน ที่มีความคล้ายคลึงกับตัวแปรในการศึกษา


ของ ชัยยุทธ และคณะ (2560) หลังจากประมาณค่าด้วยวิธีกำลังสองน้อยที่สุด (Least Square Regression) เพื่อสร้างคะแนนความยากจนด้วยวิธี PMT พบว่า ทั้งสามเทคนิคมีประสิทธิภาพในการคัดกรองครัวเรือนยากจนค่อนข้างดีแต่ยังมีจุดอ่อนในเรื่องการแปลความหมายของตัวแปรที่หายไปเมื่อเปรียบเทียบกับแบบจำลองแบบดั้งเดิม

โดยสรุปจากการทบทวนวรรณกรรมพบว่าการใช้เทคนิค Machine learning การใช้เทคนิค machine learning จะสามารถให้ได้แบบจำลองที่มีความ robust มากกว่า และยังสร้างแบบจำลองที่มีความเสถียรมากกว่า รวมทั้งยังสามารถแก้ไขปัญหาต่างๆ ของแบบจำลองได้มากกว่าแบบจำลองแบบดั้งเดิม

วิธีการดำเนินการวิจัย

ขั้นตอนกระบวนการที่ใช้ในงานศึกษาชิ้นนี้สามารถสรุปได้ดังรูปที่ 1

รูปที่ 1 สรุปขั้นตอนกระบวนการในการศึกษา



ขั้นตอนกระบวนการที่ใช้ในงานศึกษาชิ้นนี้ประกอบไปด้วย 4 ขั้นตอนหลัก ๆ คือขั้นตอนแรกการเตรียมข้อมูล ขั้นตอนคัดเลือกครัวเรือนยากจนสำหรับใช้เป็นตัวแบบ (Label) ให้แบบจำลอง machine learning เรียนรู้ ขั้นตอนการสร้างแบบจำลอง machine learning พร้อมทั้งเปรียบเทียบแบบจำลองต่าง ๆ และขั้นตอนสุดท้ายเป็นการแปลผลของตัวแปรต่าง ๆ ที่ได้จากการใช้แบบจำลอง

ข้อมูลที่ใช้ในงานศึกษาจะใช้ข้อมูลสามส่วนหลักประกอบไปด้วย ส่วนแรกข้อมูลการสำรวจสถานะเศรษฐกิจสังคมของครัวเรือน (SES) ปี พ.ศ. 2564 โดยใช้ข้อมูลประกอบไปด้วยข้อมูลรายได้ (ใช้สำหรับคัดแยกครัวเรือนยากจนกับครัวเรือนที่ไม่ใช่เพื่อให้แบบจำลอง machine learning ใช้ในการเรียนรู้) ข้อมูลลักษณะของครัวเรือน ข้อมูลลักษณะของที่อยู่อาศัย ข้อมูลการถือครองทรัพย์สินต่าง ๆ ของครัวเรือน และข้อมูลรายจ่ายประเภทต่าง ๆ ส่วนที่สองข้อมูลการสำรวจสถานะเศรษฐกิจสังคมของครัวเรือน (SES) ปี พ.ศ. 2564 รายบุคคล เพื่อใช้สำหรับสร้างตัวแปรลักษณะของครัวเรือน และส่วนที่สามข้อมูลคุณลักษณะของจังหวัดต่าง ๆ อาทิเช่น ข้อมูลผลิตภัณฑ์มวลรวมจังหวัด (Gross provincial product: GPP) ข้อมูลจำนวนประชากรรายจังหวัด ข้อมูลลักษณะอุตสาหกรรมรายจังหวัด เป็นต้น

ขั้นตอนกระบวนการศึกษาสามารถอธิบายโดยสังเขปได้ดังนี้ การเตรียมข้อมูลจะเป็นการรวมระบบฐานข้อมูลสามส่วนเข้าด้วยกันเป็นระดับครัวเรือน หลังจากได้ข้อมูลครัวเรือนยากจนแล้วจะทำการแบ่งครัวเรือนยากจนกับครัวเรือนไม่ยากจนออกจากกัน โดยการกำหนดผ่านค่ารายได้ของแต่ละครัวเรือนเพื่อใช้สำหรับเป็นตัวแบบ (Label) ให้แบบจำลอง machine learning เรียนรู้และนำไปเข้าแบบจำลองทั้งสามแบบประกอบไปด้วยด้วย แบบจำลองแบบ classification แบบ logistics regression แบบจำลอง random forest และแบบจำลอง LightGBM จากนั้นจะนำผลของแบบจำลองมาเปรียบเทียบหาแบบจำลองที่ดีที่สุดแล้วนำไปแปรผลค่าที่ได้เพื่อใช้ในการอธิบายผลของแบบจำลองต่อไป

การชี้วัดผลของแบบจำลองจะประกอบไปด้วยค่าสองค่าคือค่า Precision และค่า Recall โดยค่าทั้งสองค่ามีความหมายดังต่อไปนี้ ค่า Precision มองในมุมว่าโมเดลทำนายได้แม่นยำแค่ไหนในค่าที่สนใจ คือผลการทำนายที่เป็นครัวเรือนยากจนทั้งหมดแบบจำลองจะทำนายว่าเป็นครัวเรือนยากจนได้อย่างถูกต้องมากน้อยแค่ไหน ในขณะที่ค่าของ Recall มองในมุมว่าแบบจำลองทำนายได้ถูกต้องแค่ไหน เช่น ในผลการทำนายที่ทั้งถูกและผิดแบบจำลองทำนายว่าเป็นครัวเรือนยากจนได้อย่างถูกต้องมากน้อยแค่ไหน

การแปลผลของการประมาณค่าเพื่อหาค่าทิศทางของค่าตัวแปรผ่านการทำ Shapley value คือเป็นการคำนวณภายใต้หลักทฤษฎีเกม (game theory) ในรูปแบบทฤษฎีเกมแบบร่วมมือ (coalitional game theory) โดยในหลักการดังกล่าว จะมีการมองค่าของฟีเจอร์หรือตัวแปรในแต่ละตัวเป็น “ผู้เล่น” (player) ของเกม และผลจากการ

ทำนายของโมเดลเป็น “ผลลัพธ์” (payout) ของเกม ซึ่งค่า Shapley value เป็นค่าที่ระบุว่าควรจะแบ่งผลลัพธ์ของเกมให้แก่ผู้เล่นแต่ละคนอย่างไรให้ยุติธรรมโดยอ้างอิงจากสัดส่วนการมีส่วนร่วม (contribution) ของผู้เล่นแต่ละคน เมื่อนำหลักการดังกล่าวมาใช้ในการวิเคราะห์โมเดล ค่านี้จึงสามารถใช้เพื่อบอกว่าแต่ละฟีเจอร์จะส่งผลกระทบต่อการทำนายของโมเดลมากน้อยอย่างไรได้

สรุปและอภิปรายผล

ผลของการเปรียบเทียบประสิทธิภาพของแบบจำลองทั้งสามรูปแบบพบว่าแบบจำลอง LightGBM ได้ผลลัพธ์ของแบบจำลองที่ดีที่สุด ผ่านการเลือกตัวแบบในการเรียนรู้ผ่านเทคนิค Cross Validation คือเครื่องมือที่ช่วยให้ตัดสินใจได้ว่าควรแบ่งข้อมูลส่วนไหนไปเป็น Training Data ซึ่ง K-Fold Cross Validation คือการที่แบ่งข้อมูลเป็นจำนวน K ส่วนโดยการในแต่ละส่วนจะต้องมาจากสุ่มเพื่อที่จะให้ข้อมูลกระจายเท่า ๆ กัน

ในแบบจำลอง LightGBM ได้ทำการสุ่มจำนวนครัวเรือนทั้งหมดจาก 46,840 ครัวเรือนมาใช้ในการเรียนรู้ของแบบจำลองจำนวนทั้งสิ้น 32,788 ครัวเรือน และใช้ครัวเรือนทั้งสิ้น 14,052 ครัวเรือนเป็นตัวชี้วัดความแม่นยำของแบบจำลองซึ่งสามารถแบ่งออกได้เป็นครัวเรือนไม่ยากจน 12,982 ครัวเรือน และครัวเรือนยากจนทั้งสิ้น 1,070 ครัวเรือน ผลของประสิทธิภาพแบบจำลองสามารถได้ดังรูปที่ 2

รูปที่ 2 แสดงผลประสิทธิภาพของแบบจำลอง LightGBM

	precision	recall	f1-score	support
0	0.91	0.50	0.65	1070
1	0.96	1.00	0.98	12982
accuracy			0.96	14052
macro avg	0.94	0.75	0.81	14052
weighted avg	0.96	0.96	0.95	14052

ตัวแปรผลของแบบจำลองสามารถแบ่งเป็นสองส่วน ส่วนแรกค่าเลข 0 หมายถึงแบบจำลองทายว่าครัวเรือนนั้นเป็นครัวเรือนยากจน ในขณะที่ 1 หมายถึงไม่ใช่ครัวเรือนยากจน โดยที่แบบจำลองจะทายครัวเรือนไม่ยากจนได้ครอบคลุมและมีประสิทธิภาพ

มากกว่าเนื่องจากจำนวนครัวเรือนยากจนมีปริมาณของข้อมูลให้แบบจำลองเรียนรู้ น้อยกว่า

ในแบบจำลอง LightGBM ได้ทำการสุ่มจำนวนครัวเรือนทั้งหมดจาก 46,840 ครัวเรือนมาใช้ในการเรียนรู้ของแบบจำลองจำนวนทั้งสิ้น 32,788 ครัวเรือน และใช้ ครัวเรือนทั้งสิ้น 14,052 ครัวเรือนเป็นตัวชี้วัดความแม่นยำของแบบจำลองซึ่งสามารถ แบ่งออกได้เป็นครัวเรือนไม่ยากจน 12,982 ครัวเรือน และครัวเรือนยากจนทั้งสิ้น 1,070 ครัวเรือน

ประสิทธิภาพของแบบจำลองในการทำนายว่าครัวเรือนนั้นเป็นครัวเรือนยากจนหรือไม่ พบว่าผลการทำนายที่เป็นครัวเรือนยากจนทั้งหมดแบบจำลองจะทำนายว่าเป็น ครัวเรือนยากจนได้อย่างถูกต้องร้อยละ 91 ในขณะที่ครัวเรือนที่ทำนายถูกต้องว่าเป็น ครัวเรือนยากจนจะครอบคลุมครัวเรือนยากจนเพียงร้อยละ 50 ของครัวเรือนยากจน ทั้งหมด และแบบจำลองมีค่าความแม่นยำของแบบจำลองโดยรวมอยู่ที่ร้อยละ 65 (F1-score)

ผลการทำนายของแบบจำลองพบว่าแบบจำลองมีตัวแปรที่สำคัญกับการทำนาย ครัวเรือนยากจน 10 อันดับแรกดังนี้ จำนวนสมาชิกที่ทำงานและได้รับค่าจ้าง ค่าเช่า บ้านต่อเดือน จำนวนสมาชิกที่ได้สิทธิบัตรทอง จำนวนสมาชิกในครัวเรือนรวม ไม่รวม ลูกจ้างและคนรับใช้ จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่ เกษตร จำนวนเครื่องปรับอากาศ อายุของหัวหน้าครัวเรือน จำนวนเตาไมโครเวฟ จำนวนเตียงนอน และจำนวนหลอดไฟนีออน

การอธิบายผลการวิจัยผ่านการอธิบายค่าตัวแปรผ่านค่า SHAP ของแบบจำลอง LightGBM สามารถอธิบายผลได้ดังนี้โดยเรียงลำดับจากความสำคัญของตัวแปรต่อ แบบจำลองจากมากไปน้อย ตัวแปรที่สำคัญที่สุดคือจำนวนสมาชิกที่ทำงานและได้รับ ค่าจ้าง ถ้าจำนวนสมาชิكدังกล่าวมีจำนวนมากจะยิ่งมีโอกาสที่ครัวเรือนจะเป็น ครัวเรือนไม่ยากจนในขณะที่ถ้าตัวแปรมีค่าน้อยจะยิ่งมีโอกาสเป็นครัวเรือนยากจน เยอะ ตัวแปรที่สำคัญลำดับถัดมาคือค่าเช่าบ้านต่อเดือนถ้าหากครัวเรือนมีค่าเช่าบ้าน ที่สูงจะยิ่งมีแนวโน้มที่จะเป็นครัวเรือนที่ไม่ยากจนมากกว่าครัวเรือนที่มีค่าเช่าบ้านที่ ต่ำกว่าโดยเปรียบเทียบ ซึ่งตัวแปรค่าเช่าบ้านดังกล่าวยังสะท้อนถึงรายจ่ายซึ่ง สามารถใช้เป็นตัวแทนรายได้อีกด้วย

ตัวแปรที่สำคัญลำดับที่สามคือจำนวนสมาชิกที่ได้สิทธิบัตรทอง ตัวแปรนี้มีผล ตรงกันข้ามกับตัวแปรอันดับแรก ถ้าจำนวนสมาชิكدังกล่าวมีจำนวนมากจะยิ่งมีโอกาส

ที่ครัวเรือนจะเป็นครัวเรือนยากจนในขณะที่ถ้าตัวแปรมีค่าน้อยจะยิ่งมีโอกาสเป็นครัวเรือนไม่ยากจน ตัวแปรสำคัญลำดับที่สี่คือ จำนวนสมาชิกในครัวเรือนรวม ไม่รวมลูกจ้างและคนรับใช้หากจำนวนสมาชิกดังกมีจำนวนมากจะยิ่งมีโอกาสที่ครัวเรือนจะเป็นครัวเรือนยากจนในขณะที่ถ้าตัวแปรมีค่าน้อยจะยิ่งมีโอกาสเป็นครัวเรือนไม่ยากจน เช่นเดียวกับตัวแปรก่อนหน้า ตัวแปรลำดับที่ห้า และหกคือ จำนวนสมาชิกที่ประกอบธุรกิจอุตสาหกรรมหรือวิชาชีพที่ไม่ใช่เกษตร และจำนวนเครื่องปรับอากาศ โดยในตัวแปรทั้งสองถ้ามีจำนวนของตัวแปรดังกล่าวมากจะมีโอกาสไม่ใช่ครัวเรือนยากจนมากกว่าจำนวนน้อย

ตัวแปรที่มีความสำคัญอันดับที่เจ็ดคือ อายุของหัวหน้าครัวเรือน ถ้าหัวหน้าครัวเรือนมีอายุมากจะยิ่งมีโอกาสที่จะเป็นครัวเรือนยากจนมากกว่า เนื่องจากสภาพของการเข้าถึงอาชีพและรายได้ต่าง ๆ มีข้อจำกัดมากขึ้นเมื่อมีอายุมากขึ้น ตัวแปรที่สำคัญลำดับถัดมาคือ จำนวนเตาไมโครเวฟที่มีใช้ในครัวเรือน ถ้ามีเตาไมโครเวฟใช้ในครัวเรือน ครัวเรือนจะยิ่งมีโอกาสเป็นครัวเรือนยากจนน้อยกว่า ครัวเรือนที่ไม่มีเตาไมโครเวฟใช้ ตัวแปรที่สำคัญเป็นอันดับที่เก้าคือ จำนวนเตียงนอน ถ้าครัวเรือนมีเตียงใช้ในครัวเรือน ครัวเรือนจะยิ่งมีโอกาสเป็นครัวเรือนยากจนน้อยกว่า ครัวเรือนที่ไม่มีเตียงนอนซึ่งตัวแปรส่งผลไปในลักษณะเดียวกันกับจำนวนเตาไมโครเวฟ และตัวแปรที่สำคัญเป็นลำดับที่สิบ คือ จำนวนหลอดไฟน็อน ถ้าครัวเรือนมีจำนวนหลอดไฟน็อนใช้ในครัวเรือนเยอะจะมีโอกาสที่ครัวเรือนจะไม่ใช่ครัวเรือนยากจนมากกว่า ครัวเรือนที่มีจำนวนหลอดไฟน็อนน้อยหรือไม่มีใช้ในครัวเรือนเลย เนื่องจากหลอดไฟถือว่าเป็นสิ่งจำเป็นพื้นฐานในการเข้าถึงแสงสว่างซึ่งถือเป็นปัจจัยพื้นฐานในการดำรงชีพ

จะเห็นได้ว่าตัวแปรที่แบบจำลองมองว่าสำคัญกับการทำนายครัวเรือนยากจนจะมีผลของตัวแปรไปในทิศทางที่ถูกต้องตามหลักการทางด้านเศรษฐศาสตร์และนโยบายสาธารณะทั้งหมดดังนั้งานวิจัยชิ้นนี้จึงได้ข้อสรุปว่านอกจากการใช้แบบจำลองเทคนิค Machine Learning ในการทำนายครัวเรือนยากจนนอกจากจะมีความแม่นยำของแบบจำลองที่มากกว่าการใช้แบบจำลองแบบปกติแล้ว การอธิบายผลของแบบจำลองยังสอดคล้องกับทฤษฎี และยังไม่ต้องคำนึงถึงปัญหาภาวะร่วมเส้นตรงเชิงพหุหรือ Multicollinearity ทำให้ตัวแปรที่นำมาอธิบายมีความกว้างและหลากหลายไม่จำเป็นต้องเลือกตัวแปรมาวิเคราะห์เพียง 10 ตัวเช่นงานศึกษาของ Schreiner (2006, 2015, 2017) และงานศึกษาของชัยยุทธ และคณะ (2560)

โดยสรุปแล้วงานศึกษาชิ้นนี้มีข้อเสนอแนะให้การค้นหาคนจนควรทำเกณฑ์ตัวแปรที่ได้จากการใช้แบบจำลอง Machine Learning เป็นตัวช่วยในการคัดกรองครัวเรือนยากจนเพื่อให้ได้ประสิทธิภาพของการคัดกรองครัวเรือนยากจนที่ดีที่สุดและควรมีการประยุกต์นำเทคนิค Machine Learning ไปใช้กับงานศึกษาทางด้านเศรษฐศาสตร์ขึ้นอื่น ๆ เพื่อให้เกิดประสิทธิภาพของแบบจำลองที่สูงที่สุด และใช้ค่า SHAP ในการแปรผลของแบบจำลองเพื่อไม่ให้แบบจำลองสูญเสียความสามารถในการอธิบายผลตัวแปรไป

เอกสารอ้างอิง

- ชัยยุทธ ปัญญสวัสดิ์สุทธิ์ และคณะ. (2560), รายงานฉบับสมบูรณ์ โครงการพัฒนาระบบสารสนเทศเพื่อหลักประกันโอกาสทางการเรียนรู้: พัฒนาด้านแบบระบบสารสนเทศเพื่อหลักประกันโอกาสทางการเรียนรู้ (หลักเกณฑ์และวิธีการคัดกรอง), ศูนย์บริการวิชาการเศรษฐศาสตร์ คณะเศรษฐศาสตร์ มหาวิทยาลัยธรรมศาสตร์
- ชัยยุทธ ปัญญสวัสดิ์สุทธิ์ และคณะ. (2565). โครงการวิจัยเพิ่มประสิทธิภาพหลักเกณฑ์คัดกรองความยากจนด้วยวิธีการวัดรายได้ทางอ้อม เพื่อจัดสรรเงินอุดหนุนแบบมีเงื่อนไขประจำปีการศึกษา 2565.
- Athey, S. (2018). The Impact of Machine Learning on Economics.
- Houssou, N., Zeller, M., Alcaraz, G., Schwarze, S., & Johannsen, J. (2007). Proxy Means Tests for Targeting the Poorest Households Applications to Uganda Pro-poor development in low income countries: Food, agriculture, trade, and environment.
- Kambuya, P. (2017). Better Model Selection for Poverty Targeting through Machine Learning: A Case Study in Thailand (Vol. 38, Issue 1).
- Mcbride, L., & Nichols, A. (2016). Retooling Poverty Targeting Using Out-of-Sample Validation and Machine Learning. <http://econ.worldbank.org>.
- Schreiner, M. (2006). A simple poverty scorecard for India. report to Grameen Foundation USA, http://www.microfinance.com/English/Papers/Scoring_Poverty_India.pdf. retrieved, Jan 1, 2019.
- Schreiner, M. (2015). An Expert-Based Poverty Scorecard for Rural China. [microfinance.com/English/Papers/Scoring_Poverty_China_EN.pdf](http://www.microfinance.com/English/Papers/Scoring_Poverty_China_EN.pdf), retrieved, Jan 1, 2019.

Schreiner, M. (2017). Simple Poverty Scorecard Poverty-Assessment Tool: Cambodia. SimplePovertyScorecard. com/KHM_2011_ENG. pdf, retrieved, Jan 1, 2019.

Ysobel, D., & Ting, P. (2024). Applying an Unsupervised Machine Learning Approach to Analyze the Non-Income Poverty Indicators Used in the Listahanan 2.

Data Availability Statement: The raw data supporting the conclusions of this article will be made available by the authors, without undue reservation.

Conflicts of Interest: The authors declare that the research was conducted in the absence of any commercial or financial relationships that could be construed as a potential conflict of interest.

Publisher's Note: All claims expressed in this article are solely those of the authors and do not necessarily represent those of their affiliated organizations, or those of the publisher, the editors and the reviewers. Any product that may be evaluated in this article, or claim that may be made by its manufacturer, is not guaranteed or endorsed by the publisher.



Copyright: © 2025 by the authors. This is a fully open-access article distributed under the terms of the Attribution-NonCommercial-NoDerivatives 4.0

International (CC BY-NC-ND 4.0).